استخراج اطلاعات وقایع تاریخی ایران به صورت سازمان‌یافته

نام اعضای تیم:

فرزان رحمانی

امیررضا ویشته

امیر واحدی

محمدرضا مزروعی

مقدمه ۲
انتخاب موضوع ۳
گردآوری داده‌ها و کراولینگ ۳
اسکریپت حذف داده‌های تکراری duplicat_csv_removal.py 5
ساختار بخش Scrapy 6
پیش‌پردازش داده‌ها ۱۰
هدف کلی پیش‌پردازش: ۱۰
پیش‌پردازش داده‌های فارسی: ۱۰
پیش‌پردازش داده‌های انگلیسی: ۱۱
استخراج اطلاعات ۱۶
۱. چارچوب پردازشی ۱۸
۲. قالب هدف ۱۸
۳. طراحی پرامپت ۱۹
۴. تست و مقایسه مدل‌ها ۲۱
تحلیل رفتار و عملکرد سیستم: ۲۲
۱. کیفیت خروجی ۲۲
۲. سرعت اجرا ۲۲
۳. اعتبارسنجی ساختار ۲۲
یک روش جایگزین برای تمرین ۳۰
برچسب گذاری ۳۱
معیار ارزیابی ۳۲
فیلتر کردن نهایی داده‌ها ۵۶
گزارش آماری ۵۷

مقدمه

پردازش زبان طبیعی (Natural Language Processing - NLP) شاخه‌ای از هوش مصنوعی است که به تعامل میان رایانه و زبان انسان می‌پردازد. این حوزه با بهره‌گیری از الگوریتم‌های یادگیری ماشین و مدل‌های زبانی، امکان تحلیل، درک و تولید زبان طبیعی را برای سامانه‌های رایانه‌ای فراهم می‌سازد. کاربردهای گسترده‌ی NLP از جمله در موتورهای جست‌وجو، ترجمه ماشینی، چت‌بات‌ها و تحلیل احساسات، نشان‌دهنده‌ی اهمیت روزافزون این حوزه در فناوری‌های نوین است.

در این تمرین، هدف اصلی طراحی و پیاده‌سازی یک سیستم ساده‌ی پردازش زبان طبیعی بوده است که بتواند متون مرتبط با یک موضوع خاص را تحلیل و دسته‌بندی کند. این فرآیند شامل مراحل مختلفی از جمله گردآوری داده، کراولینگ، پیش‌پردازش، استخراج ویژگی‌ها و آماده سازی داده می‌شود.

ما در این تمرین موضوع «تاریخ» را انتخاب کرده‌ایم؛ زیرا متون تاریخی معمولاً دارای غنای زبانی، تنوع موضوعی و ساختارهای پیچیده‌تری نسبت به سایر متون هستند. این ویژگی‌ها باعث می‌شود که تحلیل زبان‌شناختی آن‌ها چالش‌برانگیز و در عین حال آموزنده باشد.

در این گزارش، به‌صورت گام‌به‌گام به شرح مراحل انجام‌شده پرداخته‌ایم و تلاش کرده‌ایم با رویکردی علمی، پیاده‌سازی یک سامانه‌ی ساده اما مؤثر در حوزه‌ی تاریخ را مستندسازی کنیم.

انتخاب موضوع

با توجه به ماهیت تمرین و الزام به انتخاب یک حوزه‌ی موضوعی خاص برای تحلیل زبانی، موضوع «تاریخ» را به عنوان دامنه‌ی محتوایی این تمرین انتخاب کردیم. متون تاریخی معمولاً از نظر واژگان، ساختارهای نحوی و سبک نگارش دارای تنوع و پیچیدگی بالایی هستند و این ویژگی‌ها، آن‌ها را به منبعی مناسب برای آزمودن توانمندی ابزارهای پردازش زبان طبیعی تبدیل می‌کند. علاوه بر این، علاقه‌ی شخصی به متون تاریخی و اهمیت این حوزه در تولید محتوای فرهنگی و آموزشی، انگیزه‌ی مضاعفی برای انتخاب این موضوع فراهم کرده است.

گردآوری داده‌ها و کراولینگ

در این تمرین، یک کراولینگ وب سفارشی طراحی و پیاده‌سازی شد که قادر است اطلاعات صفحات ویکی‌پدیای فارسی و انگلیسی را استخراج و هم‌تراز نماید. این کراولینگ با استفاده از ابزارهای Selenium و BeautifulSoup، ساختار صفحات ویکی‌پدیا را به‌طور مؤثری پیمایش کرده و داده‌های ساخت‌یافته موجود در جعبه‌اطلاعات (Infobox)، تصاویر مرتبط و محتوای متنی پاک‌سازی‌شده را استخراج می‌کند. داده‌های حاصل در قالب‌های ساخت‌یافته مانند فایل‌های CSV ذخیره می‌شوند تا در مراحل بعدی پردازش، به‌ویژه برای آموزش یا تنظیم دقیق مدل‌های زبانی بزرگ (LLM)، قابل استفاده باشند.

این سامانه همچنین قابلیت هم‌ترازی میان‌زبانی را با تطبیق صفحات فارسی و انگلیسی بر اساس پیوندهای زبانی موجود در ویکی‌پدیا فراهم می‌کند. این ویژگی برای کاربردهایی مانند ترجمهٔ ماشینی، بازیابی اطلاعات میان‌زبانی و توسعهٔ مدل‌های زبانی چندزبانه بسیار حیاتی است. ارزیابی‌های انجام‌شده نشان داد که سیستم در استخراج انواع مختلف محتوا، عملکردی دقیق و پایدار دارد و وفاداری بالایی نسبت به منابع اصلی حفظ کرده است.

در این تمرین، به‌منظور استخراج داده‌های ساخت‌یافته و متنی تمیز از صفحات ویکی‌پدیا به زبان‌های فارسی و انگلیسی، سه اسکریپت پایتون با عناوین scrap.py، scraping_en.py و

scraping_fa.py طراحی و پیاده‌سازی شده‌اند. هدف کلی این اسکریپت‌ها آماده‌سازی داده‌هایی با کیفیت برای استفاده در مدل‌های زبانی بزرگ (LLM) است. فرآیند استخراج شامل موارد زیر است:

- استخراج و پاک‌سازی محتوای اصلی مقاله.
- استخراج داده‌های ساخت‌یافته از اینفوباکس‌ها.
- دانلود تصاویر همراه با فراداده.
- ذخیره‌سازی داده‌ها به‌صورت ساخت‌یافته در فایل‌های CSV.

کد scrap.py: این اسکریپت یک ماژول کمکی برای پاک‌سازی محتوای HTML و استخراج متن تمیز از صفحات وب است. وظایف اصلی این کد شامل موارد زیر است:

- حذف عناصر غیر ضروری: تگ‌هایی مانند <style>، <sup> و <script> که عموماً شامل منابع، استایل‌دهی یا کدهای اسکریپتی هستند و برای مدل‌های زبانی مفید نیستند، حذف می‌شوند.
- حذف لینک‌ها و حفظ متن آن‌ها: تگ‌های <a> حذف می‌شوند اما متن نمایشی لینک‌ها حفظ می‌گردد.
- پاک‌سازی نهایی متن: با حذف تگ‌ها و کاراکترهای اضافی، متن نهایی به‌صورت یک خروجی تمیز، قابل‌استفاده در مدل‌های NLP آماده می‌شود.

کد scrap.py به‌عنوان تابع پشتیبان در دو اسکریپت بعدی مورد استفاده قرار می‌گیرد تا فرآیند پاک‌سازی متن در هر دو زبان فارسی و انگلیسی یکسان باشد.

کد scraping_en.py: این اسکریپت وظیفه جمع‌آوری و استخراج اطلاعات از صفحات ویکی‌پدیای انگلیسی را برعهده دارد. مراحل عملکرد آن به‌صورت زیر است:

- دسترسی به صفحات: با استفاده از Selenium (در حالت headless)، صفحات مشخص‌شده در فهرست URLها باز می‌شوند.
- استخراج محتوا: عنوان صفحه، محتوای اصلی مقاله (داخل تگ) و اینفوباکس (در صورت وجود در <table class="infobox">)

استخراج می‌شوند. حداکثر سه تصویر از هر مقاله انتخاب و دریافت می‌شود (اولویت با تصاویر اینفوباکس است).

- پردازش داده‌ها: محتوا با کمک توابع scrap.py پاک‌سازی می‌شود. داده‌های اینفوباکس به‌صورت جفت کلید-مقدار استخراج می‌گردند.
- مدیریت تصاویر: تصاویر دانلود و در یک پوشه مشخص ذخیره می‌شوند. نام فایل و لینک منبع آن‌ها در فایل نهایی ثبت می‌گردد.
- ذخیره‌سازی: عنوان، محتوای پاک‌سازی‌شده، اطلاعات اینفوباکس، اطلاعات تصاویر و آدرس URL اصلی در فایل CSV ذخیره می‌شوند.

کد scraping_fa.py: این اسکریپت مشابه scraping_en.py عمل می‌کند اما برای استخراج از صفحات ویکی‌پدیای فارسی طراحی شده است. تفاوت‌های اصلی آن به شرح زیر است:

- ورودی صفحات: از فایل CSV با نام links.csv شامل لینک‌های ویکی‌پدیای فارسی استفاده می‌کند.
- استخراج محتوا: ساختارهای HTML مشابه نسخه انگلیسی هستند اما محتوای آن‌ها به زبان فارسی و دارای راست‌به‌چپ بودن است. برای حفظ درستی نویسه‌ها، پشتیبانی کامل از یونیکد درنظر گرفته شده است.
- ذخیره‌سازی نهایی: داده‌ها شامل عنوان، متن مقاله، اینفوباکس به‌صورت JSON، اطلاعات تصاویر و URL صفحه در فایل CSV به‌نام fa_wikipedia_dataset.csv ذخیره می‌شوند. تصاویر دانلود و به‌صورت محلی ذخیره می‌شوند و ارجاع آن‌ها در فایل CSV ثبت می‌شود.

اسکریپت حذف داده‌های تکراری duplicat_csv_removal.py

این اسکریپت وظیفه پاک‌سازی داده‌های حاصل از خزیدن صفحات ویکی‌پدیا را برعهده دارد. داده‌ها که ابتدا به صورت فایل‌های CSV در مسیر crawl/ ذخیره شده‌اند، ممکن است شامل ردیف‌های تکراری باشند که عمدتاً از آدرس‌های تکراری (link) ناشی می‌شود. برای بهینه‌سازی مجموعه‌داده و حذف داده‌های زائد، این اسکریپت مراحل زیر را اجرا می‌کند:

- خواندن فایل **CSV** اولیه با استفاده از pandas.read_csv
- حذف ردیف‌های تکراری بر اساس ستون link با استفاده از drop_duplicates
- ذخیره‌سازی خروجی پاک‌سازی‌شده در فایل جدیدی با پسوند _cleaned.csv

این فرآیند بر روی دو فایل ir_treaty_link.csv و wars_links.csv به صورت مستقل انجام می‌شود و گامی مهم در آماده‌سازی داده برای استفاده در مدل‌های زبانی بزرگ محسوب می‌شود، چرا که داده‌های تکراری می‌توانند منجر به سوگیری و یادگیری غیرموثر مدل شوند.

ساختار بخش Scrapy

برای اجرای خزیدن صفحات ویکی‌پدیا، از فریم‌ورک **Scrapy** استفاده شده است که یک چارچوب قدرتمند و ماژولار برای خزیدن وب و استخراج داده محسوب می‌شود. بخش‌های مختلف این چارچوب در قالب فایل‌های استاندارد پیکربندی و توسعه یافته‌اند:

items.py: این فایل برای تعریف ساختار داده‌هایی استفاده می‌شود که توسط خزنده جمع‌آوری می‌شوند. در نسخهٔ فعلی، این کلاس به صورت خالی (pass) تعریف شده، اما قابل گسترش برای فیلدهایی نظیر title, link, infobox, text, و images است. ساختاردهی داده‌ها در این مرحله برای بهره‌برداری مؤثر از pipeline اهمیت دارد.

middlewares.py: در این فایل، دو middleware تعریف شده‌اند:

- CrawlSpiderMiddleware: برای کنترل فرآیند پردازش پاسخ‌های دریافتی از وب‌سایت توسط Spider.
- CrawlDownloaderMiddleware: برای مدیریت درخواست‌ها و پاسخ‌ها در لایه‌ی دانلودر.

این کلاس‌ها بیشتر به صورت الگوهای آماده‌ی Scrapy نوشته شده‌اند و قابلیت سفارشی‌سازی کامل را دارا هستند. متدهای آن‌ها از قبیل process_spider_input, process_spider_output, و process_request نقاط مناسبی برای افزودن لاگ، بررسی خطا، یا فیلترکردن محتوا هستند.

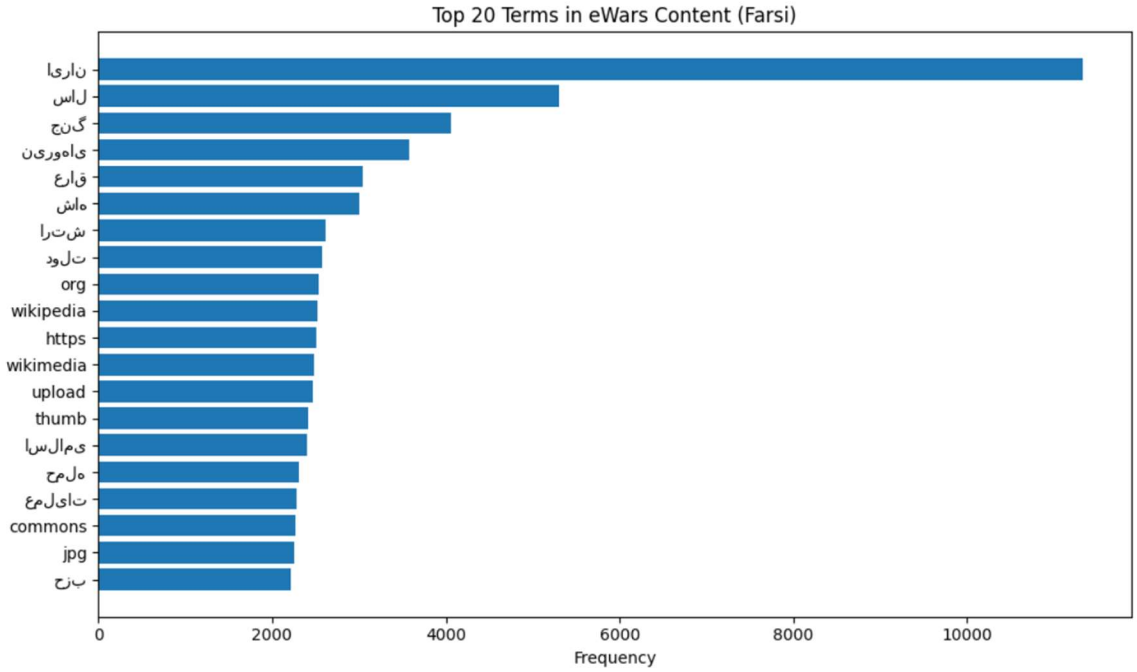
pipelines.py: این فایل مسئول پردازش نهایی داده‌هایی است که توسط spider استخراج شده‌اند. کلاس CrawlPipeline به‌صورت پایه تعریف شده و صرفاً داده‌ها را بازمی‌گرداند، اما در نسخه‌های توسعه‌یافته‌تر می‌توان از آن برای ذخیره‌سازی در پایگاه داده، پاک‌سازی، یا اعتبارسنجی داده استفاده کرد.

settings.py: فایل پیکربندی Scrapy شامل تنظیمات عمومی تمرین است. برخی تنظیمات کلیدی موجود در این فایل عبارتند از:

- BOT_NAME, SPIDER_MODULES, NEWSPIDER_MODULE: مشخص‌کننده ساختار تمرین و مسیر فایل‌های Spider.
- ROBOTSTXT_OBEY = True: احترام به فایل robots.txt سایت‌ها.
- ITEM_PIPELINES, SPIDER_MIDDLEWARES, DOWNLOADER_MIDDLEWARES: قابل فعال‌سازی برای اتصال اجزای تعریف‌شده.
- TWISTED_REACTOR, FEED_EXPORT_ENCODING: تنظیمات مرتبط با همگام‌سازی و خروجی UTF-۸ برای پشتیبانی از زبان فارسی.

این ساختار پیکربندی، اجرای دقیق، مؤثر و مقیاس‌پذیر عملیات خزیدن را فراهم می‌آورد.

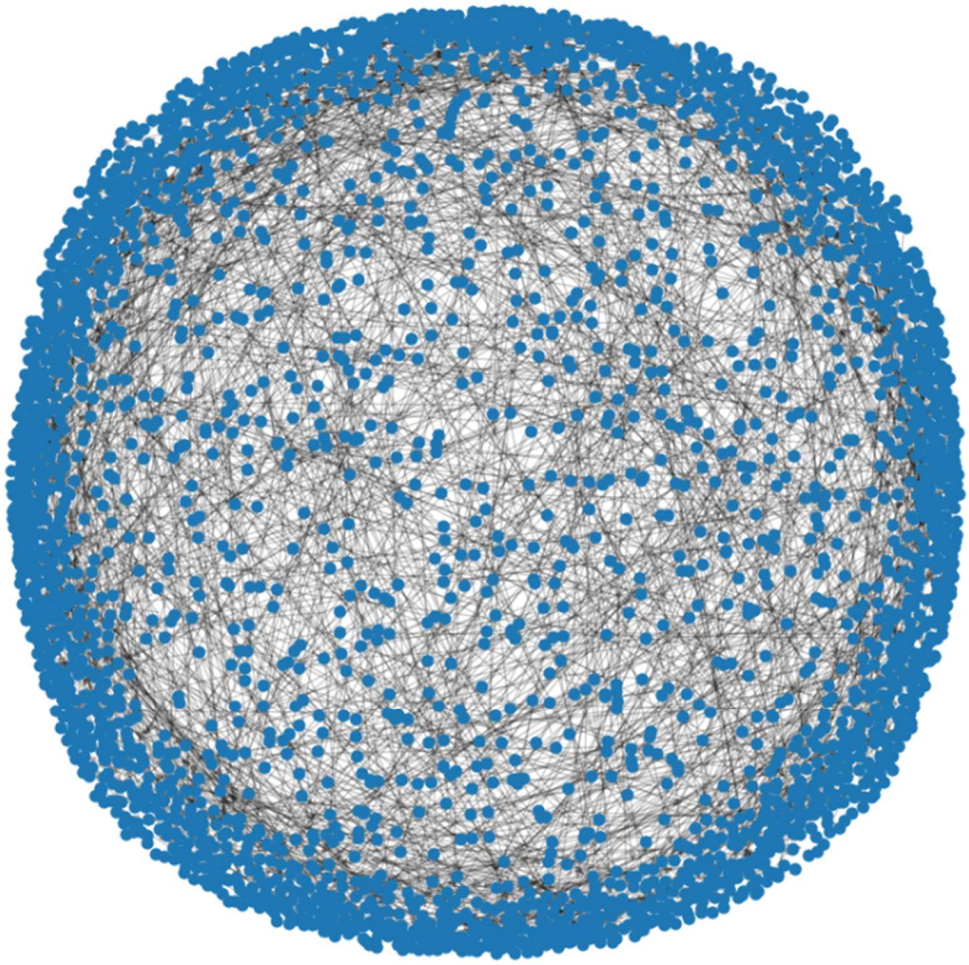
مجموعه کدهای ارائه‌شده، یک چارچوب کامل برای خزیدن، پاک‌سازی و ساخت مجموعه‌داده ساخت‌یافته از ویکی‌پدیای فارسی و انگلیسی را فراهم می‌کند. استفاده از Scrapy برای طراحی خزنده، به همراه اسکریپت‌های پیش‌پردازشی پایتون برای حذف داده‌های تکراری، نشان‌دهنده یک فرآیند استاندارد، قابل اعتماد و قابل گسترش در استخراج داده از منابع وب است.



1 to 10 of 102 entries Filter

name	link	content
1973 Sale and Purchase Agreement	https://en.wikipedia.org/wiki/1973_Sale_and_Purchase_Agreement	No infobox found.The 1973 Sale and Purchase Agreement was a 20-year agreement pressured by the Shah of consortium that nullified The Consortium Agreement of 1954 and provided the National Iranian Oil Company wit of Iranian petroleum nationalizing the nation's oil reserves. [1] [2] By 1975, western oil companies complainec and demanded renegotiation marking the first time in history that oil companies rather than the oil producing nat negotiate an oil contract. [3] The Shah had ambitions for a " Great Civilization " in which Iran would one day be oil producer in the world. He used Iran's development to establish himself as a strongman across the Middle Ea Gulf and create an oil oligarchy controlling the price of oil. In the 1960s, the Shah initiated the formation and org oil-exporting countries which would become known as the Organization of the Petroleum Exporting Countries (O also sought to terminate the 1954 Consortium Agreement an effort which was finalized with the 1973 Sale and P Agreement. [2] In response to the creation of OPEC, Maurice Bridgman of British Petroleum warned the Natior Company about "unhappy events that would harm Iran's interests and the oil industry and damage the mutual c surely ought to prevail." [4] According to Dr. Parviz Mina, an expert on Iranian Oil Affairs and previous director Iranian Oil Company, "In the early 1970s, Iran and the Shah himself officially gave an ultimatum to the Consortiu they refused to overhaul the terms of the 1954 Agreement and sign a new one instead, the Consortium Agreem terminated at the end of the initial twenty-five-year period, i.e. by 1979, and the period would not be extended. F warning, representatives of the Consortium member companies, fully aware of the stance of the National Iranian the terms and conditions to be revised, visited the Shah several times in the winter of 1972 in St. Maurice, and i presented the Shah with a treaty containing the terms and conditions, which is known as the St. Maurice Docum Shah's return to Iran, negotiations between the National Oil Company and representatives of the consortium to contract began in early 1973. At that time, I was given the chairmanship of the delegation of the National Oil Co negotiations with the Consortium. Dr. Reza Fallah also participated in these negotiations as an observer. These lasted for several months, and a new contract called the Sales and Purchase Agreement, was signed on June 3 became law after it received the approval of the two legislative bodies (the Parliament and the Senate of Iran) o 2] In the summer of 1973, Iran exploited the supply shortage to double crude oil prices further reducing the pow consortium. Political balance shifted from oil companies to oil producing nations. [3] This article related to a tre can help Wikipedia by expanding it .v, t, eStub icon: https://upload.wikimedia.org/wikipedia/commons/thumb/9/90/Siegelpr%C3%A4gungen_1643_BBB_4%2C3x4.j Siegelpr%C3%A4gungen_1643_BBB_4%2C3x4.jpg"unhappy events that would harm Iran's interests and the o damage the mutual confidence that surely ought to prevail." [4] "In the early 1970s, Iran and the Shah himself ultimatum to the Consortium, saying that if they refused to overhaul the terms of the 1954 Agreement and sign a the Consortium Agreement would be terminated at the end of the initial twenty-five-year period, i.e. by 1979, an not be extended. Following this warning, representatives of the Consortium member companies, fully aware of t National Iranian Oil Company on the terms and conditions to be revised, visited the Shah several times in the w Maurice, and in the last meeting, presented the Shah with a treaty containing the terms and conditions, which is Maurice Document. After the Shah's return to Iran, negotiations between the National Oil Company and represe consortium to prepare a new contract began in early 1973. At that time, I was given the chairmanship of the dele National Oil Company in the negotiations with the Consortium. Dr. Reza Fallah also participated in these negoti observer. These negotiations lasted for several months, and a new contract called the Sales and Purchase Agre signed on June 31, 1973, and became law after it received the approval of the two legislative bodies (the Parliar Senate of Iran) on July 31, 1973." [2]

Link Network of Persian Wikipedia Wars Pages



پیش‌پردازش داده‌ها

در این مرحله از تمرین، هدف اصلی ما پیش‌پردازش داده‌های متنی استخراج‌شده از صفحات ویکی‌پدیای فارسی و انگلیسی است که قبلاً توسط سه اسکریپت scrap.py، scraping_fa.py و scraping_en.py استخراج شده‌اند. این مرحله نقشی کلیدی در آماده‌سازی داده‌ها برای پردازش‌های بعدی از جمله آموزش مدل‌های یادگیری ماشین یا مدل‌های زبانی ایفا می‌کند. کیفیت این مرحله تاثیر مستقیمی بر دقت و کارایی تحلیل نهایی دارد.

داده‌های خام استخراج‌شده از ویکی‌پدیا در قالب فایل‌های CSV شامل ستونی با نام content بودند که محتوای متنی صفحه را شامل می‌شدند. در این مرحله فایل‌های زیر پردازش شدند:

- داده‌های فارسی: ewars_links_cleaned_fa_output_V2.csv
- داده‌های انگلیسی: ir_treaty_cleaned_en_output_v2.csv

هدف کلی پیش‌پردازش:

- حذف نویزهای رایج در مقالات ویکی‌پدیا (نظیر الگوهای قالب، تگ‌ها، آدرس‌ها، ارجاعات و پیام‌های سیستمی مانند "این مقاله ناقص است").
- نرمال‌سازی متون و یکنواخت‌سازی قالب نوشتاری.
- توکن‌سازی و استخراج توکن‌های معنادار.
- حذف یا حفظ ایست‌واژه‌ها (در صورت لزوم).
- انجام لماتایزیشن یا استمینگ برای کاهش کلمات به ریشه مفهومی‌شان (در صورت لزوم).
- آماده‌سازی خروجی پاک‌سازی‌شده برای مراحل بعدی.

پیش‌پردازش داده‌های فارسی:

برای پردازش متن فارسی از کتابخانه قدرتمند **Hazm** استفاده شد. این کتابخانه شامل امکاناتی نظیر نرمال‌ساز، توکن‌ساز، لیست ایست‌واژه‌ها و لماتایزر است.

۱. حذف نویزها:
   - حذف الگوهای خاص ویکی‌پدیا مانند No infobox found. و v, t, e.
   - حذف جمله‌های سیستمی مانند: "این مقاله ناقص است. می‌توانید با گسترش آن به ویکی‌پدیا کمک کنید."
   - حذف آدرس‌های اینترنتی و ارجاع‌های درون‌متنی.
۲. نرمال‌سازی:
   - استفاده از Normalizer برای یکپارچه‌سازی حروف، حذف نویسه‌های زائد و اصلاح ساختار نگارشی.
۳. توکن‌سازی:
   - تقسیم متن به کلمات (توکن‌ها) با استفاده از word_tokenize در Hazm.
٤. پردازش توکن‌ها:
   - در این نسخه، به‌صورت هدفمند از حذف ایست‌واژه‌ها و لماتایز کردن صرف‌نظر شد تا معنای جملات حفظ شود.
   - همزمان توکن‌های انگلیسی موجود در متون فارسی (مانند نام‌ها یا عبارات علمی) نیز حفظ شدند.
٥. ذخیره خروجی:
   - داده‌های پیش‌پردازش‌شده در فایل preprocessed_persian_data.csv ذخیره شده و به‌صورت فشرده با نام preprocessed_persian_data.zip خروجی گرفته شد.

پیش‌پردازش داده‌های انگلیسی:

برای متن‌های انگلیسی از کتابخانه‌های NLP استاندارد پایتون نظیر **nltk** استفاده شد.

۱. حذف نویزهای ویکی‌پدیایی:
   - حذف تگ‌ها و الگوهای زاید مانند "v, t, e"، "No infobox found"، و جملات مربوط به ناقص بودن مقاله.
   - حذف URLها و ارجاع‌های عددی.
۲. تنظیم قالب متن:

- حذف فاصله‌های اضافی و سفید.
- در نسخه فعلی، حروف کوچک‌سازی نشده‌اند و نشانه‌گذاری نیز باقی مانده است (به‌صورت قابل تغییر در تنظیمات کد).

۳. توکن‌سازی:
   - استفاده از word_tokenize برای تقسیم متن به توکن‌ها.

٤. حذف یا حفظ ایست‌واژه‌ها و ریشه‌سازی:
   - در نسخه نهایی این مرحله، حذف ایست‌واژه‌ها و انجام استمینگ غیرفعال شده است تا متن خام بدون دست‌کاری معنایی باقی بماند، هرچند این مراحل در کد برای فعال‌سازی آماده‌اند.

٥. ذخیره خروجی:
   - فایل نهایی در قالب eng_preprocessed_output.csv ذخیره و سپس در فایل فشرده eng_preprocessed_output.zip نگهداری شد.

پیش‌پردازش انجام‌شده باعث پاک‌سازی قابل‌توجه نویزها و قالب‌های غیرمفید متنی شد که در مقالات ویکی‌پدیا فراوان دیده می‌شوند. با توجه به اینکه هدف اصلی این تمرین آماده‌سازی داده‌ها برای استفاده در مدل‌های زبانی است، حفظ ساختار معنایی جملات در اولویت قرار گرفت، به همین دلیل حذف ایست‌واژه‌ها و لماتایزیشن/استمینگ به صورت اختیاری و قابل تنظیم باقی ماند. استفاده از ابزارهای تخصصی مانند Hazm برای زبان فارسی، و NLTK برای زبان انگلیسی، دقت و کیفیت عملیات را تضمین کرده است. خروجی نهایی اکنون شامل داده‌هایی تمیز، یکپارچه و آماده برای پردازش‌های بعدی مانند بردارسازی، آموزش مدل‌های طبقه‌بندی یا یادگیری زبان است.

<<یک نمونه پیش پردازش شده>>

تاریخ : ۱۰ دسامبر ۱۷۳۲ – ۱۹ دسامبر ۱۷۳۳ موقعیت : میان‌رودان نتایج : بدون پیروز قطعی تغییراتقلمرو : تغییری در قلمروها ایجاد نشد اردوکشی نادرشاه به میان‌رودان در ۱۷۳۲ – ۱۷۳۳ میلادی یک عملیات نظامی به رهبری نادر در آخرین سال‌های حکومت صفوی بود . پس از اردوکشی ناموفق شاه تهماسپ دوم به غرب ایران و شکست در برابر عثمانیان ، نادر وی را از پادشاهی ایران خلع کرد و پسر خردسالش ، عباس سوم را بر تخت نشاند . با شکست شاه

تهامسپ در نبرد با عثمانی ، نفوذ قسطنطنیه در قفقاز افزایش‌یافته بود و نادر حالا برای تضعیف آنان ، تصمیم به لشکرکشی به عراق گرفت و بدین گونه جنگ میان ایران و عثمانی در منطقه بین‌النهرین از سر گرفته_شد . نادر با وجود پیروزی‌هایی که در نبردهای خود در جریان این اردوکشی داشت ، به خصوص در نبرد آق‌دربند که ارتش عثمانی را به کل از بین برد ، اما نتوانست به یک پیروزی نهایی در جنگ دست پیدا کند . گرچه ورود به بغداد ناتمام ماند ، اما تلاش‌های ایران برای فتح شهر در سال‌های بعد و تا پایان دوران نادر ادامه پیدا کرد . اردوکشی نادر به قفقاز که دو سال پس از این اتفاق روی داد ، در نهایت با پیروزی نهایی ایران در این جنگ و بیرون راندن عثمانیان از تمامی سرزمین‌های ایران صفوی انجامید . با این حال نادر به دلیل قیام فزاینده‌ای در جنوب فارس که نیاز به توجه فوری وی داشت ، نتوانست فتح چشمگیر خود را دنبال کند ؛ بنابراین ، بغداد باز هم از افتادن به دست فارسی نجات یافت . این مبارزات انتخاباتی در مورد سرنوشت جنگ تصمیم نگرفت ، اما صحنه‌ای برای مبارزات نادر برای قفقاز در سال ۱۷۳۵ تعیین کرد که در آن با شکست تکان‌دهنده عثمانی‌ها در باغاوارد ، استانبول به زانو درآمد . او ابتدا در ژانویه ۱۷۳۳ م بغداد را محاصره کرد . نادر تصمیم داشت تا با محاصره بغداد ، عثمانی‌ها را از شهر بیرون کشد یا سختی محاصره ، آنان را به تسلیم وادارد . احمدپاشا کوشید تا مانع عبور نیروهای ایرانی از دجله شود و محاصره نادر تکمیل نشود ؛ بنابراین توپخانه را در ساحل غربی دجله تقویت کرد . نادر تصمیم گرفت از این مانع عبور کند و برای آن با استفاده از تنه‌های نخل و مشک‌های پرشده از باد ، پلی درست کرد . در ۲ رمضان ۱۱۴۵ ه . ق / ۱۵ فوریه ۱۷۳۳ م ، نادر با ۲۵۰۰ پیشقراول از پل گذشت و به سوی جنوب حرکت کرد . پل چندان استقامت نداشت و پس از گذشت ۱۵۰۰ تن دیگر از پیشقراولان ، از هم پاشید . احمدپاشا با شنیدن خبر از بین رفتن پل ، نیرویی قوی شامل سواره و توپخانه و پیاده ینی‌چری به مقابله نادر فرستاد . نادر به نیروهای عثمانی حمله کرد و با رسیدن ۱۵۰۰ تن دیگری که پس از او از پل گذشته_بودند ، بر شدت حملات افزود . نیروهای عثمانی توپخانه را رها و عقب‌نشینی کردند . اکنون محاصره بغداد تنگ‌تر ، و ۲۷۰۰ برج در اطراف بغداد برپا شد . نیروهای نادر شامل ۸۰ , ۰۰۰ سوار و ۲۰ , ۰۰۰ پیاده بودند اما توپ سنگین کافی نداشتند تا دیوار بغداد را بکوبند . ازاین‌رو نادر تصمیم گرفت تا با ادامه محاصره ، ساکنان بغداد از گرسنگی تسلیم شوند . سپاهیان نادر شهرهای سامرا ، نجف ، کربلا ، حله و دیگر شهرهای اطراف را تصرف کردند و تعدادی نیز به بصره رفتند تا به قبایل شورشی عرب در برابر عثمانی‌ها یاری رسانند . نوروز در شمال بغداد گذشت و هم‌زمان قحطی در بغداد بروز کرد . احمد پاشا

به‌مدت کوتاهی تحت محاصره قرار گرفت . او در پایان ماه محرم ۱۱۴۶ ه . ق / ۱۳ ژوئیه ۱۷۳۳ م ، برای مذاکره اقدام کرد و قرار گذاشت درصورت نرسیدن نیروهای عثمانی تا چهار هفته بعد ، بغداد را تسلیم کند . اما چند روز پس از آن خبر نزدیک شدن توپال عثمان پاشا با ۸۰ , ۰۰۰ سرباز و ۶۰ قبضه توپ رسید . نادر پیکی با پیامی تند نزد او فرستاد اما او پیک را زندانی کرد و پاسخ نادر را هم نداد . احمدپاشا قبل از اینکه نیروهای عثمانی تحت فرماندهی توپال عثمان پاشا به شهر نزدیک شوند ، پیروز شد . نادر ۱۲۰۰۰ سرباز را به فرماندهی محمدخان بلوچ بر محاصره بغداد باقی گذاشت و با دیگر نیروهای خویش به مقابله با توپال عثمان رفت . در ۷ صفر ۱۱۴۶ ه . ق / ۱۹ ژوئیه ۱۷۳۳ م ، نبرد آغاز شد و سرانجام پس از ساعت‌ها جنگیدن ، سپاهیان نادر شکست خوردند و عقب نشستند . نادر در این نبرد ۳۰ , ۰۰۰ تن از نیروهایش را از دست داد . عثمانی‌ها نیز ۲۰ , ۰۰۰ نیرو از دست دادند . پس از رسیدن خبر شکست نیروهای نادر به احمدپاشا ، وی به نیروهای ایرانی محاصره‌کننده بغداد حمله برد . تعدادی همراه با محمدخان بلوچ گریختند اما بیشترشان کشته یا اسیر شدند . نادر در رجب ۱۱۴۶ ه . ق / دسامبر ۱۷۳۳ م با احمد پاشا پیمان جدیدی را امضا کرد . پس از شکست در محاصره بغداد ، نادر از بهرز به‌سوی ایران حرکت کرد . او دستور بازسازی سپاه را داد . میانه تابستان ۱۱۴۶ ه . ق / ۱۷۳۳ م ، وارد همدان شد و در اواخر همان تابستان ، سپاه بار دیگر بازسازی شد . از سوی دیگر ، توپال عثمان هیچ‌یک از نیروهای کمکی و تدارکاتی را که از استانبول درخواست شده‌بود ، دریافت نکرد . در ۲۲ ربیع‌الثانی ۱۱۴۶ ه . ق / ۲ اکتبر ۱۷۳۳ م نادر بار دیگر به‌سوی کرکوک حرکت کرد . هم‌زمان با گذشتن از مرزهای عثمانی ، خبر شورش محمدخان بلوچ بدو رسید که با طایفه عرب شیخ احمد مدنی علیه نادر متحد شده_بود . با این اتحاد ، بخش اعظم سواحل خلیج‌فارس از شمال آن تا جزیره کیش به آشوب کشیده_شد . بااین‌حال نادر به پیشروی‌اش در خاک عثمانی ادامه داد . ۱۵ جمادی‌الاول ۱۱۴۶ ه . ق / ۲۴ اکتبر ۱۷۳۳ م ، دو سپاه ایران و عثمانی در لیلان در جنوب کرکوک درگیری کوچکی داشتند . این درگیری نتیجه‌ای نداشت و عثمانی‌ها به کرکوک عقب‌نشینی کردند . نادر برای بیرون کشیدن توپال عثمان از کرکوک ، قلعه سورداش در شمال شرق کرکوک را تصرف کرد . او سپاه عثمانی را به گذرگاه آق‌دربند ، در شمال کرکوک کشاند . پس از آن ۱۲۰۰۰ نیروی عثمانی از دره آق‌دربند گذشتند و به‌سوی سپاه ایران حرکت کردند . نادر با مستحکم کردن موضع خود ، سربازانش را برای حمله آماده کرد . کمی بعد توپال عثمان وارد شد و نیروهای عثمانی نزدیک به ۱۰۰ , ۰۰۰ نفر رسید . پس از چند ساعت نبرد سنگین ، توپال عثمان کشته_شد و سربازان عثمانی فرار کردند . در این نبرد

تلفات عثمانی‌ها به حدود ۲۰ , ۰۰۰ کشته و اسیر رسید . پس از پایان نبرد ، نادر مجددا شهرک‌های اطراف بغداد را اشغال کرد و سپس برای راندن عثمانی‌ها از تبریز ، به‌سوی شمال حرکت کرد ؛ اما پیش از رسیدن به تبریز ، عثمانی‌ها عقب نشستند . احمدپاشا از بغداد پیامی برای مذاکره فرستاد . ۱۲ رجب ۱۱۴۶ ه . ق / ۱۹ دسامبر ۱۷۳۳ م ، میان نادر و احمدپاشا عهدنامه‌ای بسته_شد مبنی بر خروج عثمانی‌ها از همه سرزمین‌های اشغالی پیش از سال ۱۷۲۲ م و مبادله اسیران و توپ‌های تصاحب‌شده هر دو طرف و نیز رفتار شایسته با زائران ایرانی اماکن مذهبی عراق . از سوی احمدپاشا دستور تخلیه شهرهای گنجه ، تفلیس ، ایروان و شیروان به حاکمان‌شان داده_شد ، اما دربار عثمانی در استانبول آن را ملغی ، و فرمانده کل نیروهای تازه به‌نام عبدالله کوپرولو را همراه با نیروهای کمکی به دیار بکر اعزام کرد . نادر پیش از ترک عراق ، در نجف و کربلا به زیارت رفت و سپس سریعا سوی جنوب شرق ایران حرکت کرد . آکس‌وورتی ، مایکل (۱۳۸۸) . شمشیر ایران : نادرشاه . ترجمه محمدحسین آریا . تهران : اساطیر . شابک ۹۷۸ - ۹۶۴ - ۳۳۱ - ۴۴۰ - ۸.

Avery, Peter (۱۹۹۱) . « Nadir Shah and the Afsharid Legacy » . InPeter Avery;Gavin . (به انگلیسی) Hambly;Charles Melville (eds .) . The Cambridge History of Iran Vol . ۷. Cambridge : Cambridge University Press . , Tucker, Ernest (۲۰۰۶ b) . « Online ed .) . Retrieved ۳ May) (به انگلیسی) Nāder Shah » . Encyclopædia Iranica ۲۰۲۱. Moghtader, Gholam-Hussein (۲۰۰۸) . The Great Batlles of Nader Shah, Donyaye Ketab, Axworthy, Michael (۲۰۰۹) . The Sword of Persia : Nader Shah, from tribal warrior to conquering tyrant, I . B . Tauris, Ghafouri, Ali (۲۰۰۸) . History of Iran's wars : from the Medes to now, Etela'at Publishing : امپراتوری عثمانی

استخراج اطلاعات

در ادامه‌ی فرآیند آماده‌سازی داده‌های متنی ویکی‌پدیای فارسی و انگلیسی، پس از مرحله‌ی پاک‌سازی و پیش‌پردازش محتوای متنی، گام کلیدی بعدی، استخراج اطلاعات ساختاریافته از داده‌های غیرساختاری (متنی) است. این کار برای بهره‌برداری مؤثرتر از داده‌ها در کاربردهایی چون پاسخ‌گویی به پرسش، بازیابی اطلاعات، استخراج دانش و ساخت پایگاه‌های دانش ضروری است. در این مرحله، از مدل‌های زبانی بزرگ (LLM) برای استخراج اطلاعات معنایی و تبدیل آن‌ها به فرمت JSON ساختاریافته استفاده شده است.

هدف اصلی در این مرحله، تبدیل محتوای متنی نیمه‌ساخت‌یافته یا غیرساختاریافته به اطلاعات ساختاریافته در قالب JSON است. این فرمت نه‌تنها برای انسان قابل فهم است بلکه برای ماشین نیز به‌راحتی قابل تحلیل، جستجو و پردازش می‌باشد.

برای رسیدن به این هدف، از مدل‌های زبانی بزرگ (LLMs) بهره گرفتیم تا با درک عمیق از متن، اطلاعات کلیدی را شناسایی کرده، تفسیر و در قالب مناسب استخراج کنند. رویکرد انجام‌شده شامل مراحل زیر است:

۱. ارائه‌ی قالب JSON هدف به مدل: در ابتدا، ساختار مورد انتظار اطلاعاتی به مدل معرفی شد. این ساختار شامل فیلدهایی مشخص مانند ،title ،location ،organization people_involved ،topic ،date و غیره بود.
۲. تغذیه مدل با محتوای متنی: هر متن کامل (که پیش‌تر پاک‌سازی شده بود) به مدل داده شد.
۳. درخواست از مدل برای پر کردن فیلدهای JSON: مدل به‌صورت مستقیم خروجی خود را در قالب JSON تولید کرد، به‌نحوی که در هر پاسخ، اطلاعات مربوطه به صورت ساختاریافته بازگردانده شدند.
٤. ذخیره‌سازی خروجی: خروجی‌های مدل در قالب فایل‌های .json ذخیره شدند تا برای مراحل بعدی مانند تحلیل، تجمیع، پایگاه‌سازی یا مصورسازی قابل استفاده باشند.

استفاده از LLM برای استخراج اطلاعات ساختاریافته دارای مزایای بسیار زیادی نسبت به روش‌های سنتی مبتنی بر قوانین (rule-based) یا حتی یادگیری ماشین کلاسیک است:

مزیت	شرح
درک عمیق از زبان	مدل‌های زبانی بزرگ قادر به درک معنی، مفهوم، و روابط معنایی پیچیده بین کلمات هستند. این مزیت در استخراج اطلاعات از متون آزاد (مانند ویکی‌پدیا) بسیار کلیدی است.
سازگاری با تغییرات زبانی	نیازی به نوشتن قوانین ثابت و شکننده برای هر نوع متن یا عبارت نیست. مدل به‌طور تطبیقی با متون جدید سازگار می‌شود.
خروجی‌های دقیق‌تر و غنی‌تر	برخلاف الگوهای regex یا pipelineهای مبتنی بر NER ساده، مدل LLM می‌تواند داده‌هایی را استخراج کند که به‌صورت صریح در متن نیامده‌اند ولی به‌طور ضمنی قابل برداشت‌اند.
ساختار خروجی مستقیم در قالب **JSON**	مدل توانایی دارد که مستقیماً خروجی‌های ساخت‌یافته (structured) در قالب مورد نظر تولید کند، بدون نیاز به مرحله‌ی واسط برای قالب‌بندی.
انعطاف‌پذیری بالا در فیلدها و قالب‌ها	می‌توان به‌راحتی با دادن promptهای جدید یا قالب JSON جدید، نوع خروجی را تغییر داد بدون نیاز به بازنویسی کدهای پیچیده.

با استفاده از چارچوب Ollama که امکان اجرای مدل‌های زبانی متن‌باز و سبک را به صورت محلی فراهم می‌کند، فرایندی پیاده‌سازی شده که متون تاریخی فارسی را تحلیل کرده و بر اساس قالبی

از پیش تعیین‌شده به فرمت JSON تبدیل می‌کند. این اطلاعات سپس می‌توانند برای یادگیری ماشین، تحلیل‌های آماری یا استفاده در پایگاه‌های دانش مورد استفاده قرار گیرند.

- طراحی یک سیستم تمام‌خودکار برای استخراج اطلاعات ساخت‌یافته از متون فارسی تاریخی.
- استفاده از مدل‌های زبانی کوچک به‌منظور کاهش منابع سخت‌افزاری مورد نیاز و افزایش سرعت پاسخ‌گویی.
- حفظ دقت معنایی و صحت محتوایی خروجی‌ها در حوزه حساس تاریخ‌نگاری.
- تولید خروجی در قالب JSON با کلیدهای انگلیسی و مقادیر فارسی برای یکپارچگی با سیستم‌های داده‌محور.

۱. چارچوب پردازشی

پلتفرم Ollama به‌عنوان موتور اجرایی مدل‌ها انتخاب شد. این چارچوب با فراهم‌سازی محیطی محلی و امن، امکان اجرای مدل‌های متن‌باز (open-source) مانند LLaMA3، Phi4، Qwen، Gemma و DeepSeek را فراهم می‌آورد، بدون نیاز به اتصال به سرورهای خارجی یا APIهای مبتنی بر فضای ابری. همچنین از محیط توسعه Google Colab و پردازنده‌های T۴ جهت پردازش‌های این تمرین استفاده شده است.

۲. قالب هدف

قالبی دقیق و سخت‌گیرانه برای خروجی در نظر گرفته شد. به‌عنوان مثال، برای رویدادهای جنگی، فیلدهایی مانند event_type, title, description, period, location, causes, outcomes, casualties, key_figures, و sources تعریف شدند. رعایت ساختار، الزامی بوده و مدل ملزم به تولید JSON معتبر با مقادیر فقط به زبان فارسی و کلیدهای انگلیسی بود. تمام ساختارهای قالب به صورت فایل‌های JSON به همراه فایل‌های تمرین ارسال شده است.

۳. طراحی پرامپت

برای هدایت مدل‌ها، پرامپت‌هایی دقیق طراحی شد که ضمن انتقال مفهوم، انتظارات ساختاری را نیز منتقل کنند. این پرامپت‌ها شامل مثال، توضیح نقش هر فیلد، هشدار در مورد اشتباهات رایج، و تأکید بر عدم ترجمه کلیدها و رعایت قوانین JSON بودند.

پرامپت‌های مورد استفاده:

ROLE: You are a JSON FILLER specialist. FILL THE GIVEN JSON STRUCTURE BASED ON THE INFORMATION I GIVE YOU.

RULES:

1. OUTPUT MUST BE:

- OUTPUT ONLY ONE JSON, NOTHING MORE
- KEYWORDS MUST BE "English", VALUES MUST BE "Farsi"
- ALL FIELDS MUST PRESENT, NOTHING MORE, NOTHING LESS
- ALL NUMBERS / DIGITS MUST BE ENGLISH.
- OUTPUT MUST STRICTLY BETWEEN START_JSON{JSON}END_JSON
- Unknown numbers: null
- Unknown string: ""
- ONLY ONE JSON AS OUTPUT, NOTHING MORE

- SOME INFORMATION SHOULD BE INFERRED FROM THE CONTENT AND ARE NOT EXPLICITLY MENTIONED. YOU SHOULD INFER THEM.

- THE CONTENT I GIVE YOU IS ENOUGH COMPREHENSIVE TO FILL ALL ENTRIES OF THE JSON. SO TRY TO FILL ALL OF THEM.

STRUCTURE: THE OUTPUT MUST FOLLOW THE FOLLOWING STRUCTURE (EXACTLY THE SAME, DO NOT CHANGE):

"""

DESIRED JSON STRUCTURE

"""

NOW, FILL THE ABOVE EMPTY JSON STRUCTURE WITH THE INFORMATION IN THE FOLLOWING PARAGRAPHS. THE OUTPUT MUST FOLLOW THE SAME JSON STRUCTURE AS ABOVE, BUT FILLED BASED ON THE FOLLOWING INFORMATION. SOME INFORMATION SHOULD BE INFERRED FROM THE CONTENT AND ARE NOT EXPLICITLY MENTIONED. YOU SHOULD INFER THEM.:

START OF CONTENT

QUERY_CONTENT_PLACEHOLDER

END OF CONTENT

YOUR TASK IS TO OUTPUT THE GIVEN JSON FORMAT, BUT FILLED BASED ON THE INFORMATION I GAVE YOU.

لازم به ذکر است که در این پرامپت نمونه‌هایی از ورودی و خروجی نیز قرار داده‌شده است تا مدل بهتر بتواند خروجی مطلوب تولید کند. در واقع از تکنیک Few-Shut Learning استفاده کرده‌ایم.

همچنین ساختارهای متفاوتی نیز برای هر یک از وقایع تاریخی مانند جنگ‌ها، عهدنامه‌ها و قراردادها، انقلاب‌ها و دستاوردها طراحی شده است. این ساختارها به صورت اتوماتیک بر اساس موضوع مورد انتخاب در پرامپت قرار می‌گیرد تا خروجی نهایی مطابق آن باشد.

فایل‌های نمونه Few-Shut و ساختارهای متفاوت JSON به همراه تمرین ارسال شده است.

چالش‌های طراحی پرامپت:
یکی از چالش‌های عمده که با طراحی پرامپت در طول این تمرین داشتیم این بود که اگر طول پرامپت از حدی بزرگ‌تر شود، یا ساختار آن کمی تغییر کند، مدل خروجی مطلوبی تولید نمی‌کند. از آنجایی که از مدل‌های زبانی متن‌باز کوچک و متوسط استفاده شده است، این مشکل دو چندان است. به همین دلیل باید در طراحی پرامپت دقت بسیار زیادی داشت.

۴. تست و مقایسه مدل‌ها

برای ارزیابی مدل‌ها، پرس‌وجوهایی متنوع شامل متون عمومی، علمی، ترجمه، کدهای برنامه‌نویسی و داده‌های تاریخی اجرا شد. از هر مدل زمان پاسخ‌دهی، نرخ کلمات در ثانیه، حجم تولید و صحت ساختار خروجی بررسی گردید.

تحلیل رفتار و عملکرد سیستم:

۱. کیفیت خروجی

مدل‌های مختلف رفتاری متنوع از خود نشان دادند. مدل‌هایی مانند ۳LLaMA و ۲٫۵Qwen نسبت به سایرین دقت بالاتری در تولید ساختار JSON داشتند. در بسیاری از موارد، حتی مقادیر خالی نیز به‌درستی با "" یا null تولید می‌شد. برخی مدل‌ها (مانند ۳Gemma) تمایل به تولید متن بدون رعایت ساختار دقیق JSON داشتند و نیازمند post-processing بودند.

۲. سرعت اجرا

مدل‌های کوچک‌تر مانند phi4-mini و LLaMA3:8B زمان پاسخ‌دهی کمتری داشتند (میانگین ۲ تا ۵ ثانیه) در حالی که مدل‌هایی مانند DeepSeek:14B زمان‌های بالاتر (تا ۱۲ ثانیه) را ثبت کردند. این مقایسه اهمیت انتخاب مدل مناسب با توجه به منابع سیستم را نشان می‌دهد.

۳. اعتبارسنجی ساختار

برای اعتبارسنجی ساختار خروجی، تلاش شد تا پاسخ مدل‌ها با استفاده از json.loads() تجزیه شوند. در مواردی که مدل‌ها کاما یا براکت‌های نادرست استفاده کرده بودند، parsing با شکست مواجه می‌شد. در نتیجه، یکی از چالش‌ها، ترغیب مدل‌ها به تولید JSON معتبر بود.

یکی از مهم‌ترین دستاوردهای این تمرین، بهره‌گیری مؤثر از مدل‌های زبانی سبک و متن‌باز است که بدون نیاز به سخت‌افزارهای سنگین یا GPU، قادر به پردازش متون فارسی و تولید خروجی‌های ساخت‌یافته هستند. طراحی این سامانه به‌گونه‌ای بوده که به‌صورت کاملاً محلی و آفلاین اجرا شود؛ ویژگی‌ای که آن را برای کاربردهای امنیتی و پژوهشی ایده‌آل می‌سازد. همچنین، این سیستم فرایند استخراج اطلاعات از متون تاریخی را به‌طور کامل خودکار کرده و نیاز به برچسب‌گذاری داده‌ها یا دخالت انسانی را از میان برداشته است. قابلیت توسعه این سامانه برای سایر

رویدادهای تاریخی نظیر انقلاب‌ها، قراردادها یا شخصیت‌های مهم نیز از دیگر مزایای کلیدی آن محسوب می‌شود که زمینه‌ساز توسعه پایگاه‌های دانش غنی و بومی خواهد بود.

با وجود موفقیت کلی سامانه، چالش‌هایی نیز در مسیر اجرا مشاهده شد. برخی از مدل‌های مورد استفاده توانایی کافی برای تولید خروجی دقیق در قالب JSON نداشتند یا خروجی آن‌ها نیازمند پردازش تکمیلی (post-processing) برای اعتبارسنجی و اصلاح بود. همچنین، به دلیل تفاوت ساختاری بین مدل‌های مختلف، در برخی موارد رفتار مدل‌ها در برابر یک پرامپت یکسان متفاوت و پیش‌بینی‌ناپذیر بود که نیاز به تنظیم‌های خاص برای هر مدل را مطرح می‌سازد. علاوه بر این، آموزش مدل‌ها برای رعایت دقیق قواعد سخت‌گیرانه مانند فرمت‌بندی صحیح JSON و محدود کردن زبان خروجی به فارسی، یکی از چالش‌های اساسی تمرین بود که در گام‌های بعدی نیازمند بهبود خواهد بود.

ابتدا مجموعه‌ای از داده‌های متنی پیش‌پردازش‌شده از منابع فارسی گردآوری شد و سپس با استفاده از مدل‌های زبان کوچک و سبک شرکت OpenAI نظیر gpt-4.1-nano، این متون به خروجی‌های JSON ساخت‌یافته تبدیل شدند. این سامانه به گونه‌ای طراحی شده است که کاملاً به صورت محلی اجرا شده و از قابلیت اجرای آفلاین بهره می‌برد که مزیتی مهم برای پردازش داده‌های حساس محسوب می‌شود.

برای شروع، داده‌ها از فایل فشرده‌شده preprocessed_persian_data.zip استخراج و به صورت لیست دیکشنری‌های پایتونی بارگذاری شدند. سپس برای هر ورودی، محتوای متنی آن (شامل روایت یا توصیف یک رویداد تاریخی) به عنوان ورودی به مدل زبانی داده شد، همراه با یک پرامپت بسیار دقیق و صریح که مدل را ملزم می‌کرد بر اساس نوع رویداد (جنگ، قرارداد یا انقلاب)، تنها یکی از قالب‌های JSON از پیش تعیین‌شده را تکمیل کند. در این پرامپت قوانین سخت‌گیرانه‌ای وضع شد از جمله: استفاده از زبان فارسی در تمام مقادیر، حفظ کامل ساختار JSON، عدم افزودن یا حذف فیلدها، و استفاده از "" برای مقادیر متنی گم‌شده و null برای مقادیر عددی ناموجود. این طراحی دقیق باعث شد خروجی‌های مدل با حداقل نیاز به اصلاحات جانبی، قابل پردازش با json.loads() باشند.

رفتار برنامه در تبدیل متون به JSON کاملاً کنترل‌شده و قابل پیش‌بینی بود. مدل زبان در بیشتر موارد موفق شد نوع رویداد را تشخیص داده و اطلاعات مورد نیاز را از متن استخراج کند. با این حال، در برخی نمونه‌ها، مدل به دلیل ابهام در محتوا یا کمبود اطلاعات، مقادیر خالی یا null تولید کرد که با توجه به طراحی سیستم، این رفتار کاملاً قابل قبول بود. پس از دریافت خروجی مدل، تنها محتوای بین برچسب‌های START_JSON و END_JSON استخراج شده و به‌عنوان داده ساخت‌یافته در سیستم ذخیره شد. در نهایت، خروجی‌های نهایی در دو فرمت CSV و JSON ذخیره گردیدند تا هم برای تحلیل‌های آماری و هم برای استفاده در سیستم‌های مبتنی بر API قابل بهره‌برداری باشند.

در ابتدا با استفاده از پکیج dotenv، کلید API مدل زبانی از فایل .env بارگذاری شد تا اتصال امن به سرور OpenAI برقرار گردد. مدل پیش‌فرض مورد استفاده من، نسخه‌ای سبک از GPT-٤ به نام "gpt-4.1-nano" بوده است.

داده‌های متنی از دو منبع اصلی بارگذاری شدند:

- یک فایل ZIP شامل نسخه پیش‌پردازش‌شده‌ای از مقالات تاریخی فارسی به فرمت CSV.
- فایل CSV اصلی با محتوای متنی، نام مقاله و لینک مرجع برای هر مقاله تاریخی.

نتیجه این بخش لیستی از دیکشنری‌ها بود که در هر دیکشنری، سه کلید اصلی داشتیم: name, link, content.

برای تضمین انسجام ساختاری، سه فایل JSON به عنوان الگوهای استاندارد برای سه نوع رویداد تاریخی بارگذاری شدند:

- war_json_format.txt: ساختار مربوط به جنگ‌ها
- revolution_json_format.txt: ساختار مربوط به انقلاب‌ها
- contract_json_format.txt: ساختار مربوط به قراردادها

همچنین برای درک بهتر مدل، سه فایل نمونه‌ی خروجی واقعی از هر نوع رویداد نیز بارگذاری شدند تا به عنوان راهنما (few-shot examples) در متن prompt به مدل ارائه شوند.

در مهم‌ترین بخش تمرین، با استفاده از حلقه‌ای بر روی صد مقاله اول و سپس صد مقاله دوم از مجموعه داده‌ها، برای هر متن یک prompt دقیق طراحی شد که شامل موارد زیر بود:

- وظیفه مدل: استخراج یک رویداد تاریخی از متن و تبدیل آن به فرمت JSON.
- انتخاب خودکار نوع رویداد (جنگ، قرارداد یا انقلاب).
- ارائه دقیق ساختار مورد نیاز برای هر نوع رویداد.
- نمونه‌های واقعی خروجی برای کمک به مدل.
- الزامات دقیق برای خروجی (شروع با START_JSON و پایان با END_JSON، عدم تغییر در ساختار، استفاده از مقادیر خالی یا null در صورت نبود داده و ...).

این prompt برای هر مقاله به مدل فرستاده شد و پاسخ دریافتی توسط دستور get_completion دریافت شد. سپس بخش JSON خروجی با استفاده از json.loads تجزیه شد و به داده اصلی افزوده شد.

در صورتی که خروجی مدل قابل پارس نبود، خطا ثبت شده و آن ورودی صرفاً مقدار None به عنوان خروجی دریافت کرد.

مدل‌های زبانی کوچک عملکرد نسبتاً خوبی در تفکیک نوع رویداد داشتند و توانستند اکثراً ساختارهای مورد انتظار را بازسازی کنند. برخی مشاهدات مهم عبارت بودند از:

- در مواردی که متن مبهم بود، مدل با دقت خوبی نزدیک‌ترین نوع رویداد را انتخاب می‌کرد.
- مدل تمایل داشت مقادیر را به صورت توصیفی و کامل در فیلدهای متنی وارد کند که مطلوب ما بود.
- در چند مورد معدود، مدل خروجی را خارج از محدوده START_JSON تا END_JSON ارائه داد که منجر به خطای parsing شد.

در پایان، داده‌های ساختارمند شده در دو فرمت ذخیره شدند:

- structured_data.csv: مناسب برای پردازش با ابزارهایی مانند Excel یا pandas.
- structured_data.json: مناسب برای کاربردهای پردازش ماشینی یا تغذیه به پایگاه‌های داده NoSQL.

در این مرحله از تمرین، با استفاده از مدل‌های زبانی پیشرفته، توانستیم مرحله‌ی بسیار مهم و چالش‌برانگیز استخراج اطلاعات را به شکلی خودکار و دقیق انجام دهیم. بهره‌گیری از LLMها، نه‌تنها فرآیند استخراج اطلاعات را ساده‌تر و سریع‌تر کرد، بلکه دقت و عمق داده‌های استخراجی را نیز به شکل چشم‌گیری افزایش داد. این مرحله، بستری بسیار قدرتمند برای انجام تحلیل‌های هوشمند، ساخت سیستم‌های پاسخ‌گو، و اتصال داده‌ها به یکدیگر در مراحل بعدی تمرین فراهم می‌سازد.

در واقع به جای بالا آوردن مدل های کوچک تر به صورت لوکال از API مدل قدرتمند تر -GPT4.1 nano استفاده کردیم. این مدل دقت را به طرز چشمگیری افزایش داده و به علت context بزرگ تر در ورودی در پردازش وزودی های بزرگ کمتر هذیان میگوید. برای گرفتن API در یک کورس prompt engineering از DeepLearning.ai ثبت نام کردیم و از آن استفاده کردیم. کد های این بخش در فایل json_extractor.ipynb موجود است.

<<یک نمونه خروجی>>

{'event_type': 'جنگ',

'title': 'جنگ کرنال',

'description': ' نبرد کرنال در تاریخ ۵ اسفند ۱۱۱۷ هجری قمری (۲۴ فوریه ۱۷۳۹ میلادی) بین لشکر نادرشاه افشار و لشکر محمدشاه پادشاه هند رخ داد. این جنگ منجر به شکست و اسارت امپراتور هند شد و نادرشاه هندوستان را فتح کرد. دلیل وقوع این جنگ، فرار های یاغی به هندوستان و عدم تسلیم ایشان توسط محمدشاه گورکانی اعلام \u200cافغان\ شد.',

'period': {'start_year': '1739', 'end_year': None, 'era': 'صفویه و افشاریه'},

'location': {'province': '',

'city': 'کرنال',

'modern_location': {'country': 'ایران', 'province': ''},

'coordinates': {'latitude': None, 'longitude': None, 'accuracy': ''}},

'causes': ['فرار افغان\u200cهای یاغی به هندوستان',

'عدم تسلیم افغان\u200cهای یاغی توسط محمدشاه گورکانی'],

'belligerents': [{'name': 'نادرشاه افشار (دولت ایران)',

'leader': 'نادرشاه افشار',

'type': 'دولت',

'strength': None},

{'name': 'محمدشاه (پادشاهی گورکانی هند)',

'leader': 'محمدشاه',

'type': 'دولت',

'strength': None}],

'result': 'شکست و اسارت امپراتور هند و فتح هندوستان توسط نادرشاه افشار',

'casualties': {'side_a': None,

'side_b': None,

'civilian': None,

'notes': ''},

'impact': {'political': [], 'economic': [], 'social': [], 'cultural': []},

'historical_significance': 'این جنگ منجر به گسترش قلمرو امپراتوری ایران و تغییرات در توازن قدرت در منطقه شد.',

'timeline': [{'date': '1739-02-24',

'event': 'نبرد کرنال',

'description': ' نبرد بین لشکر نادرشاه و لشکر محمدشاه که منجر به شکست و اسارت امپراتور هند شد.'}],

'key_figures': [{'name': 'نادرشاه افشار',

'role': 'قائد و فرمانده ایرانی',

'allegiance': 'ایران'},

{'name': 'محمدشاه', 'role': 'پادشاه هند', 'allegiance': 'هند'}],

'aftermath': ' فتح هندوستان توسط نادرشاه و تغییرات در مرزهای منطقه، تاثیرات سیاسی و نظامی قابل توجهی داشت.',

'controversies': [],

'references': [{'title': 'تاریخ جنگ\u200cهای ایران و هند',

'author': '',

'year': '',

'type': '',

'reliability': ''}],

'source': {'name': '',

'author': '',

'publication_date': '',

```
 'url': '',
 'archive': {'name': '', 'location': ''}},
'metadata': {'last_updated': '',
 'contributors': [],
 'verification_status': ''}}
```

یک روش جایگزین برای تمرین

گروه ما یک روش دیگری برای این تمرین تست کرد. این روش به ترتیب در زیر توضیح داده شده است:

- ابتدا نام عنوان تمامی موضوعاتی که می‌خواهیم درباره آنها اطلاعات جمع‌آوری کنیم را در یک لیست قرار می‌دهیم.
- سپس برای هر یک از عنوان‌ها که یک موضوع خاص (جنگ، انقلاب و...) دارد را انتخاب کرده و ساختار JSON آن را تعیین می‌کنیم.
- برای هر یک از فیلدهای ساختار جیسون، با استفاده از Search API سعی می‌کردیم صرفاً اطلاعات مورد نیاز برای پر کردن آن فیلد را از اینترنت استخراج کنیم.
- اطلاعات استخراج شده را به یک مدل زبانی کوچک می‌دهیم تا دقیقاً آن فیلد را پر کند.
- این فرایند را برای همه فیلدهای فایل جیسون یک واقعه تاریخی و همه وقایع تاریخی تکرار می‌کنیم تا خروجی‌های موردنظر آماده‌شوند.

با توجه به خروجی‌هایی که از این روش گرفتیم و خروجی‌های روش اصلی، مشاهده کردیم که خروجی‌های روش اصلی از کیفیت بهتری برخوردار هستند و اطلاعات کامل‌تری را شامل می‌شوند. به همین دلیل ترجیح بر این شد که از روش اولیه استفاده شوند.

لازم به ذکر است که این روش زمان بیشتری برای استخراج اطلاعات و تهیه فایل جیسون نیاز داشت، به طوری که برای تولید یک فایل جیسون، حدود ۸۰ ثانیه زمان نیاز دارد. با این حال، این روش فرایند جمع‌آوری داده و پیش‌پردازش و ایجاد فایل جیسون به صورت اتوماتیک انجام می‌دهد و یک فرایند end-to-end برای این کاربرد است.

برچسب گذاری

در این بخش از تمرین، فرایند برچسب‌گذاری (Labeling) داده‌ها به عنوان یکی از مراحل کلیدی آماده‌سازی داده برای تحلیل مدل‌های زبانی و یادگیری ماشین انجام شده است. این فرایند با هدف تفکیک داده‌ها به دو کلاس اصلی از نظر کیفیت، یعنی "خوب" و "بد" صورت گرفته و شامل دو رویکرد متفاوت بوده است: برچسب‌گذاری اتوماتیک با کمک مدل‌های زبانی کوچک و برچسب‌گذاری دستی توسط انسان.

روش‌های برچسب‌گذاری:

برچسب‌گذاری اتوماتیک: برای برچسب‌گذاری اتوماتیک، از دو مدل زبانی کوچک و سبک (Small Language Models) در چارچوب Ollama استفاده شده است:

- مدل phi3.8b (با API o3-mini)
- مدل gpt-4o (با API 4o)

این مدل‌ها به‌صورت مستقل و موازی بر روی مجموعه داده اعمال شدند و خروجی آن‌ها به صورت لیبل‌های دودویی (خوب / بد) ثبت گردید. به منظور حصول اطمینان از سازگاری ساختار، کلیه خروجی‌ها در قالب یک قالب JSON استاندارد شده با کلیدهای انگلیسی و مقادیر فارسی ذخیره شدند.

برچسب‌گذاری دستی: به منظور ارزیابی کیفیت برچسب‌گذاری اتوماتیک و تهیه برچسب‌های مرجع، مجموعه‌ای از داده‌ها نیز به‌صورت دستی توسط سه نفر (در بعضی نمونه ها چهار نفر) از اعضای تیم مورد بررسی و برچسب‌گذاری قرار گرفت. فرآیند به این صورت بود که هر نمونه به صورت مستقل توسط هر دو فرد بررسی شد و در صورت اختلاف، جلسه توافق و حل‌وفصل برای تعیین برچسب نهایی برگزار شد. (توجه شود چون برای اضافه کردن فردی دیگر باید اکانت پریمیوم میخریدیم همگی با یک اکانت در زمان های مختلف لیبل زدیم.)

پلتفرم مورد استفاده برای انجام و مدیریت فرایند برچسب‌گذاری، Label Studio بوده است. این ابزار متن‌باز و انعطاف‌پذیر، امکان تعریف تمرین‌های برچسب‌گذاری با ساختار دلخواه، بارگذاری

داده‌های متنی، تعریف برچسب‌های سفارشی و مشاهده تاریخچه‌ی تصمیم‌گیری‌ها را فراهم کرده است. تنظیمات تمرین شامل تعریف دو کلاس "خوب" و "بد" و نمایش داده‌ها به صورت متنی ساده بوده است.

به منظور دستیابی به یکنواختی در تفسیر داده‌ها و جلوگیری از بروز سوگیری در فرآیند برچسب‌گذاری، سیاست‌های زیر به عنوان دستورالعمل راهنما در اختیار برچسب‌گذاران قرار گرفت:

تعریف دقیق کلاس‌ها:

- خوب: متنی که ساختار زبانی منسجم، اطلاعات معتبر و مرتبط، نداشتن ابهام و نگارشی مناسب دارد. ('Good')
- بد: متنی که شامل اطلاعات ناقص، مغشوش، اشتباه یا غیرقابل استفاده از نظر مدل‌های زبانی است. ("Bad")

عدم توجه به جهت‌گیری موضوعی: مهم نیست که متن در مورد چه موضوعی باشد، بلکه ساختار و کیفیت نگارشی مد نظر است.

بررسی در سطح جمله و پاراگراف: کیفیت باید در سطح کلی محتوا سنجیده شود، نه فقط یک جمله یا عبارت خاص.

تطابق با هدف نهایی تمرین: برچسب‌گذاری باید در راستای کمک به مدل‌های زبانی برای یادگیری محتوای باکیفیت انجام شود.

معیار ارزیابی

کاپای کوهن (κ) یک معیار آماری است که میزان توافق بین دو ارزیاب را پس از حذف تاثیر توافق تصادفی می‌سنجد. این معیار با مقایسه توافق مشاهده‌شده (p_o) با توافق مورد انتظار بر اساس احتمال تصادفی (p_e) محاسبه می‌شود و نتیجه آن بین ۱ (توافق کامل) تا ۰ (توافق تصادفی) تفسیر می‌شود. این معیار در پژوهش‌های پزشکی و روان‌شناسی کاربرد گسترده‌ای دارد. با این حال در این تمرین برای ارزیابی فرآیند برچسب‌زنی به نمونه‌ها استفاده می‌شود. رابطه این معیار را در زیر مشاهده می‌کنید:

$$\kappa \equiv \frac{p_o - p_e}{1 - p_e} = 1 - \frac{1 - p_o}{1 - p_e}$$

برای بررسی میزان همخوانی بین برچسب‌گذاران انسانی و نیز مقایسه برچسب‌گذاری انسانی با مدل‌های زبانی، از معیارهای ارزیابی استاندارد ضریب کاپا استفاده شده است. این ضریب یک معیار آماری برای اندازه‌گیری میزان توافق بین دو برچسب‌گذار است که تأثیر توافق تصادفی را حذف می‌کند. در این تمرین، مقدار ضریب کاپا بین دو برچسب‌گذار انسانی برابر با حدود **۰٫۸۳** محاسبه شد که نشان‌دهنده توافق خوب است. در نهایت برای هر واقعه تاریخی سه برچسب وجود دارد و برچسب نهایی براساس majority vote این پرچسب‌ها انجام می‌شود.

فرآیند برچسب‌گذاری داده‌ها، به‌صورت ترکیبی از برچسب‌گذاری دستی و خودکار انجام شده و داده‌های حاصل در قالب ساختار یافته برای مراحل بعدی آماده‌سازی شده‌اند. تحلیل مقادیر کاپا نشان‌دهنده کیفیت مناسب برچسب‌های انسانی و توافق بالا بین آن‌ها بوده است. همچنین، عملکرد مدل‌های زبانی سبک (به ویژه gpt-4o) نسبتاً رضایت‌بخش ارزیابی شد، هرچند در برخی موارد نیاز به بازبینی و اصلاح دستی وجود داشته است.

<<چند نمونه خروجی>>

جنگ خراسان


```
{
  "id": 175142064,
  "data": {
    "link":
"https://fa.wikipedia.org/wiki/%D8%AC%D9%86%DA%AF_%D8%AE%D8%B1%D8%A7%D8%B3
%D8%A7%D9%86",
    "name": "جنگ خراسان",
    "content": " مشهد : پیروزی قاطع صفوی تغییراتقلمرو : خراسان نتایج : ۱۷۲۷ – ۱۷۲۶ تاریخ : موقعیت
به دست وفاداران صفوی افتاد فتح خراسان توسط نیروهای وفادار صفوی علیه جدایی‌طلبان در خراسان، اولین لشکرکشی
```

بزرگ نادر بود که وی به نمایندگی از مدعی جدید تاج‌وتخت صفوی، تهماسب دوم، انجام داد . این امر او را به ",": مرکز چشم‌انداز سیاسی جنگ در ایران متلاشی‌شده در اوایل سده هجدهم سوق داد . اعدام‌شده


```
    "extracted_content": {
      "title": "فتح خراسان توسط نادر",
      "causes": [
        "جدایی‌طلبی در خراسان",
        "تلاش برای تثبیت قدرت صفوی در منطقه"
      ],
      "impact": {
        "social": [],
        "cultural": [],
        "economic": [],
        "political": [
          "تقویت موقعیت نادر در منطقه خراسان و ایران"
        ]
      },
      "period": {
        "era": "",
        "end_year": "1727",
        "start_year": "1726"
      },
      "result": "پیروزی قاطع صفوی و تصرف مشهد",
      "source": {
        "url": "https://fa.wikipedia.org/wiki/نادرشاه",
        "name": "ویکی‌پدیا فارسی",
```

```
      "author": "کاربران ویکی‌پدیا",
      "archive": {
        "name": "آرشیو ملی ایران",
        "location": "تهران، ایران"
      },
      "publication_date": "2023-01-01"
    },
    "location": {
      "city": "مشهد",
      "province": "خراسان",
      "coordinates": {
        "accuracy": "",
        "latitude": null,
        "longitude": null
      },
      "modern_location": {
        "country": "ایران",
        "province": "خراسان"
      }
    },
    "metadata": {
      "contributors": [
        "کاربر A",
        "کاربر B"
      ],
```

```
        "last_updated": "2025-04-24",
        "verification_status": "تأیید شده"
      },
      "timeline": [
        {
          "date": "1726",
          "event": "شروع لشکرکشی نادر به خراسان",
          "description": "نادر به نمایندگی از تهماسب دوم، حمله به خراسان و تصرف مشهد را آغاز کرد."
        },
        {
          "date": "1727",
          "event": "تصرف کامل خراسان",
          "description": "نادر موفق شد خراسان را به کنترل خود درآورد و پیروزی قاطع در این منطقه کسب کند."
        }
      ],
      "aftermath": "این پیروزی نقش مهمی در تثبیت قدرت نادر و شکل‌گیری سیاست‌های نظامی و سیاسی او در ایران داشت.",
      "casualties": {
        "notes": "",
        "side_a": null,
        "side_b": null,
        "civilian": null
      },
      "event_type": "جنگ",
```

```
      "references": [
        {
          "type": "کتاب",
    "year": "۱۹۳۰",
          "title": "تاریخ نادر شاه افشار",
          "author": "محمدحسن خان اعتمادالسلطنه",
          "reliability": "معتبر"
        }
      ],
      "description": " فتح خراسان توسط نیروهای وفادار صفوی علیه جدایی‌طلبان در خراسان، اولین لشکرکشی بزرگ نادر بود که وی به نمایندگی از مدعی جدید تاج‌وتخت صفوی، تهماسب دوم، انجام داد. این امر او را به مرکز چشم‌انداز سیاسی جنگ در ایران متلاشی‌شده در اوایل سده هجدهم سوق داد.",
      "key_figures": [
        {
          "name": "نادر",
          "role": "رهبر نظامی و فرمانده لشکرکشی",
          "allegiance": "صفوی"
        }
      ],
      "belligerents": [
        {
          "name": "نیروهای وفادار صفوی",
          "type": "نظامی",
          "leader": "نادر",
          "strength": null
        },
```

```
        {
          "name": "جدایی‌طلبان در خراسان",
          "type": "متمرد",
          "leader": "",
          "strength": null
        }
      ],
      "controversies": [],
      "historical_significance": " این لشکرکشی آغاز قدرت‌گیری نادر و نقش‌آفرینی او در تحولات سیاسی و نظامی ایران در اوایل سده هجدهم بود."
    }
  },
  "annotations": [
    {
      "id": 60206996,
      "result": [
        {
          "id": "5058413e-994f-4032-ad0d-c97740ac3dba",
          "type": "choices",
          "value": {
            "choices": [
              "Good"
            ]
          },
          "origin": "prediction",
          "to_name": "text",
```

```
          "from_name": "quality"
        }
      ],
      "created_username": "farzan Rahmani farzanrahmani70@gmail.com,
70663",
      "created_ago": "2 days, 6 hours",
      "completed_by": {
        "id": 70663,
        "first_name": "farzan",
        "last_name": "Rahmani",
        "avatar": null,
        "email": "farzanrahmani70@gmail.com",
        "initials": "fR"
      },
      "last_annotation_history": 65557856,
      "reviews": null,
      "was_cancelled": false,
      "ground_truth": false,
      "created_at": "2025-05-02T09:16:50.884808Z",
      "updated_at": "2025-05-02T09:16:50.884819Z",
      "draft_created_at": null,
      "lead_time": 1.083,
      "import_id": null,
      "last_action": "prediction",
      "bulk_created": false,
      "task": 175142064,
```

```
      "project": 145865,
      "updated_by": 70663,
      "parent_prediction": 39604864,
      "parent_annotation": null,
      "last_created_by": 70663,
      "comment_count": 0,
      "unresolved_comment_count": 0
    },
    {
      "id": 60281762,
      "result": [
        {
          "id": "F4Hf7CusVu",
          "type": "choices",
          "value": {
            "choices": [
              "Good"
            ]
          },
          "origin": "manual",
          "to_name": "text",
          "from_name": "quality"
        }
      ],
      "created_username": "farzan Rahmani farzanrahmani70@gmail.com,
70663",
```

```
    "created_ago": "3 hours, 27 minutes",
    "completed_by": {
      "id": 70663,
      "first_name": "farzan",
      "last_name": "Rahmani",
      "avatar": null,
      "email": "farzanrahmani70@gmail.com",
      "initials": "fR"
    },
    "last_annotation_history": 65637077,
    "reviews": null,
    "was_cancelled": false,
    "ground_truth": false,
    "created_at": "2025-05-04T12:31:50.489045Z",
    "updated_at": "2025-05-04T12:31:50.489054Z",
    "draft_created_at": null,
    "lead_time": 1.353,
    "import_id": null,
    "last_action": "submitted",
    "bulk_created": false,
    "task": 175142064,
    "project": 145865,
    "updated_by": 70663,
    "parent_prediction": null,
    "parent_annotation": null,
```

```
      "last_created_by": 70663,
      "comment_count": 0,
      "unresolved_comment_count": 0
    },
    {
      "id": 60281765,
      "result": [
        {
          "id": "yRCyGT_f1d",
          "type": "choices",
          "value": {
            "choices": [
              "Good"
            ]
          },
          "origin": "manual",
          "to_name": "text",
          "from_name": "quality"
        }
      ],
      "created_username": "farzan Rahmani farzanrahmani70@gmail.com,
70663",
      "created_ago": "3 hours, 27 minutes",
      "completed_by": {
        "id": 70663,
        "first_name": "farzan",
```

```
        "last_name": "Rahmani",
        "avatar": null,
        "email": "farzanrahmani70@gmail.com",
        "initials": "fR"
      },
      "last_annotation_history": 65637080,
      "reviews": null,
      "was_cancelled": false,
      "ground_truth": false,
      "created_at": "2025-05-04T12:31:54.444379Z",
      "updated_at": "2025-05-04T12:31:54.444388Z",
      "draft_created_at": null,
      "lead_time": 1.456,
      "import_id": null,
      "last_action": "submitted",
      "bulk_created": false,
      "task": 175142064,
      "project": 145865,
      "updated_by": 70663,
      "parent_prediction": null,
      "parent_annotation": null,
      "last_created_by": 70663,
      "comment_count": 0,
      "unresolved_comment_count": 0
    }
```

```
  ],
  "predictions": [
    {
      "id": 39604864,
      "result": [
        {
          "id": "5058413e-994f-4032-ad0d-c97740ac3dba",
          "type": "choices",
          "value": {
            "choices": [
              "Good"
            ]
          },
          "to_name": "text",
          "from_name": "quality"
        }
      ],
      "model_version": "Auto-label NLP_HW1__Evaluate Historical Data
Quality Based on Completeness, Accuracy, and Relevance",
      "created_ago": "3 days",
      "score": 1,
      "cluster": null,
      "neighbors": null,
      "mislabeling": 0,
      "created_at": "2025-05-01T15:39:28.131665Z",
      "updated_at": "2025-05-01T15:39:28.131668Z",
```

```
      "model": null,
      "model_run": 20701,
      "task": 175142064,
      "project": 145865
    }
  ]
}
```


جنگ ایران و روم (۴۴۰)


```
{
  "id": 175142202,
  "data": {
    "link":
"https://fa.wikipedia.org/wiki/%D8%AC%D9%86%DA%AF_%D8%A7%DB%8C%D8%B1%D8%A7
%D9%86_%D9%88_%D8%B1%D9%88%D9%85_(%DB%B4%DB%B4%DB%B0)",
    "name": "جنگ ایران و روم (۴۴۰)",
    "content": "جنگ ایران و روم (۴۴۰) موقعیت : خاور نزدیک نتایج : پیمان صلح : پرداخت باج روم به ایران تاریخ : ۴۴۰ ایران و روم درگیری کوتاهی میان ایران ساسانی و امپراتوری بیزانس بود . دلیل کوتاه بودن این جنگ تحت حمله قرار گرفتن استان‌های جنوبی روم به دست وندال‌ها بود که رومیان را واداشت این جنگ را به سرعت تمام کنند و تمرکز خود را روی وندال‌ها بگذارند . به ساسانیان در ازای صلح پول نیز داده شد . Daryaee, Touraj . « Yazdegerd II » . Encyclopaedia Iranica . , Frye, R . N.(۱۹۸۳).« The political history of Iran under the Sasanians » . InYarshater, Ehsan ( ed . ) . The Cambridge History of Iran, Volume ۳(۱):The Seleucid, Parthian and Sasanian Periods . Cambridge : Cambridge University Press . ISBN ۰-۵۲۱ -۲۰۰۹۲-X . , Payne, Richard(۲۰۱۵).« The Reinvention of Iran : The Sasanian Empire and the Huns » . In Maas, Michael ( ed . ) . The Cambridge Companion to the Age of Attila . Cambridge University Press . pp.۲۸۲–۲۹۹. ISBN ۹۷۸-۱-۱۰۷-۶۳۳۸۸-۹.,Shayegan, M . Rahim(۲۰۱۷).« Sasanian political ideology » . In Potts, Daniel T . ( ed . ) . The Oxford Handbook of Ancient Iran . Oxford University Press . pp.۱–۱۰۲۱. ISBN ۹۷۸-۰-۱۹-۰۶۶۸۶۶-۲. East Roman - Sasanian frontier :",
```

```
  "extracted_content": {
    "terms": [
      "پایان جنگ با پیمان صلح",
      "پرداخت باج به ایران"
    ],
    "title": "پیمان صلح میان ایران و روم در جنگ ۴۴۰",
    "impact": {
      "economic": [],
      "political": [],
      "territorial": []
    },
    "period": {
      "era": "",
      "end_year": "440",
      "start_year": "440"
    },
    "result": "پایان جنگ در سال ۴۴۰ و پرداخت باج به ایران",
    "source": {
      "url": "",
      "name": "",
      "author": "",
      "archive": {
        "name": "",
        "location": ""
      },
```

```
      "publication_date": ""
    },
    "parties": [
      {
        "name": "ایران ساسانی",
        "type": "",
        "representative": ""
      },
      {
        "name": "امپراتوری بیزانس",
        "type": "",
        "representative": ""
      }
    ],
    "location": {
      "city": "",
      "province": "",
      "coordinates": {
        "accuracy": "",
        "latitude": null,
        "longitude": null
      },
      "modern_location": {
        "country": "ایران",
        "province": ""
```

```
      }
    },
    "metadata": {
      "contributors": [],
      "last_updated": "",
      "verification_status": ""
    },
    "event_type": "صلح",
    "references": [
      {
        "type": "مقاله",
        "year": "",
        "title": "Yazdegerd II",
        "author": "Daryaee, Touraj",
        "reliability": ""
      },
      {
        "type": "کتاب",
        "year": "1983",
        "title": "The political history of Iran under the Sasanians",
        "author": "Frye, R. N.",
        "reliability": ""
      },
      {
        "type": "کتاب",
```

```
          "year": "2015",
          "title": "The Reinvention of Iran : The Sasanian Empire and the Huns",
          "author": "Payne, Richard",
          "reliability": ""
        },
        {
          "type": "کتاب",
          "year": "2017",
          "title": "Sasanian political ideology",
          "author": "Shayegan, M. Rahim",
          "reliability": ""
        }
      ],
      "description": " در جنگ ۴۴۰ میلادی میان ایران ساسانی و امپراتوری بیزانس، درگیری کوتاهی رخ داد که به دلیل حمله وندال‌ها به استان‌های جنوبی روم بود. رومیان برای تمرکز بر وندال‌ها، این جنگ را به سرعت پایان دادند و در ازای آن، پولی به عنوان باج به ایران پرداخت شد.",
      "controversies": []
    }
  },
  "annotations": [
    {
      "id": 60208178,
      "result": [
        {
          "id": "df3a2a7e-426c-4d54-9427-06c4643e9c75",
          "type": "choices",
```

```
          "value": {
            "choices": [
              "Bad"
            ]
          },
          "origin": "prediction",
          "to_name": "text",
          "from_name": "quality"
        }
      ],
      "created_username": "farzan Rahmani farzanrahmani70@gmail.com,
70663",
      "created_ago": "2 days, 6 hours",
      "completed_by": {
        "id": 70663,
        "first_name": "farzan",
        "last_name": "Rahmani",
        "avatar": null,
        "email": "farzanrahmani70@gmail.com",
        "initials": "fR"
      },
      "last_annotation_history": 65559182,
      "reviews": null,
      "was_cancelled": false,
      "ground_truth": false,
      "created_at": "2025-05-02T09:51:38.451253Z",
```

```
    "updated_at": "2025-05-02T09:51:38.451266Z",
    "draft_created_at": "2025-05-02T09:51:37.463393Z",
    "lead_time": 8.863,
    "import_id": null,
    "last_action": "prediction",
    "bulk_created": false,
    "task": 175142202,
    "project": 145865,
    "updated_by": 70663,
    "parent_prediction": 39605002,
    "parent_annotation": null,
    "last_created_by": 70663,
    "comment_count": 1,
    "unresolved_comment_count": 1
  },
  {
    "id": 60287809,
    "result": [
      {
        "id": "JubdPbH78K",
        "type": "choices",
        "value": {
          "choices": [
            "Bad"
          ]
```

```
          },
          "origin": "manual",
          "to_name": "text",
          "from_name": "quality"
        }
      ],
      "created_username": "farzan Rahmani farzanrahmani70@gmail.com,
70663",
      "created_ago": "1 hour, 24 minutes",
      "completed_by": {
        "id": 70663,
        "first_name": "farzan",
        "last_name": "Rahmani",
        "avatar": null,
        "email": "farzanrahmani70@gmail.com",
        "initials": "fR"
      },
      "last_annotation_history": 65643276,
      "reviews": null,
      "was_cancelled": false,
      "ground_truth": false,
      "created_at": "2025-05-04T14:38:31.242951Z",
      "updated_at": "2025-05-04T14:38:31.242961Z",
      "draft_created_at": null,
      "lead_time": 4.246,
      "import_id": null,
```

```
      "last_action": "submitted",
      "bulk_created": false,
      "task": 175142202,
      "project": 145865,
      "updated_by": 70663,
      "parent_prediction": null,
      "parent_annotation": null,
      "last_created_by": 70663,
      "comment_count": 0,
      "unresolved_comment_count": 0
    },
    {
      "id": 60287810,
      "result": [
        {
          "id": "1GSBKwbfub",
          "type": "choices",
          "value": {
            "choices": [
              "Good"
            ]
          },
          "origin": "manual",
          "to_name": "text",
          "from_name": "quality"
```

```
        }
      ],
      "created_username": "farzan Rahmani farzanrahmani70@gmail.com,
70663",
      "created_ago": "1 hour, 24 minutes",
      "completed_by": {
        "id": 70663,
        "first_name": "farzan",
        "last_name": "Rahmani",
        "avatar": null,
        "email": "farzanrahmani70@gmail.com",
        "initials": "fR"
      },
      "last_annotation_history": 65643277,
      "reviews": null,
      "was_cancelled": false,
      "ground_truth": false,
      "created_at": "2025-05-04T14:38:35.555375Z",
      "updated_at": "2025-05-04T14:38:35.555383Z",
      "draft_created_at": null,
      "lead_time": 2.114,
      "import_id": null,
      "last_action": "submitted",
      "bulk_created": false,
      "task": 175142202,
      "project": 145865,
```

```
      "updated_by": 70663,
      "parent_prediction": null,
      "parent_annotation": null,
      "last_created_by": 70663,
      "comment_count": 0,
      "unresolved_comment_count": 0
    }
  ],
  "predictions": [
    {
      "id": 39605002,
      "result": [
        {
          "id": "df3a2a7e-426c-4d54-9427-06c4643e9c75",
          "type": "choices",
          "value": {
            "choices": [
              "Bad"
            ]
          },
          "to_name": "text",
          "from_name": "quality"
        }
      ],
      "model_version": "Auto-label NLP_HW1__Evaluate Historical Data
Quality Based on Completeness, Accuracy, and Relevance",
```

```
      "created_ago": "3 days",
      "score": 1,
      "cluster": null,
      "neighbors": null,
      "mislabeling": 0,
      "created_at": "2025-05-01T15:39:45.651879Z",
      "updated_at": "2025-05-01T15:39:45.651882Z",
      "model": null,
      "model_run": 20701,
      "task": 175142202,
      "project": 145865
    }
  ]
}
```


فیلتر کردن نهایی داده‌ها

پس از آنکه داده های برچسب گذاری شدند ما ٤٥٠ داده برچسب گذاری شده داریم. حال با اعمال یک فیلتر فقط آنهایی به تعداد بیشتر از ٥٠٪ برچسب Good از نظر کیفیت خورده اند را نگه میداریم و بقیه داده ها که با رای اکثریت برچسب Bad از نظر کیفیت دارند را دور میریزیم. پس از این فیلتر ما ۳۸۰ داده نهایی با کیفیت خوب و قابل استفاده در تسک های مختلف داریم. کد این بخش در فایل filtered_extracted_contents.json موجود است.

گزارش آماری

با توجه به بحث های انجام شده در گروه تلگرام به گزارش مقادیر تعداد کلمات داخل دیتاست، تعداد رکوردهای دیتاست و میانگین طول رشته های هر رکورد دیتاست پیش از استخراج اطلاعات به صورت JSON و پس از آن می پردازیم. کد این قسمت در فایل "frequency_analysis.ipynb" موجود است. نتیجه تحلیل آماری خواسته شده به شکل زیر می‌باشد.

```
Analysis Results:

Number of records: 450

Total words in 'content': 408068

Total words in json ‘extracted content’: 139751

Average length of 'content': 4487.15 characters

Average length of json ‘extracted content’: 1736.52 characters
```

پایان