به نام خدا

نام اعضای تیم:

فرزان رحمانی 403210725

امیررضا ویشته 403211827

امیر واحدی 403211776

محمدرضا مزروعی 403207045

انتخاب موضوع تمرین 4
فاز ۱: ساخت دیتاست از داده های ساختار یافته..... 5
فاز ۲: ساخت مجموعه داده های ارزیابی 23
۲.۱ مقدمه..... 23
۲.۲ روند کلی 24
۲.۳ جزئیات کار..... 25
فاز ۳: آموزش مدل زبانی GLOT500..... 29
۳.۱ آماده‌سازی و تحلیل مجموعه داده‌ها..... 29
۳.۲ استراتژی فیلتر کردن داده‌ها..... 29
۳.۳ طراحی معماری مدل..... 30
۳.۴ پیش آموزش مدل زبان ماسک‌شده ((Masked Language Model..... 30
۳.۵ پیاده‌سازی یادگیری مقابله‌ای ((Contrastive Learning Implementation 31
۳.۶ پیشرفت آموزش و تحلیل تلفات 31
فاز ۴: خروجی گرفتن از مدل‌ها (تولید و ارزیابی خروجی مدل) 33
۴.۱ طراحی چارچوب ارزیابی..... 33
۴.۲ پیاده‌سازی مدل پایه TF-IDF..... 33
۴.۳ تنظیمات ارزیابی مدل عصبی 33
۴.۴ تحلیل و تفسیر نتایج 34
۴.۵ جزئیات پیاده‌سازی فنی..... 35
۴.۶ بینش‌های روش‌شناختی 36
۴.۷ درس‌های فنی آموخته‌شده..... 36
فاز ۵: ارزیابی انسانی با استفاده از Label Studio..... 38
فاز ۶: تحلیل نتایج و مقایسه عملکرد مدل‌ها 41
۶.۱. توافق بین ارزیاب‌ها 41
۶.۲. عملکرد کلی مدل..... 42
۶.۳. تحلیل عملکرد مدل بر اساس نوع سوال..... 43
۶.۳.۱. سوالات مرتبط با مکان (شهر/استان)..... 43
۶.۳.۲. سوالات مرتبط با زمان (تاریخ/سال)..... 44
۶.۳.۳. سوالات مرتبط با شخص 45
۶.۳.۴. سوالات مرتبط با فعالیت/رشته 45
۶.۳.۵. سایر سوالات 46
۶.۴. تفاوت بین مدل‌های پایه و فاین‌تیون شده 47

۶.۵. مقایسه بین روش آماری (TF-IDF) و مدل زبانی.....47
۶.۶. تحلیل کیفی ارزیابی‌های انسانی.....47
۶.۷. نتیجه‌گیری نهایی.....48
فاز ۷: شناسایی نمونه های تکراری مدل تنظیم‌شده‌ی دقیق GLOT500 (امتیازی).....49
۱. مقدمه و روش‌شناسی.....49
۱.۱ هدف.....49
۱.۲ رویکرد روش‌شناختی.....49
۲. تولید جاسازی و تحلیل شباهت.....50
۲.۱ فرآیند تولید جاسازی.....50
۲.۲ ساخت ماتریس شباهت.....50
۳. نتایج تشخیص موارد تکراری مبتنی بر آستانه.....51
۳.۱ تحلیل چند آستانه‌ای.....51
۳.۲ تحلیل دقیق جفت‌های با شباهت بالا.....52
۳.۳ تحلیل شیوع موارد تکراری.....55
۴. تشخیص موارد تکراری مبتنی بر خوشه‌بندی.....55
۴.۱ تحلیل خوشه‌بندی DBSCAN.....55
۴.۲ تحلیل محتوای خوشه.....56
۵. مفاهیم و بینش‌های کیفیت داده‌ها.....57
۵.۱ انواع موارد تکراری شناسایی شده.....57
۵.۲ ارزیابی کیفیت مجموعه داده‌ها.....57
۶. اعتبارسنجی عملکرد مدل.....58
۶.۱ نمایش کیفیت جاسازی.....58
۶.۲ کاربردهای عملی نشان داده شده.....58
۷. برتری پیاده‌سازی فنی.....59
۷.۱ کارایی محاسباتی.....59
۷.۲ چارچوب تحلیل قوی.....59
۸. توصیه‌ها و مسیرهای آینده.....59
۸.۱ توصیه‌های فوری پاکسازی داده‌ها.....59
۸.۲ فرصت‌های بهبود مدل.....59
۹. نتیجه‌گیری.....60

انتخاب موضوع تمرین

موضوع انتخابی تیم ما "مشاهیر" بوده است. این مجموعه داده شامل اطلاعات مربوط به مشاهیر (ادبی، علمی، فرهنگی، ورزشی و ...) از تمرین قبلی است و حدود 9000 رکورد دارد. این مجموعه داده شامل 8 فایل "JSON" است.

فاز ۱: ساخت دیتاست از داده های ساختار یافته

در این فاز از تمرین، قصد داریم از فایل‌های جیسون داده‌شده، در مرحله اول یک متن روان شامل چند جمله که بیان‌کننده تمام اطلاعات هر ساختار جیسون باشد، ایجاد کنیم؛ سپس از هر متن، پنج سوال درباره جنبه‌های متفاوت آن، به همراه پاسخ طرح کنیم.

به صورت دقیق‌تر ورودی و خروجی این فاز را بررسی می‌کنیم:

ورودی فاز اول

هشت فایل جیسون، هر یک درباره یک دسته خاص از مشاهیر، جمعاً شامل اطلاعات حدود ده هزار مشاهیر. بنابراین به صورت کلی، ده هزار ساختار جیسون داریم که هر یک اطلاعات یک فرد مشهور را شامل می‌شود. از آنجایی که این هشت فایل برای گروه‌های متفاوت است، ساختار جیسون متفاوتی نیز دارند.

خروجی فاز اول

خروجی این فاز مشتمل بر دو بخش است:

1. به ازای هر ساختار جیسون (اطلاعات متعلق به یک فرد مشهور)، یک یا چند پاراگراف ایجاد شود که تمامی اطلاعات موجود در ساختار جیسون باشد را در قالب جملات بیان کند. این متن باید روان و قابل فهم باشد.
2. از پاراگراف‌های ایجادشده برای تولید پنج سوال و پاسخ استفاده شود. سوال و پاسخ جنبه‌های متفاوت مربوط به اطلاعات آن فرد مشهور را شامل می‌شود.

بنابراین ورودی شامل ده هزار ساختار جیسون از مشاهیر است. خروجی نیز شامل ده هزار متن به ازای هر ساختار جیسون و پنج سوال به ازای هر متن است. در نتیجه، در انتهای این فاز توقع داریم حدود پنجاه هزار جفت سوال-پاسخ داشته باشیم.

تمامی پیاده‌سازی این فاز در فایل nlp_hw#2_phase_1.ipynb قرار دارد. در این گزارش به بخش‌های کلیدی این پیاده‌سازی اشاره می‌کنیم.

نکته مهم

با توجه به فرایند توضیح داده‌شده، کیفیت خروجی به صورت مستقیم به کیفیت ورودی بستگی دارد. اگر ورودی شامل اطلاعات جامع و کاملی از آن فرد مشهور باشد، متن تولید شده از آن نیز جامعیت مناسبی خواهد داشت و می‌توان در مرحله بعد، سوالات متنوعی از جنبه‌های گوناگون متن طرح کرد. اما اگر ساختار جیسون ورودی فاقد اطلاعات مفید باشد، متن تولید شده کیفیت مناسبی نخواهد داشت و سوالات متنوعی نمی‌توان از آن طرح کرد. با این تفاصیل، بیشترین تلاش را انجام داده‌ایم تا فرایند تبدیل ساختار جیسون به متن به بهترین نحو ممکن انجام شود و تا حد ممکن سوالات باکیفیتی طرح شود، اما از آنجایی که در این فاز، کنترلی روی ورودی داده‌شده نداریم، ساختارهای جیسونی در ورودی وجود دارد که اطلاعات مفید و جامعی درباره فرد مشهور را شامل نمی‌شود. این مشکل باعث تولید خروجی کم‌کیفیت می‌شود. این مورد از اختیارات اعضای گروه خارج است.

بنابر آنچه گفته شد، می‌توان این فاز را به مراحل زیر مرحله تقسیم کرد:

1. تصمیم‌گیری برای نحوه انجام فاز اول و دوم
2. انتخاب پلتفرم جهت استفاده از مدل‌های زبانی
3. ستاپ و آماده‌سازی محیط
4. پیاده‌سازی توابع کمکی و لاجیک اصلی
5. پیکربندی محیط
6. تست کردن استفاده از مدل‌های زبانی برای تعداد زیادی درخواست
7. استخراج متن از ساختار جیسون
8. استخراج پنج سوال و پاسخ از متن

حال به ترتیب، به توضیح این مراحل می‌پردازیم:

مرحله اول از فاز اول: تصمیم‌گیری برای نحوه انجام فاز اول و دوم

در این مرحله، دو روش برای انجام کامل این فاز وجود داشت:

1. استفاده از روش‌های مبتنی بر قانون (rule-based approaches)
2. استفاده از مدل‌های زبانی

با توجه به موارد زیر تصمیم بر این شد که از روش دوم، یعنی استفاده از مدل‌های زبانی برای این‌فاز استفاده کنیم:

- مدل‌های زبانی، به دلیل توانایی در درک و تولید زبان طبیعی، گزینه‌ای ایده‌آل برای تبدیل ساختارهای جیسون به متون روان و قابل‌فهم هستند. این مدل‌ها می‌توانند اطلاعات پراکنده در فیلدهای مختلف جیسون را به صورت خودکار ترکیب کرده و متونی منسجم تولید کنند که تمام جزئیات را پوشش دهد. همچنین، با توجه به ظرفیت بالای این مدل‌ها در پردازش زبان، متون تولیدشده از نظر روان‌بودن و خوانایی در سطح بالایی قرار دارند، حتی اگر ساختار جیسون ورودی پیچیده یا دارای فیلدهای نامتعارف باشد.
- یکی دیگر از مزایای کلیدی مدل‌های زبانی، توانایی آن‌ها در تولید سوالات متنوع و دقیق از متون است. این مدل‌ها می‌توانند با تحلیل محتوای متن، سوالاتی را طرح کنند که جنبه‌های مختلف اطلاعاتی را پوشش دهد، از جمله جزئیات شخصی، دستاوردها، و رویدادهای مهم زندگی افراد مشهور. همچنین، به‌دلیل انعطاف‌پذیری بالای مدل‌های زبانی، سوالات تولیدشده نه تنها از نظر تنوع، بلکه از نظر دقت و ارتباط با متن اصلی نیز از کیفیت مطلوبی برخوردار خواهند بود.
- علاوه بر این، استفاده از مدل‌های زبانی سرعت و مقیاس‌پذیری فرآیند را به‌طور چشمگیری افزایش می‌دهد. با توجه به حجم بالای داده‌های ورودی (ده هزار ساختار جیسون)، روش‌های مبتنی بر قانون نیازمند زمان و تلاش زیادی برای پوشش تمام حالات ممکن هستند، در حالی که مدل‌های زبانی می‌توانند به‌صورت خودکار و بدون نیاز به تنظیم دستی قوانین، خروجی‌های باکیفیت تولید کنند.

بنابر موارد بیان‌شده، تصمیم بر این شد که از مدل‌های زبانی برای استخراج متن از ساختار جیسون و استخراج سوال و پاسخ از متن استفاده کنیم.

حال به مرحله دوم از فاز اول می‌پردازیم.

مرحله دوم از فاز اول: انتخاب پلتفرم جهت استفاده از مدل‌های زبانی

در این مرحله، سه انتخاب پیش‌رو برای استفاده از مدل‌های زبانی داشتیم:

1. استفاده از پلتفرم Ollama جهت استفاده از مدل‌های زبانی بر بستر Google Colab
2. استفاده مستقیم از API مدل‌های زبانی (رایگان – تعداد محدود توکن)

3. استفاده از API پلتفرم متیس (Metis)

با توجه به موارد زیر، ترجیح دادیم از API پلتفرم متیس جهت استفاده از مدل‌های زبانی بهره ببریم:

1. پلتفرم متیس به‌عنوان یک سرویس داخلی، مزایای قابل‌توجهی برای پروژه‌های پردازش زبان طبیعی دارد. یکی از مهم‌ترین مزیت‌های آن، عدم نیاز به فیلترشکن برای دسترسی به API است که باعث می‌شود فرآیند توسعه و اجرای مدل‌ها بدون اختلال و با سرعت بالاتری انجام شود.
2. از نظر فنی، پلتفرم متیس امکانات مناسبی برای پردازش حجم بالای داده‌ها ارائه می‌دهد. با توجه به نیاز این پروژه به پردازش ده‌هزار ساختار جیسون و تولید پنجاه‌هزار جفت سوال-پاسخ، متیس از نظر مقیاس‌پذیری و پایداری گزینه مناسبی محسوب می‌شود.
3. عدم نیاز به سخت‌افزار پردازشی قوی یکی از مزایای دیگر استفاده از API است. لازم به ذکر است که استفاده از پلتفرم‌هایی مانند Ollama نیازمند سخت‌افزار پردازشی قوی برای استفاده از مدل‌زبانی است که انتخاب آن را با چالش همراه می‌کند.

همچنین در انتخاب مدل زبانی، تعدادی انتخاب داشتیم. با توجه به موارد زیر، ترجیح دادیم از مدل Gemini 2.5 Flash Lite استفاده کنیم:

1. استفاده از مدل Gemini 2.5 Flash Lite برای این پروژه به دلایل متعددی بهینه و منطقی بود. اولاً، این مدل به‌طور خاص برای پردازش حجم بالای داده‌های متنی با کارایی بالا طراحی شده است، که با نیاز این پروژه به پردازش ده‌هزار ساختار جیسون و تولید پنجاه‌هزار جفت سوال-پاسخ کاملاً همخوانی دارد. همچنین، این مدل از نظر سرعت و مصرف منابع بهینه‌سازی شده است، که امکان پردازش سریع و کم‌هزینه‌تر داده‌ها را در مقایسه با مدل‌های سنگین‌تر فراهم می‌کند. از آنجا که پروژه حاضر نیازمند پردازش انبوه داده‌ها بدون تأخیرهای محسوس بود، Gemini 2.5 Flash Lite گزینه‌ای ایده‌آل محسوب می‌شد.
2. علاوه بر این، Gemini 2.5 Flash Lite تعادلی مناسب بین دقت و کارایی برقرار می‌کند. با توجه به محدودیت‌های احتمالی در کیفیت برخی از داده‌های ورودی (ساختارهای جیسون با اطلاعات ناقص)، استفاده از یک مدل سبک‌وزن اما هوشمند مانند این مدل، امکان تولید متون روان و سوالات متنوع را حتی در شرایط داده‌های ناقص فراهم می‌کند.

با اینکه ترجیح دادیم از مدل مذکور استفاده کنیم، با توجه به پیکربندی که انجام شده است، این پیاده‌سازی قابلیت استفاده از تمام مدل‌های Gemini ،ChatGPT و تمام مدل‌های متن‌باز از طریق Ollama را خواهد داشت و پیاده‌سازی آن انجام شده است.

مرحله سوم از فاز اول: ستاپ و آماده‌سازی محیط

علیرغم اینکه تصمیم بر استفاده از API از پلتفرم Metis بود، گروه ما دو آپشن دیگر را نیز پیاده‌سازی کرده است. یعنی در فاز اول امکان استفاده از هر سه آپشن زیر برای ما وجود دارد و با توجه به پیکربندی، می‌توان یکی از آنها را انتخاب کرد:

1. استفاده از پلتفرم Ollama جهت استفاده از مدل‌های زبانی بر بستر Google Colab
2. استفاده مستقیم از API مدل‌های زبانی (رایگان – تعداد محدود توکن)
3. استفاده از API پلتفرم متیس (Metis)

پیاده‌سازی هر سه این موارد در فایل نوت‌بوک فاز اول موجود است.

مرحله چهارم از فاز اول: پیاده‌سازی توابع کمکی و لاجیک اصلی

در این مرحله تمام توابع کمکی، از جمله توابع ورودی و خروجی، نمایش اطلاعات، بارگذاری و ذخیره‌سازی فایل‌ها، توابع مربوط به کوئری زدن به مدل‌های زبانی متفاوت، ایجاد log و ... پیاده‌سازی شده است. در مراحل بعدی صرفاً از این توابع استفاده خواهد شد.

مرحله پنجم از فاز اول: پیکربندی محیط

از آنجایی که تصمیم‌های متنوعی برای انجام این فاز باید اتخاذ شود، نیاز به یک مرحله پیکربندی است تا تمامی آنها به صورت جامع پوشش داده شود. در این مرحله، تمامی آدرس‌های مقداردهی شده‌اند، توابع پیکربندی پلتفرم ollama و سایر مدل‌های زبانی نوشته شده است و... .

مرحله ششم از فاز اول: تست کردن استفاده از مدل‌های زبانی برای تعداد زیادی درخواست

برای اینکه از عملکرد مدل زبانی و پلتفرم آن اطمینان حاصل کنیم، بهتر است آن را برای تعداد زیادی از درخواست‌ها تست و ارزیابی کنیم. در این مرحله تعداد زیادی prompt تصادفی تولیدشده را به مدل زبانی می‌دهیم و خروجی آن را ارزیابی می‌کنیم. اجرای این مرحله قبل از تولید متن و سوال ضروری است.

مرحله هفتم از فاز اول: استخراج متن از ساختار جیسون

در این مرحله، با استفاده از توابع پیاده‌سازی‌شده در مرحله چهارم، سعی می‌کنیم برای هر ساختار جیسون، متن روان و با کیفیتی از آن استخراج کنیم. برای این کار، نیاز به یک prompt مناسب داریم که در آن تمام ملاحظاتی که مدل زبانی باید رعایت کند را قرار داده‌ایم.

پس از آن برای هر یک از هشت فایل ورودی پردازش تبدیل ساختار جیسون به متن را انجام می‌دهیم و خروجی را به ذخیره می‌کنیم. از آنجایی که این هشت فایل در برخی موارد با هم تفاوت دارند، برای پوشش این استثناها، رفتار متفاوتی با هر یک از آنها داریم.

نکته

با توجه به اینکه برخی از ساختارهای جیسون، فیلدهای خالی داشتند، یک پیش‌پردازش برای حذف آنها به صورت بازگشتی انجام شده است. همچنین از آنجایی که اطلاعات لینک‌ها در استخراج متن از ساختار جیسون کاربردی نیست و منجر به گمراهی مدل زبانی می‌شود، این موارد نیز طی یک مرحله پیش‌پردازش حذف شده است و یک ساختار جیسون اصلاح‌شده (refined) به مدل زبانی به عنوان ورودی داده می‌شود. همچنین از بعضی از فیلدهای ساختار جیسون که تاثیری مثبتی در خروجی ندارد، مانند مختصات جغرافیایی محل تولد و مرگ و...، صرف نظر شده است.

مرحله هشتم از فاز اول: استخراج سوال و پاسخ از متن

در این مرحله، مشابه مرحله قبل، ابتدا prompt مناسب برای تبدیل سوال به متن آماده می‌کنیم. سپس از خروجی مرحله هفتم استفاده می‌کنیم و از هر متن، 5 سوال به همراه پاسخ آن تولید می‌کنیم.

چند نمونه ورودی و خروجی

نمونه اول

ساختار جیسون اصلی


```
{
  "name":"کامبیز آتابای",
  "sex":"male",
  "nick-names":[

  ],
  "birth":{
        "date":"1939-02-02",
        "location":{
        "province":"تهران",
        "city":"تهران",
        "coordinates":{
        "latitude":"35.6895",
        "longitude":"51.3890"
        }
        }
  },
  "death":{
        "date":"",
```

```
        "location":{
        "province":"",
        "city":"",
        "coordinates":{
        "latitude":"",
        "longitude":""
        }
        },
        "tomb_location":{
        "province":"",
        "city":"",
        "coordinates":{
        "latitude":"",
        "longitude":""
        }
        }
},
"era":"دودمان پهلوی، جمهوری اسلامی ایران",
"occupation":[
        "مدیر فوتبال",
        "مربی"
],
"works":[
        "مدیر کل فنی و خدمات عمومی در دربار پهلوی",
        "رئیس دفتر فرح پهلوی در نیویورک",
        "دهمین رئیس فدراسیون فوتبال ایران",
        "ششمین رئیس کنفدراسیون فوتبال آسیا"
],
"events":[

],
```

```
  "image":[

"https://commons.wikimedia.org/wiki/Special:FilePath/Kambiz_Atabay.jpg"
  ]
}
```


ساختار جیسون اصلاح‌شده (refined)


```
{
  "name":"کامبیز آتابای",
  "sex":"male",
  "birth":{
        "date":"1939-02-02",
        "location":{
        "province":"تهران",
        "city":"تهران"
        }
  },
  "era":"دودمان پهلوی، جمهوری اسلامی ایران",
  "occupation":[
        "مدیر فوتبال",
        "مربی"
  ],
  "works":[
        "مدیر کل فنی و خدمات عمومی در دربار پهلوی",
        "رئیس دفتر فرح پهلوی در نیویورک",
        "دهمین رئیس فدراسیون فوتبال ایران",
        "ششمین رئیس کنفدراسیون فوتبال آسیا"
  ]
}
```


خروجی متنی از ساختار جیسون

کامبیز آتابای مردی است که در تاریخ ۱۳۱۷/۱۱/۱۳ در تهران متولد شده است. او در دوران دودمان پهلوی و جمهوری اسلامی ایران فعالیت داشته است. آتابای در حرفه‌های مدیر فوتبال و مربیگری مشغول بوده است. او سابقه فعالیت به عنوان مدیر کل فنی و خدمات عمومی در دربار پهلوی و رئیس دفتر فرح پهلوی در نیویورک را دارد. همچنین، کامبیز آتابای دهمین رئیس فدراسیون فوتبال ایران و ششمین رئیس کنفدراسیون فوتبال آسیا بوده است.

خروجی جفت سوال-پاسخ از متن


```
{
  "questions_and_answers":[
        {
        "id":1,
        "question":"کامبیز آتابای در چه تاریخی در تهران متولد شد؟",
        "answer":"کامبیز آتابای در تاریخ ۱۳۱۷/۱۱/۱۳ در تهران متولد شده است."
        },
        {
        "id":2,
        "question":"کامبیز آتابای در کدام دوران‌های سیاسی ایران فعالیت داشته است؟",
        "answer":"او در دوران دودمان پهلوی و جمهوری اسلامی ایران فعالیت داشته است."
        },
        {
        "id":3,
        "question":"کامبیز آتابای چه سمت‌هایی در دربار پهلوی داشته است؟",
        "answer":"او سابقه فعالیت به عنوان مدیر کل فنی و خدمات عمومی در دربار پهلوی و رئیس دفتر فرح پهلوی در نیویورک را دارد."
        },
        {
        "id":4,
      "question":"کامبیز آتابای در فوتبال ایران چه سمتی داشته است؟",
        "answer":"کامبیز آتابای دهمین رئیس فدراسیون فوتبال ایران بوده است."
        },
        {
        "id":5,
        "question":"کامبیز آتابای در فوتبال آسیا چه سمتی داشته است؟",
        "answer":"او ششمین رئیس کنفدراسیون فوتبال آسیا بوده است."
        }
  ]
}
```


نمونه دوم

ساختار جیسون اصلی

```
{

"url":"https://fa.wikipedia.org/wiki/%D9%85%D8%AC%D8%AA%D8%A8%DB%8C_%DA%AF%D9%84%DB%8C%D8%AC",
  "name":"مجتبی گلیج",
  "sex":"مرد",
  "sport":"کشتی",
  "birth":{
        "date":"۳ سال ۲۸) ۱۳۷۵ بهمن)",
        "place":"تنکابن"
  },
  "death":null,
  "height":"۱٫۸۳ متر) ۶ فوت ۰ اینچ)",
  "weight":null,

"image":"https://upload.wikimedia.org/wikipedia/commons/thumb/e/e4/Mojtaba_Goleij_%28cropped%29.JPG/330px-Mojtaba_Goleij_%28cropped%29.JPG",
  "teams":[

  ],
  "honors":[
        "مدال برنز قهرمانی کشتی جهان اسلو ۲۰۲۱",
        "مدال نقره بازی‌های آسیایی هانگژو ۲۰۲۲",
        "مدال نقره مسابقات قهرمانی آسیا بیشکک ۲۰۱۸",
        "مدال طلا مسابقات قهرمانی آسیا دهلی نو ۲۰۲۰",
        "مدال برنز مسابقات قهرمانی آسیا آستانا ۲۰۲۳",
        "مدال طلا بازی‌های همبستگی کشورهای اسلامی قونیه ۲۰۲۱",
        "مدال طلا قهرمانی زیر ۲۳ سال جهان بیدگوشچ ۲۰۱۷",
        "مدال طلا قهرمانی زیر ۲۳ سال جهان بوداپست ۲۰۱۹",
        "مدال طلا بازی‌های آسیایی داخل سالن عشق‌آباد ۲۰۱۷"
  ],
  "id":12,
  "label":"SAT",
  "label_2":"SAT"
}
```


ساختار جیسون اصلاح‌شده (refined)

```
{
  "name":"مجتبی گلیج",
  "sex":"مرد",
  "sport":"کشتی",
  "birth":{
        "date":"۳ بهمن ۱۳۷۵ (۲۸ سال)",
        "place":"تنکابن"
  },
  "height":"۱٫۸۳ متر (۶ فوت ۰ اینچ)",
  "honors":[
        "مدال برنز قهرمانی کشتی جهان اسلو ۲۰۲۱",
        "مدال نقره بازی‌های آسیایی هانگژو ۲۰۲۲",
        "مدال نقره مسابقات قهرمانی آسیا بیشکک ۲۰۱۸",
        "مدال طلا مسابقات قهرمانی آسیا دهلی نو ۲۰۲۰",
        "مدال برنز مسابقات قهرمانی آسیا آستانا ۲۰۲۳",
        "مدال طلا بازی‌های همبستگی کشورهای اسلامی قونیه ۲۰۲۱",
        "مدال طلا قهرمانی زیر ۲۳ سال جهان بیدگوشچ ۲۰۱۷",
        "مدال طلا قهرمانی زیر ۲۳ سال جهان بوداپست ۲۰۱۹",
        "مدال طلا بازی‌های آسیایی داخل سالن عشق‌آباد ۲۰۱۷"
  ]
}
```


خروجی متنی از ساختار جیسون

مجتبی گلیج کشتی‌گیر مرد ایرانی است که در تاریخ ۳ بهمن ۱۳۷۵ در تنکابن متولد شده است. قد او ۱٫۸۳ متر است. گلیج افتخارات متعددی در رشته کشتی کسب کرده است. او مدال برنز قهرمانی کشتی جهان در اسلو ۲۰۲۱، مدال نقره بازی‌های آسیایی هانگژو ۲۰۲۲، مدال نقره مسابقات قهرمانی آسیا در بیشکک ۲۰۱۸، مدال طلا مسابقات قهرمانی آسیا در دهلی نو ۲۰۲۰ و مدال برنز مسابقات قهرمانی آسیا در آستانا ۲۰۲۳ را در کارنامه دارد. همچنین، او مدال طلای بازی‌های همبستگی کشورهای اسلامی در قونیه ۲۰۲۱، مدال طلای قهرمانی زیر ۲۳ سال جهان در بیدگوشچ ۲۰۱۷ و بوداپست ۲۰۱۹، و مدال طلای بازی‌های آسیایی داخل سالن در عشق‌آباد ۲۰۱۷ را نیز به دست آورده است.

خروجی جفت سوال-پاسخ از متن


```
{
  "questions_and_answers":[
        {
        "id":1,
```

```
        "question":"مجتبی گلیج در چه سالی و در کدام شهر متولد شده است؟",
        "answer":"مجتبی گلیج در تاریخ ۳ بهمن ۱۳۷۵ در تنکابن متولد شده است."
        },
        {
        "id":2,
        "question":"قد مجتبی گلیج چقدر است؟",
        "answer":"قد او ۱٫۸۳ متر است."
        },
        {
        "id":3,
        "question":"مجتبی گلیج چه مدالی در قهرمانی کشتی جهان در اسلو ۲۰۲۱ کسب کرده است؟",
        "answer":"او مدال برنز قهرمانی کشتی جهان در اسلو ۲۰۲۱ را کسب کرده است."
        },
        {
        "id":4,
        "question":"کدام مدال در بازی‌های آسیایی هانگژو ۲۰۲۲ توسط مجتبی گلیج به دست آمده است؟",
        "answer":"او مدال نقره بازی‌های آسیایی هانگژو ۲۰۲۲ را به دست آورده است."
        },
        {
        "id":5,
        "question":"مجتبی گلیج در مسابقات قهرمانی آسیا در دهلی نو ۲۰۲۰ چه مدالی کسب کرد؟",
        "answer":"او مدال طلای مسابقات قهرمانی آسیا در دهلی نو ۲۰۲۰ را کسب کرد."
        }
  ]
}
```


نمونه سوم

ساختار جیسون اصلی


```
{
  "name":"حکیم ابوالقاسم فردوسی توسی",
  "sex":"",
  "nick-names":[
        "فردوسی"
  ],
  "birth":{
```

```
        "date":"۳۲۹ خ.ه ۳۱۹،ق.ه",
        "location":{
        "province":"خراسان",
        "city":"توس",
        "coordinates":{
        "latitude":"",
        "longitude":""
        }
        }
},
"death":{
        "date":"پیش از۴۱۱ ه.ق،۳۹۷ خ.ه",
        "location":{
        "province":"خراسان",
        "city":"توس",
        "coordinates":{
        "latitude":"",
        "longitude":""
        }
        },
        "tomb_location":{
        "province":"خراسان",
        "city":"توس",
        "coordinates":{
        "latitude":"",
        "longitude":""
        }
        }
},
"era":"قرن چهارم",
"occupation":[
        "سخن سرای",
        "سرایندهٔ"
],
"works":[
        "شاهنامه"
],
```

```
  "events":[
          {
          "title":"روز بزرگداشت فردوسی",
          "start_date":"۲۵ اردیبهشت",
          "end_date":"",
          "location":{
          "province":"",
          "city":"",
          "coordinates":{
          "latitude":"",
          "longitude":""
          }
          },
          "related_people":[

        ],
          "description":""
          }
  ],
  "image":{
          "young":"",
          "adult":"https://api.ganjoor.net/api/ganjoor/poet/image/ferdousi.gif",
          "tomb":""
  },
  "sample_id":3,
  "quality_1":"Bad",
  "quality_2":"Good",
  "created_at_1":"2025-05-03T16:35:59.878040Z",
  "created_at_2":"2025-05-03T08:33:32.540506Z",
  "updated_at_1":"2025-05-03T16:35:59.878040Z",
  "updated_at_2":"2025-05-03T08:33:32.540530Z",
  "lead_time_1":6.867,
  "lead_time_2":3.787,
  "created_at_3":"2025-05-04T13:59:47.130268Z",
  "updated_at_3":"2025-05-04T13:59:47.130294Z",
  "lead_time_3":6.202
}
```

ساختار جیسون اصلاح‌شده (refined)


```
{
  "name":"حکیم ابوالقاسم فردوسی توسی",
  "nick-names":[
        "فردوسی"
  ],
  "birth":{
        "date":"۳۲۹ ه.خ ۳۱۹،ه.ق",
        "location":{
        "province":"خراسان",
        "city":"توس"
        }
  },
  "death":{
        "date":"پیش از۴۱۱ ه.ق،۳۹۷ ه.خ",
        "location":{
        "province":"خراسان",
        "city":"توس"
        },
        "tomb_location":{
        "province":"خراسان",
        "city":"توس"
        }
  },
  "era":"قرن چهارم",
  "occupation":[
        "سخن سرای",
        "سرایندهٔ"
  ],
  "works":[
        "شاهنامه"
  ],
  "events":[
        {
        "title":"روز بزرگداشت فردوسی",
        "start_date":"۲۵ اردیبهشت"
```

```
        }
    ]
}
```

خروجی متنی از ساختار جیسون

حکیم ابوالقاسم فردوسی توسی، که با نام فردوسی نیز شناخته می‌شود، سخن‌سرا و سرایندهٔ ایرانی بود. او در سال ۳۲۹ هجری قمری (۳۱۹ هجری خورشیدی) در شهر توس، واقع در استان خراسان، چشم به جهان گشود. فردوسی در دوران قرن چهارم هجری می‌زیست و اثر مشهور او شاهنامه است. او پیش از سال ۴۱۱ هجری قمری (۳۹۷ هجری خورشیدی) در شهر توس، استان خراسان، درگذشت و آرامگاه وی نیز در شهر توس، استان خراسان قرار دارد. روز بزرگداشت فردوسی در ۲۵ اردیبهشت برگزار می‌شود.

خروجی جفت سوال-پاسخ از متن

```
{
  "questions_and_answers":[
        {
        "id":1,
        "question":"حکیم ابوالقاسم فردوسی در کدام شهر متولد شد؟",
        "answer":"او در شهر توس، واقع در استان خراسان، چشم به جهان گشود."
        },
        {
        "id":2,
        "question":"نام اثر مشهور فردوسی چیست؟",
        "answer":"اثر مشهور او شاهنامه است."
        },
        {
        "id":3,
        "question":"فردوسی در کدام قرن هجری می‌زیست؟",
        "answer":"فردوسی در دوران قرن چهارم هجری می‌زیست."
        },
        {
```

```
        "id":4,
        "question":"آرامگاه فردوسی در کدام شهر قرار دارد؟",
        "answer":"آرامگاه وی نیز در شهر توس، استان خراسان قرار دارد."
        },
        {
        "id":5,
        "question":"روز بزرگداشت فردوسی چه تاریخی است؟",
        "answer":"روز بزرگداشت فردوسی در ۲۵ اردیبهشت برگزار می‌شود."
        }
  ]
}
```


پیاده‌سازی تمام بخش‌های این فاز در فایل نوت‌بوک nlp_hw#2_phase_1.ipynb موجود است. همچنین خروجی مرحله هفتم (استخراج متن از ساختار جیسون) و مرحله هشتم (اسختراج جفت سوال-پاسخ از متن) در پوشه mashahir_data/output_phase_1 قرار دارد.

فاز ۲: ساخت مجموعه داده های ارزیابی

۲.۱ مقدمه

در فاز دوم این تمرین، هدف طراحی و تهیه‌ی یک مجموعه داده‌ی ارزیابی مستقل (برای مجموعه داده‌ی مشاهیر) جهت سنجش دقیق‌تر عملکرد مدل‌های زبانی در فازهای بعدی بود. بر اساس دستور کار ارائه‌شده، لازم بود که مجموعه‌ای شامل ۵۰ سؤال انسانی (در گروه ما 67 سؤال انسانی) طراحی شود که محتوای آن‌ها در دامنه داده‌های تمرین قرار بگیرد، اما در فرآیند آموزش مدل‌ها مورد استفاده قرار نگرفته باشند.

ابتدا با بررسی دقیق دامنه محتوایی داده‌های تمرین (اعم از متون استخراج‌شده یا تولیدشده)، سعی شد درک عمیقی از مفاهیم، موضوعات اصلی و اطلاعات نهفته در آن‌ها به دست آید. بر این اساس، طراحی سؤالات در دو دسته کلی انجام شد:

1.سؤالات کلی در دامنه داده‌ها:

این سؤالات به نحوی طراحی شدند که مدل را به تولید پاسخ‌هایی نیازمند به استنتاج یا ترکیب اطلاعات وادار کنند. نمونه‌هایی از این نوع سؤالات به صورت مفهومی در رابطه با حوزه‌ی موضوعی داده‌ها طراحی شدند تا توانایی مدل در درک کلی محتوا و کاربرد اطلاعات را بسنجند.

2.سؤالات استخراج‌شده از متن داده‌ها (غیر تکراری با داده آموزش):

در این بخش، با مرور دقیق متن داده‌ها، سؤالاتی طراحی شدند که از اطلاعات مشخص موجود در داده‌ها برگرفته شده‌اند ولی در هیچ‌یک از مراحل آموزش مدل استفاده نشده‌اند. این کار با هدف بررسی دقت بازیابی اطلاعات مدل و تشخیص توانایی آن در پاسخ‌گویی به جزئیات خاص انجام گرفت.

در فرآیند طراحی سؤالات، نکات زیر به دقت رعایت شد:

- عدم تکرار با داده‌های آموزش به‌منظور جلوگیری از حافظه‌محور بودن پاسخ مدل.
- پوشش متوازن جنبه‌های مختلف محتوای داده‌ها (اعم از اطلاعات عمومی، جزئیات تخصصی، روابط علی و کاربردی).
- تنوع ساختاری در قالب سؤال‌ها (سؤالات باز، بسته، و دارای چند لایه اطلاعاتی).
- حفظ زبان طبیعی و روان برای طبیعی‌تر بودن تعامل با مدل.

در نهایت، مجموعه‌ای شامل 67 سؤال انسانی طراحی‌شده تهیه شد که می‌تواند به عنوان یک مرجع مستقل و معتبر جهت ارزیابی مدل‌های زبانی مورد استفاده قرار گیرد. این سؤالات در قالب فایل جیسون ذخیره شده‌اند و به‌صورت دستی تولید شده‌اند تا از هرگونه شباهت یا استخراج ماشینی جلوگیری شود.

۲.۲ روند کلی

در این مرحله از تمرین، هدف استخراج 67 سوال مستقل با حداقل شباهت به سوالات موجود در مجموعه داده آموزشی است. ابتدا از خروجی فاز اول، که هشت فایل جیسون حاوی متون داده‌ها به همراه پنج سوال برای هر متن است، استفاده شده است. اول از همه برای هر فایل مواردی که طول متن داده کمتر مساوی 160 است را جدا کرده و بعد از آن نسبت به حجم داده در هر فایل به صورت تصادفی بین 10 الی 100 متن به همراه سوالاتش انتخاب شد. در نهایت 500 متن به همراه سوالاتش از تمامی داده‌هایی که طول متن آن کمتر مساوی 160 است، استخراج شده است.

در مرحله بعد به صورت دستی و انسانی هر متن با سوالاتش مورد بررسی قرار گرفت و یک سوال مستقل و متفاوت از 5 سوال آن متن به طوریکه روی متن تعریف شده باشد، طراحی شد. بنابراین 500 سوال از 500 متن انتخابی به دست آمد و در یک لیست قرار گرفت. بعد از آن تمامی داده‌های هشت فایل جیسون را در کنار هم قرار داده و تنها آن‌هایی که طول متن‌شان کمتر مساوی 160 است، نگه داشته و بقیه داده‌ها حذف شدند. سپس تنها 5 سوال مربوط به هر داده‌ی باقی مانده استخراج شده و به لیست دیگری اضافه شده است.

حال یک لیست از 500 سوال طرح شده به صورت دستی و انسانی داریم و یک لیست شامل تمامی سوالات مجموعه داده‌ی آموزش داریم. هدف آن است سوالاتی از این 500 سوال لیست اول انتخاب کنیم که کمترین شباهت را نسبت به تمامی سوالات لیست دوم داشته باشد.

تابعی طراحی شده است که هدف آن این است که تک تک سوالات لیست اول را با تمامی سوالات لیست دوم مقایسه کند و یک عدد بین 0 تا 100 به عنوان میزان شباهت آن سوال نسبت به سوالات مجموعه داده‌ی آموزش بدهد و اگر میزان شباهت کمتر مساوی 20 بود، به صورت سورت شده از کمترین میزان شباهت تا بیشترین در خروجی چاپ کند. در نهایت 67 سوال از سوالات خروجی که مناسب‌تر هستند و تمامی ویژگی‌های خواسته شده را دارد به صورت دستی و انسانی انتخاب می‌شود و به همراه متن متناظر و پاسخ سوال در یک فایل اکسل قرار می‌گیرد. این سوالات نهایی انتخاب شده در فاز دوم برای ارزیابی مدل در فازهای بعدی است. سپس فایل جیسون متناظر فایل اکسل تولید می‌شود.

۲.۳ جزئیات کار

حال به صورت کلی به شرح جزئیات کدهای این فاز و نحوه اجرای آن می‌پردازیم:

کد short_data_sampler.py:

این بخش از کد با هدف مرور و بررسی نمونه‌های کوتاه متنی و نمایش سؤالات طراحی‌شده برای آن‌ها پیاده‌سازی شده است. فرآیند کلی اجرا به شکل زیر است:

در ابتدا، فایل جیسون شامل مجموعه‌ای از متون و سؤالات مربوط به هر متن بارگذاری می‌شود. این فایل‌ها با ساختار مشابه و فرمت UTF-8 ذخیره شده‌اند. پس از بارگذاری، تنها آن دسته از نمونه‌ها انتخاب می‌شوند که طول متن آن‌ها کمتر یا مساوی ۱۶۰ کاراکتر باشد. هدف از این فیلترگذاری، تمرکز روی متون خلاصه و ساده برای تحلیل سریع سؤالات طراحی‌شده است.

از میان متون فیلترشده، به‌صورت تصادفی حداکثر بین 10 تا 100 نمونه انتخاب می‌شود (اگر تعداد کل کمتر باشد، همان تعداد موجود انتخاب می‌شود). این مرحله برای بررسی نمونه‌ای از داده‌ها بدون بررسی کل مجموعه انجام می‌گیرد. در نهایت، برای هر یک از نمونه‌های انتخاب‌شده:

- متن اصلی نمایش داده می‌شود.
- سپس سؤالات مربوط به آن متن (در صورت وجود) چاپ می‌شوند.

این کد امکان مشاهده و مرور سریع نمونه‌های کوتاه متنی و بررسی کیفیت سؤالات طراحی‌شده برای آن‌ها را فراهم می‌کند. همچنین می‌تواند به‌عنوان ابزار پشتیبان برای بازبینی کیفی یا نمونه‌برداری دستی از داده‌ها مورد استفاده قرار گیرد.

کد short_q_filter.py:

این قطعه کد برای استخراج خودکار سؤالات مربوط به متون با طول کوتاه (حداکثر ۱۶۰ کاراکتر) از فایل‌های جیسون طراحی شده است. این عملیات به منظور آماده‌سازی، پالایش یا تحلیل کیفی سؤالات طراحی‌شده روی داده‌های متنی انجام می‌شود.

ابتدا فایل جیسون مشخص‌شده را بارگذاری می‌کند. هر ورودی شامل یک متن و مجموعه‌ای از سؤالات و پاسخ‌ها است. تنها نمونه‌هایی در نظر گرفته می‌شوند که طول متن توصیفی آن‌ها حداکثر ۱۶۰ کاراکتر باشد. این محدودیت به صورت پارامتر max_length تعریف شده و قابل تغییر است. برای هر ورودی واجد شرایط (یعنی متنی با طول کمتر از ۱۶۰ کاراکتر)، تمام سؤالات غیرخالی از بخش questions_and_answers استخراج و در یک

لیست جمع‌آوری می‌شوند. در پایان، تمام سؤالات استخراج‌شده به صورت فهرست‌شده در خروجی چاپ می‌شوند.

این کد می‌تواند برای اهداف زیر مورد استفاده قرار گیرد:

- مرور سریع سؤالات مرتبط با متون کوتاه به‌منظور تحلیل کیفیت طراحی آن‌ها.
- استخراج نمونه‌های خاص جهت ارزیابی یا مصورسازی.
- بررسی آماری یا کیفی سؤالات در فازهای مختلف طراحی مجموعه ارزیابی.

کد sentence_similarity_fa.py:

هدف از این ماژول، ارائه یک سیستم ترکیبی برای سنجش میزان شباهت بین دو جمله فارسی است. این سامانه با ترکیب روش‌های مختلف سطح واژگانی، آماری، کاراکتری و معنایی، یک امتیاز نهایی از شباهت بین دو جمله تولید می‌کند. این امتیاز می‌تواند در کاربردهایی مانند تشخیص سؤالات تکراری، ارزیابی تنوع سؤالات، یا پالایش داده‌های آموزشی و ارزیابی استفاده شود.

از کتابخانه‌ی hazm برای نرمال‌سازی، توکن‌سازی، حذف توقف‌واژه‌ها و ریشه‌یابی (lemmatization) استفاده شده است. این مرحله نقش کلیدی در آماده‌سازی داده‌های متنی فارسی برای پردازش دارد و تضمین می‌کند که روش‌های بعدی روی نسخه‌ی یکپارچه و تمیز از متن اعمال شوند.

شش روش مختلف برای محاسبه شباهت دو جمله پیاده‌سازی شده‌اند:

- Lexical Overlap: شباهت بر اساس هم‌پوشانی واژگان (نسبت اشتراک کلمات پس از پیش‌پردازش).
- TF-IDF Similarity: شباهت آماری واژگانی با استفاده از وزن‌دهی TF-IDF و محاسبه شباهت کسینوسی.
- Bag-of-Words (BoW) Similarity: شباهت ساده‌ی بر پایه شمارش واژگان بدون در نظر گرفتن وزن.
- N-gram Overlap: شباهت بر اساس هم‌پوشانی n-gramهای واژگانی (پیش‌فرض: bigram).
- Character-Level Similarity: شباهت سطح کاراکتری با استفاده از تابع SequenceMatcher (مناسب برای تشخیص تغییرات کوچک نوشتاری).
- Semantic Similarity (SBERT): محاسبه شباهت معنایی با استفاده از مدل BERT فارسی (ParsBERT) از طریق کتابخانه sentence-transformers. این روش از دقیق‌ترین و قدرتمندترین روش‌های موجود است.

هر روش یک امتیاز عددی بین ۰ تا ۱ تولید می‌کند. این امتیازها با وزن‌های مشخصی ترکیب می‌شوند. وزن‌ها نشان‌دهنده اهمیت نسبی هر روش در محاسبه نهایی هستند. به‌طور خاص، وزن بالاتر به شباهت معنایی (SBERT) و TF-IDF داده شده که نشانه اعتماد بیشتر به این معیارهاست. نتیجه نهایی یک عدد بین ۰ تا ۱۰۰ است که بیانگر میزان شباهت بین دو جمله است.

کاربردهای بالقوه این ماژول:

- تشخیص سؤالات مشابه یا تکراری در مجموعه داده‌ها.
- ارزیابی میزان تفاوت سؤالات ارزیابی با داده‌های آموزش برای اطمینان از استقلال داده‌ها.
- تحلیل تنوع زبانی در طراحی سؤالات.
- فیلتر کردن نمونه‌های مشابه برای افزایش تنوع در داده‌های ارزیابی.

کد compare_question_lists_fa.py:

این ماژول طراحی شده است تا از میان یک لیست از سؤالات، آن‌هایی را که کمترین شباهت معنایی و واژگانی را با لیست مرجع دارند، استخراج کند. این فرآیند در زمینه‌هایی نظیر ارزیابی تنوع، فیلتر سؤالات تکراری، و ساخت مجموعه ارزیابی مستقل کاربرد دارد.

- list_a: لیستی از سؤالات کاندید (مثلاً سؤالات ارزیابی جدید).
- list_b: لیستی از سؤالات مرجع (مثلاً سؤالات آموزش).
- threshold: آستانه‌ای برای شباهت جمله‌ای؛ پیش‌فرض ۲۰٪. تنها سؤالاتی که میانگین شباهت‌شان با کل سؤالات مرجع کمتر از این آستانه باشد انتخاب می‌شوند.

برای هر سؤال در لیست A شباهت آن با تمام سؤالات لیست B محاسبه می‌شود و میانگین این شباهت‌ها در نظر گرفته می‌شود. تنها آن دسته از سؤالاتی که میانگین شباهت آن‌ها با لیست مرجع کمتر از مقدار آستانه باشد، در خروجی قرار می‌گیرند. سؤالات خروجی به‌صورت صعودی بر اساس امتیاز شباهت مرتب می‌شوند. یعنی سؤالاتی که بیشترین تفاوت معنایی با داده‌های مرجع دارند در بالای لیست قرار می‌گیرند.

کاربردها و مزایا:

تولید سؤالات متمایز برای ارزیابی مدل‌های زبانی، بدون تداخل با داده‌های آموزش.

افزایش تنوع معنایی در مجموعه سؤالات با حذف موارد تکراری یا مشابه.

تحلیل خودکار شباهت معنایی بین دو مجموعه متنی با سرعت و دقت بالا.

کدهای xlsx_to_json_p1.py و xlsx_to_json_p2.py:

هدف از این دو اسکریپت، تبدیل ساختار یافته داده‌های موجود در فایل Excel به فرمت JSON و سپس استخراج فقط بخش سؤالات از فایل خروجی است. این عملیات به منظور ساده‌سازی پردازش داده‌ها، یکپارچه‌سازی قالب فایل‌ها و آماده‌سازی ورودی برای تحلیل‌های بعدی طراحی شده است.

اسکریپت اول ابزار قابل اعتماد برای تبدیل دستی یا نیمه‌خودکار داده‌های طراحی‌شده در اکسل به ساختار JSON برای استفاده در مدل‌های زبانی، ارزیابی‌ها یا سیستم‌های هوشمند است.

مزایا و کاربرد نهایی این دو ابزار:

- تبدیل سریع و بدون خطای داده‌های طراحی‌شده در اکسل به قالب JSON استاندارد.
- استخراج ساختارمند تنها سؤالات برای تحلیل‌های معنایی یا شباهت.
- یکپارچه‌سازی مراحل جمع‌آوری داده تا پیش‌پردازش نهایی.
- مناسب برای فاز ارزیابی یا تولید داده برای مدل‌های NLP.

فاز ۳: آموزش مدل زبانی GLOT500

۳.۱ آماده‌سازی و تحلیل مجموعه داده‌ها

مرحله آموزش با تحلیل کامل ساختار مجموعه داده‌ها برای درک ویژگی‌های پیکره متنی فارسی ما آغاز می‌شود. از استخراج اولیه مجموعه داده‌ها، ۵۲۰۳۶ جفت سوال-پاسخ مشتق شده از ۱۰۴۱۰ سند متنی به دست آمده است. این پیکره متنی قابل توجه، پایه و اساس غنی برای آموزش مدل بازیابی ما فراهم می‌کند.

نتایج تحلیل آماری مجموعه داده:

- حداکثر طول سوال: ۱۵۳ کاراکتر
- میانگین طول سوال: ۴۷.۷۵ کاراکتر
- حداکثر طول متن: ۵۸۵۲ کاراکتر
- میانگین طول متن: ۴۵۱.۵۹ کاراکتر

درک این آمار برای تعیین طول توالی مناسب (appropriate sequence length) و نیازهای حافظه در طول آموزش بسیار مهم است. تنوع گسترده در طول متن (از بسیار کوتاه تا نسبتاً بلند) مستلزم بررسی دقیق نحوه مدیریت موثر این تنوع است.

۳.۲ استراتژی فیلتر کردن داده‌ها

با توجه به محدودیت‌های محاسباتی و بحث در گروه تلگرامی درسی NLP در مورد هدف قرار دادن تقریباً ۱۰۰۰۰ نمونه برای آموزش مؤثر، ما یک رویکرد فیلتر کردن استراتژیک را پیاده‌سازی کردیم. فیلتر کردن بر اساس محدودیت‌های طول متن بود تا پردازش مداوم و الزامات محاسباتی قابل مدیریت تضمین شود.

ما با اعمالی فیلتر بر اساس آستانه‌های حداکثر طول مختلف آزمایش کردیم:

- MAX_LENGTH = ۵۱۲ منجر به ۳۸۱۵۶ نمونه شد.
- MAX_LENGTH = ۲۵۶ منجر به ۲۵۹۱۱ نمونه شد.
- MAX_LENGTH = ۱۶۰ منجر به ۱۳۳۱۶ نمونه شد.

تصمیم نهایی برای استفاده از MAX_LENGTH = ۱۶۰ برای ایجاد تعادل بین اندازه مجموعه داده‌ها و کارایی محاسباتی گرفته شد و در نهایت ۱۳۳۱۶ جفت سوال-متن (۱۳۳۱۶ سوال و ۲۶۶۶ متن) برای آموزش فراهم شد. این تصمیم، ملاحظات عملی را که باید هنگام کار با مجموعه داده‌های دنیای واقعی و منابع محاسباتی محدود در نظر گرفته شود، نشان می‌دهد.

۳.۳ طراحی معماری مدل

هسته اصلی رویکرد ما بر معماری دو-رمزگذار (dual-encoder architecture) مبتنی بر مدل پایه GLOT500 متمرکز است. GLOT500 به ویژه برای این کار مناسب است زیرا یک مدل چندزبانه است که زبان فارسی را در داده‌های آموزشی خود گنجانده و پایه‌ای قوی برای کار بازیابی تخصصی ما فراهم می‌کند.

اجزای معماری دو-رمزگذار:

- رمزگذار پایه (Base Encoder): مدل ترنسفورمر GLOT500 که در هاگینگ فیس با نام cis-lmu/glot500-base موجود است.
- سر تصویر (Projection Head): نگاشت لایه خطی از hidden_size به بعد۲۵۶
- استراتژی ادغام (Pooling Strategy): استخراج نمایش توکن CLS

طراحی دو-رمزگذار به ما این امکان را می‌دهد که سوالات و متون را به طور مستقل رمزگذاری کنیم و در عین حال روابط شباهت معنادار بین آنها را از طریق یادگیری مقابله‌ای (contrastive learning) یاد بگیریم. سر تصویر ابعاد را کاهش می‌دهد در حالی که روابط معنایی را حفظ می‌کند و جاسازی‌ها را برای محاسبه شباهت کارآمدتر می‌کند.

۳.۴ پیش آموزش مدل زبان ماسک‌شده (Masked Language Model)

قبل از پیاده‌سازی یادگیری مقابله‌ای، یک مرحله پیش آموزش MLM اختیاری اما توصیه‌شده را در نظر گرفتیم. این مرحله برای تطبیق بهتر مدل GLOT500 با ویژگی‌های خاص پیکره متنی فارسی ما عمل می‌کند.

پیکربندی پیش آموزش MLM:

- Masking probability: 15%
- Training epochs: 2
- Batch size: 8
- Learning approach: Standard MLM objective

پیش آموزش MLM به مدل کمک می‌کند تا الگوهای زبانی و واژگان خاص مجموعه داده‌های ما را بهتر درک کند و پایه مناسب‌تری برای مرحله یادگیری مقابله‌ای بعدی ایجاد کند. این رویکرد دو مرحله‌ای اغلب منجر به عملکرد نهایی بهتری در مقایسه با تنظیم دقیق مستقیم می‌شود.

۳.۵ پیاده‌سازی یادگیری مقابله‌ای (Contrastive Learning) (Implementation)

قلب رویکرد آموزشی ما در یادگیری مقابله‌ای نهفته است که به مدل می‌آموزد تا جاسازی‌های مشابهی را برای جفت‌های سوال-متن مرتبط از نظر معنایی ایجاد کند و در عین حال جفت‌های غیرمرتبط را از هم جدا کند.

تابع زیان مقابله‌ای: تابع زیان از شباهت کسینوسی با مقیاس‌بندی دما (temperature scaling) استفاده می‌کند:

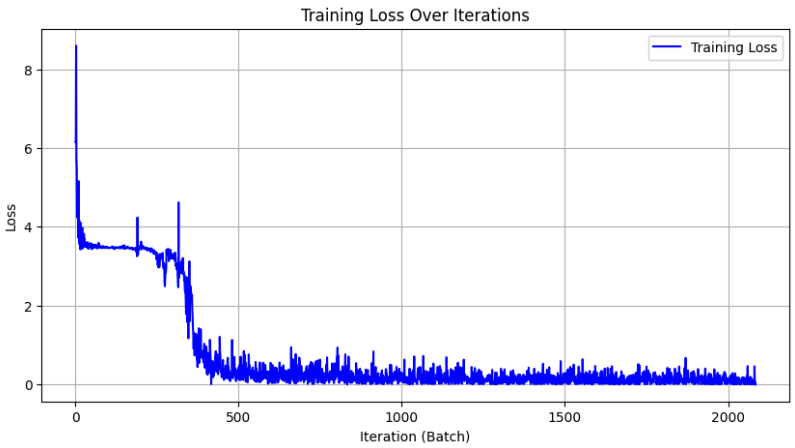
- Temperature parameter: 0.05 (controls the sharpness of the similarity distribution)
- Objective: Maximize similarity between related question-text pairs
- Negative sampling: In-batch negative sampling approach

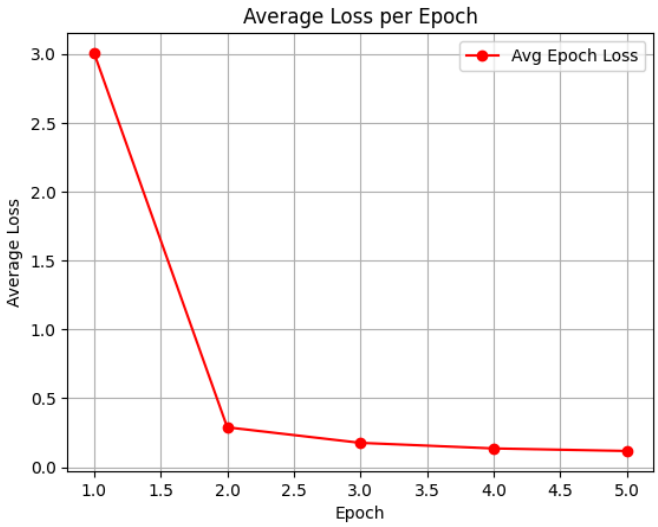
پیکربندی آموزش:

- نرخ یادگیری: 2e-5 (نرخ محافظه‌کارانه برای جلوگیری از فراموشی فاجعه‌بار)
- بهینه‌ساز: AdamW (کاهش وزن را به طور مؤثر مدیریت می‌کند)
- تعداد epochs یا همان دوره‌ها: 5
- Batch size (اندازه دسته): 32 (بهینه‌شده برای استفاده از حافظه GPU به اندازه 12.5/15.0 گیگابایت)

۳.۶ پیشرفت آموزش و تحلیل تلفات

فرآیند آموزش ویژگی‌های همگرایی عالی را نشان داد، به طوری که تلفات از دوره اول تا دوره‌های بعدی به طور چشمگیری کاهش یافت:





پیشرفت تلفات دوره به دوره:

- دوره ۱: ۳.۰۰۶۶ (کاهش اولیه بالا با یادگیری ساختار وظیفه توسط مدل)
- دوره ۲: ۰.۲۸۹۲ (بهبود قابل توجه با ظهور الگوها)
- دوره ۳: ۰.۱۷۶۴ (بهبود مداوم جاسازی‌ها)
- دوره ۴: ۰.۱۳۵۸ (نزدیک شدن به همگرایی)
- دوره ۵: ۰.۱۱۷۳ (پایدار، کاهش کم که نشان‌دهنده یادگیری خوب است)

این مسیر تلفات نشان می‌دهد که مدل با موفقیت یاد گرفته است که بین جفت‌های متن-سوال مرتبط و غیرمرتبط تمایز قائل شود، و افت شدید اولیه نشان می‌دهد که نمایش‌های GLOT500 از قبل آموزش دیده، نقطه شروع قوی برای سازگاری بوده‌اند.

منحنی‌های آموزش، چندین بینش مهم در مورد فرآیند یادگیری را آشکار می‌کنند. کاهش سریع اولیه نشان می‌دهد که مدل به سرعت ساختار وظیفه اساسی را درک می‌کند، در حالی که بهبود تدریجی و مداوم نشان می‌دهد که روابط معنایی جزئی در طول فرآیند آموزش در حال یادگیری هستند.

فاز ۴: خروجی گرفتن از مدل‌ها (تولید و ارزیابی خروجی مدل)

۴.۱ طراحی چارچوب ارزیابی

مرحله ۴ بر ارزیابی سیستماتیک مدل آموزش‌دیده ما در برابر روش‌های پایه تعیین‌شده تمرکز دارد. ما یک چارچوب ارزیابی جامع طراحی کردیم که سه رویکرد مختلف برای بازیابی متن را مقایسه می‌کند و به ما امکان می‌دهد تا سهم خاص رویکرد تنظیم دقیق خود را درک کنیم.

روش‌های ارزیابی مقایسه‌شده:

1. بازیابی TF-IDF: رویکرد سنتی مبتنی بر کلمات کلیدی
2. GLOT500 Zero-Shot: مدل از پیش آموزش‌دیده بدون آموزش مختص به وظیفه
3. GLOT500 تنظیم‌شده دقیق: مدل آموزش‌دیده تقابلی ما (Fine-tuned GLOT500)

این مقایسه چندوجهی، بینش‌هایی را در مورد اثربخشی رویکردهای عصبی در مقابل روش‌های سنتی و ارزش ویژه افزوده شده توسط آموزش تطبیق دامنه ما ارائه می‌دهد.

۴.۲ پیاده‌سازی مدل پایه TF-IDF

Baseline یا مدل پایه TF-IDF به عنوان معیار بازیابی اطلاعات سنتی ما عمل می‌کند. این رویکرد نشان دهنده روش استانداردی است که در بسیاری از کاربردهای عملی قبل از ظهور روش‌های بازیابی عصبی استفاده می‌شد.
پیکربندی TF-IDF:

- بردارسازی: TF-IDF استاندارد با پارامترهای پیش‌فرض
- معیار شباهت: شباهت کسینوسی
- مکانیسم بازیابی: رتبه‌بندی Top-k بر اساس امتیازات شباهت

TF-IDF یک مبنای قوی ارائه می‌دهد زیرا روابط آماری مهم بین عبارات پرس‌وجو و محتوای سند را ثبت می‌کند و آن را به ویژه برای تطابق دقیق کلمات کلیدی و پرس‌وجوهای سنگین با اصطلاحات مؤثر می‌سازد.

۴.۳ تنظیمات ارزیابی مدل عصبی

هر دو رویکرد عصبی (zero-shot و fine-tuned) از یک خط لوله کدگذاری و بازیابی پیروی می‌کنند، با این تفاوت کلیدی که وزن‌های مدل اساسی مورد استفاده برای نمایش متن هستند.

فرآیند تولید Embedding (جاسازی):

- توکن‌سازی با توکن‌ساز GLOT500
- Forward pass با مدل‌های رمزگذار مربوطه
- استخراج توکن CLS برای نمایش در سطح جمله
- تصویرسازی (Projection) از طریق لایه خطی آموخته‌شده (برای مدل تنظیم‌شده دقیق)

محاسبه شباهت:

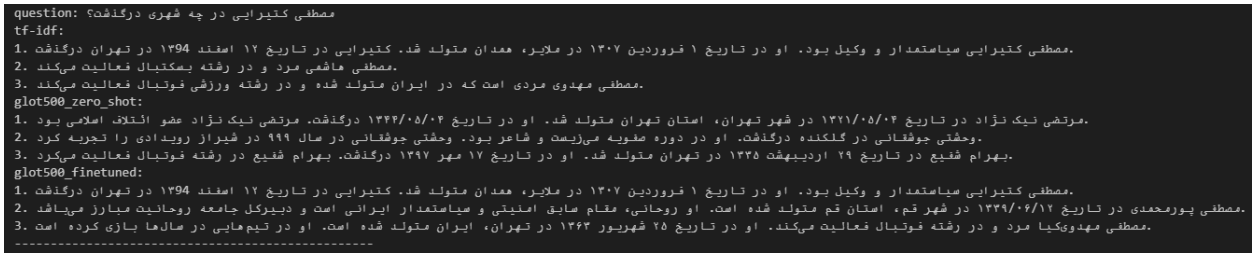
- متریک: شباهت کسینوسی بین جاسازی‌های پرس‌وجو و سند (query and document embeddings)
- رتبه‌بندی: انتخاب k=3 برتر بر اساس امتیازات شباهت
- استنتاج: پردازش دسته‌ای برای کارایی

۴.۴ تحلیل و تفسیر نتایج

نتایج ارزیابی تفاوت‌های آشکاری را بین سه رویکرد نشان می‌دهد و نقاط قوت و ضعف هر روش را برای بازیابی متن فارسی برجسته می‌کند.

تحلیل مطالعه موردی:

با نگاهی به اولین نمونه پرس‌وجو "مصطفی کتیرایی در چه شهری درگذشت؟"، ما الگوهای بازیابی متمایزی را مشاهده می‌کنیم:



- TF-IDF: با موفقیت، احتمالاً به دلیل تطبیق دقیق نام، ابتدا مرتبط‌ترین سند را بازیابی می‌کند، اما نتایج بعدی ارتباط کمتری را نشان می‌دهند.
- Zero-Shot GLOT500: با بازیابی اسناد مربوط به مرگ و مکان‌ها، درک معنایی را نشان می‌دهد، اما برای شخص خاص فاقد دقت است.

- GLOT500 تنظیم‌شده دقیق: دقت TF-IDF را با درک معنایی بهبود یافته ترکیب می‌کند و چندین ورودی مرتبط "مصطفی" (مصطفی) را رتبه‌بندی می‌کند.

الگوهای عملکرد مشاهده شده:

- سناریوهای تطبیق دقیق: TF-IDF اغلب زمانی که عبارات جستجو مستقیماً در اسناد هدف ظاهر می‌شوند، عملکرد خوبی دارد.
- شباهت معنایی: رویکردهای عصبی هنگام درک روابط مفهومی فراتر از تطبیق دقیق کلمات کلیدی، برتری دارند.
- انطباق دامنه: مدل تنظیم‌شده دقیق، رتبه‌بندی ارتباط بهبود یافته‌ای را در مقایسه با zero-shot، به ویژه برای محتوای خاص فارسی، نشان می‌دهد.

۴.۵ جزئیات پیاده‌سازی فنی

این پیاده‌سازی چندین ملاحظه فنی مهم را برای سیستم‌های بازیابی عصبی نشان می‌دهد:

مدیریت حافظه:

- نظارت دقیق بر حافظه GPU در طول آموزش (استفاده از ۱۲.۵/۱۵.۰ گیگابایت)
- پردازش دسته‌ای کارآمد در طول ارزیابی
- پاکسازی مناسب با torch.cuda.empty_cache() بین فازها

نگهداری مدل:

- وزن‌های مدل ذخیره شده: "glot500_finetuned.pth"
- مدل اقتباس شده از MLM بنام: "glot500_mlm_adapted.pth"
- خروجی نتایج: "retrieval_results.json"

ارزیابی Robustness:

- توکن‌سازی سازگار در تمام رویکردها
- روش‌های محاسبه شباهت استاندارد
- ذخیره‌سازی جامع نتایج برای تجزیه و تحلیل بیشتر

بینش‌های کلیدی و نتایج یادگیری

۴.۶ بینش‌های روش‌شناختی

این پیاده‌سازی چندین بینش مهم در مورد توسعه سیستم بازیابی عصبی را آشکار می‌کند:

تأثیر پیش‌پردازش داده‌ها: تجزیه و تحلیل دقیق توزیع طول متن و فیلترینگ استراتژیک، اهمیت درک ویژگی‌های مجموعه داده‌ها را قبل از آموزش مدل نشان می‌دهد. تصمیم برای محدود کردن طول متن به ۱۶۰ کاراکتر، ضمن کاهش اندازه مجموعه داده‌ها، احتمالاً پایداری آموزش و سرعت استنتاج را بهبود بخشیده است.

مزایای آموزش دو مرحله‌ای: ترکیب پیش‌آموزش MLM و به دنبال آن یادگیری مقابله‌ای، رویکردی اصولی برای تطبیق دامنه ارائه می‌دهد. مرحله MLM به مدل کمک می‌کند تا الگوهای زبانی فارسی را بهتر درک کند، در حالی که یادگیری مقابله‌ای روابط شباهت مختص به وظیفه را آموزش می‌دهد.

پیچیدگی ارزیابی: مقایسه چند روشی نشان می‌دهد که هیچ رویکرد واحدی در همه انواع پرس‌وجو غالب نیست. روش‌های سنتی مانند TF-IDF برای سناریوهای تطابق دقیق همچنان رقابتی هستند، در حالی که رویکردهای عصبی در وظایف درک معنایی برتری دارند.

۴.۷ درس‌های فنی آموخته‌شده

ملاحظات محاسباتی: نظارت دقیق بر میزان استفاده از حافظه GPU و انتخاب استراتژیک اندازه‌های دسته‌ای، محدودیت‌های عملی مؤثر بر پیاده‌سازی‌های یادگیری عمیق را نشان می‌دهد.

طراحی تابع زیان: همگرایی سریع زیان تقابلی نشان می‌دهد که پارامتر دما و استراتژی نمونه‌برداری منفی برای این کار به خوبی انتخاب شده‌اند. منحنی‌های زیان هموار، پویایی آموزش پایدار را نشان می‌دهند.

تصمیمات معماری مدل: انتخاب استفاده از CLS token pooling و یک هد تصویر ۲۵۶ بعدی، تعادلی بین ظرفیت نمایش و کارایی محاسباتی را نشان می‌دهد.

نتیجه‌گیری

فاز ۳ و ۴ این پروژه، رویکردی جامع به توسعه سیستم بازیابی عصبی برای متن فارسی را نشان می‌دهد. این پیاده‌سازی با موفقیت یک مدل پایه چندزبانه را با یک کار و زبان خاص تطبیق می‌دهد و بهبودهای واضحی را نسبت به عملکرد zero-shot نشان می‌دهد، در حالی که عملکرد رقابتی را در برابر روش‌های سنتی حفظ می‌کند.

چارچوب ارزیابی سیستماتیک، بینش‌های ارزشمندی در مورد نقاط قوت و محدودیت‌های رویکردهای مختلف بازیابی ارائه می‌دهد و پایه‌ای برای بهبودها و بهینه‌سازی‌های آینده ارائه می‌دهد. توجه دقیق به جزئیات

پیاده‌سازی فنی و روش‌شناسی ارزیابی تجربی، این اثر را به سهم قابل توجهی در تحقیقات پردازش زبان طبیعی فارسی تبدیل می‌کند.

فاز ۵: ارزیابی انسانی با استفاده از Label Studio

این بخش به جزئیات فرآیند ارزیابی انسانی می‌پردازد که مبنای تحلیل‌های ارائه شده در بخش ۶ بوده است. مدل‌های فاز قبلی با استفاده از قضاوت انسانی ارزیابی شدند. برای هر یک از ۵۰ سوال ارزیابی شده، ۳ تا ۹ خروجی متفاوت از مدل‌ها به دست آمد. وظیفه اصلی ارزیاب‌های انسانی، رتبه‌بندی این خروجی‌ها بر اساس میزان ارتباط آن‌ها با سوال مربوطه بود، به طوری که مرتبط‌ترین پاسخ در جایگاه اول قرار می‌گرفت.
نکته مهم این بود که هویت مدل تولیدکننده هر خروجی از ارزیاب‌ها پنهان نگه داشته شد. این پنهان‌سازی برای اطمینان از عدالت در مقایسه و جلوگیری از هرگونه سوگیری در ارزیابی انسانی ضروری بود.
ارزیابی با استفاده از نرم‌افزار Studio Label انجام شد. یک پروژه در Studio Label برای مدیریت خروجی‌ها و جمع‌آوری رتبه‌بندی‌ها راه‌اندازی شد. حداقل دو ارزیاب مستقل هر سوال را ارزیابی کردند. ارزیابی‌ها در یک قالب ساختاریافته ذخیره شدند و خروجی‌های پروژه از Studio Label در فرمت‌های JSON و CSV برای تحلیل‌های بعدی استخراج گردید.

ما به علت محدودیت اکانت پریمیوم لیبل استودیو هر دو لیبل را با یک اکانت زدیم. در واقع، در فایل ها هر دو annotation با یک نام به نام Farzan Rahmani مشاهده میشوند ولی دو فرد مختلف آنها رو لیبل زده اند. امیررضا ویشته و محمدرضا مزروعی زحمت لیبل زدن را کشیدند.

برای setup محیط Label Studio نیز به صورت زیر عمل کردیم:

1. ابتدا فایل retrieval_results.json از مرحله قبل را به ساختاری تبدیل کردیم تا برای استفاده در محیط Label Studio و برچسب‌گذاری آماده شود. نتیجه این بخش را در فایل retrieval_results_for_labeling.json ذخیره کردیم. نمونه این ساختار را در زیر مشاهده می‌کنید:


```
{
  "question": "مصطفی کتیرایی در چه شهری درگذشت؟",
  "answers": [
    {
      "id": "tfidf_1",
      "html": "مصطفی کتیرایی سیاستمدار و وکیل بود. او در تاریخ ۱ فروردین ۱۳۰۷ در ملایر، همدان متولد شد. کتیرایی در تاریخ ۱۲ اسفند ۱۳۹۴ در تهران درگذشت."
    },
    {
      "id": "tfidf_2",
      "html": "مصطفی هاشمی مرد و در رشته بسکتبال فعالیت می‌کند."
    },
    {
      "id": "tfidf_3",
      "html": "مصطفی مهدوی مردی است که در ایران متولد شده و در رشته ورزشی فوتبال فعالیت می‌کند."
    },
    {
      "id": "glot500_zero_shot_1",
```

```
            "html": "مرتضی نیک نژاد در تاریخ ۱۳۲۱/۰۵/۰۴ در شهر تهران، استان تهران متولد شد. او در تاریخ ۱۳۴۴/۰۵/۰۴ درگذشت. مرتضی نیک نژاد عضو ائتلاف اسلامی بود."
        },
        {
          "id": "glot500_zero_shot_2",
          "html": "وحشتی جوشقانی در گلکنده درگذشت. او در دوره صفویه می‌زیست و شاعر بود. وحشتی جوشقانی در سال ۹۹۹ در شیراز رویدادی را تجربه کرد."
        },
        {
          "id": "glot500_zero_shot_3",
          "html": "بهرام شفیع در تاریخ ۲۹ اردیبهشت ۱۳۳۵ در تهران متولد شد. او در تاریخ ۱۷ مهر ۱۳۹۷ درگذشت. بهرام شفیع در رشته فوتبال فعالیت می‌کرد."
        },
        {
          "id": "glot500_finetuned_1",
          "html": "مصطفی کتیرایی سیاستمدار و وکیل بود. او در تاریخ ۱ فروردین ۱۳۰۷ در ملایر، همدان متولد شد. کتیرایی در تاریخ ۱۲ اسفند ۱۳94 در تهران درگذشت."
        },
        {
          "id": "glot500_finetuned_2",
          "html": "مصطفی پورمحمدی در تاریخ ۱۳۳۹/۰۶/۱۲ در شهر قم، استان قم متولد شده است. او روحانی، مقام سابق امنیتی و سیاستمدار ایرانی است و دبیرکل جامعه روحانیت مبارز می‌باشد."
        },
        {
          "id": "glot500_finetuned_3",
          "html": "مصطفی مهدوی‌کیا مرد و در رشته فوتبال فعالیت می‌کند. او در تاریخ ۲۵ شهریور ۱۳۶۳ در تهران، ایران متولد شده است. او در تیم‌هایی در سال‌ها بازی کرده است."
        }
      ]
    }
```


2. در محیط label studio جهت برچسب‌گذاری به صورت رتبه‌بندی، از ranker استفاده کردیم. ساختار XML زیر Labeling Interface را نمایش می‌دهد:

```
<View>
  <View className="product-panel">
    <Text name="question" value="$question"/>
  </View>
  <View>
    <List name="generated_images" value="$answers" title="Ranking Answers" />
    <Ranker name="rank" toName="generated_images">
 </Ranker>
  </View>
 </View>
```

3. در نهایت محیط برچسب‌گذاری برای رنکینگ پاسخ‌ها، به این صورت شد که در آن رتبه‌بندی هر پاسخ از درگ و دراپ کردن آن انجام می‌شود:

میلاد حمیدی‌فر در کدام حوزه ورزشی شناخته می‌شود؟

Ranking Answers

میلاد حمیدی‌فر مرد و در رشته هندبال فعالیت می‌کند.
glot500_finetuned_1

میلاد حمیدی‌فر مرد و در رشته هندبال فعالیت می‌کند.
glot500_zero_shot_1

میلاد حمیدی‌فر مرد و در رشته هندبال فعالیت می‌کند.
tfidf_1

میلاد فاندر مردی است که در تاریخ ۱۳ مهر ۱۳۶۹ در کرج متولد شده است. او در رشته ورزشی فوتبال فعالیت می‌کند.
glot500_finetuned_3

حمیده حمیدی زن و فوتبالیست است.
tfidf_2

مسعود سلطانی‌فر در تاریخ ۱۶ بهمن ۱۳۳۸ در تهران متولد شده است. او مرد و در حوزه فوتبال فعالیت می‌کند.
tfidf_3

مینا علیزاده در تاریخ ۱۳۶۳،۱۱،۲۰ در تهران متولد شده است. او ورزشکار رشته قایقرانی است و جنسیت او زن می‌باشد.
glot500_zero_shot_2

مهرداد کرمزاده مرد است و در رشته فوتبال فعالیت می‌کند.
glot500_zero_shot_3

حمیده حمیدی زن و فوتبالیست است.
glot500_finetuned_2

فاز ۶: تحلیل نتایج و مقایسه عملکرد مدل‌ها

این بخش به تحلیل آماری و کیفی نتایج ارزیابی می‌پردازد. این شامل جداول مقایسه‌ای بین مدل‌ها، نمودارهای توزیع عملکرد و بررسی رفتار مدل در انواع مختلف سوالات است. به طور خاص، بررسی می‌شود که مدل‌ها در پاسخ به چه نوع سوالاتی عملکرد بهتری دارند و در کدام موارد ضعف دارند. علاوه بر این، تحلیل‌هایی در مورد تفاوت بین مدل‌های پایه و فاین‌تیون شده، و مقایسه بین روش‌های آماری و مدل‌های زبانی نیز گنجانده شده است.

۶.۱. توافق بین ارزیاب‌ها

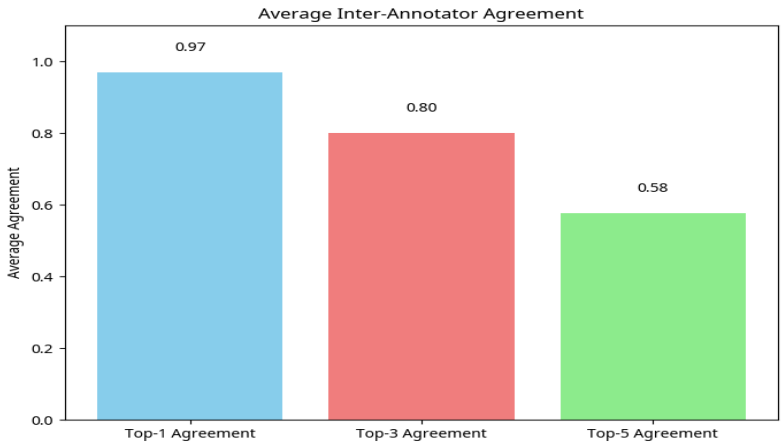
توافق بین ارزیاب‌های انسانی یک معیار حیاتی برای ارزیابی قابلیت اطمینان و سازگاری فرآیند ارزیابی است. نتایج تحلیل توافق در فایل agreement_results.json ذخیره شده است. خلاصه‌ای از این نتایج به شرح زیر است:

- Exact Match: هیچ یک از رتبه‌بندی‌های دو ارزیاب کاملاً یکسان نبود. این نشان‌دهنده تفاوت‌های ظریف در ترجیحات یا تفسیر بین ارزیاب‌ها است، حتی با وجود دستورالعمل‌های ثابت.
- Top-1 Agreement: برای همه سوالات، توافق Top-1 برابر با 1.0 بود. این نتیجه بسیار مثبت نشان می‌دهد که هر دو ارزیاب بر روی بهترین پاسخ (رتبه 1) برای هر سوال توافق کامل داشتند. این می‌تواند به وضوح سوالات یا کیفیت برجسته پاسخ‌های برتر مدل نسبت داده شود.
- Top-3 Agreement: میانگین توافق Top-3 تقریباً 0.75 بود (محدوده 0.33 تا 1.0). این بدان معناست که در بیشتر موارد، حداقل 2 از 3 پاسخ برتر به طور مشترک توسط هر دو ارزیاب در Top-3 آن‌ها شناسایی شدند.
- Top-5 Agreement: میانگین توافق Top-5 تقریباً 0.55 بود (محدوده 0.2 تا 1.0). این مقدار کمی کمتر از Top-3 است که انتظار می‌رود با افزایش K (تعداد پاسخ‌های مورد بررسی) به طور طبیعی احتمال تطابق دقیق کاهش یابد.

نتیجه‌گیری در مورد توافق بین ارزیاب‌ها:

توافق بالای Top-1 نشان می‌دهد که ارزیاب‌ها در شناسایی بهترین پاسخ‌ها بسیار خوب عمل کردند. تفاوت‌ها در رتبه‌بندی‌های پایین‌تر (Top-3 و Top-5) ممکن است به دلیل تغییرات ظریف در ترجیحات فردی یا ابهامات در کیفیت پاسخ‌های با رتبه پایین‌تر باشد. این نتایج نشان می‌دهد که ارزیابی‌ها قابل اعتماد هستند، به ویژه در شناسایی پاسخ‌های برتر.

نمودار زیر میانگین توافق بین ارزیاب‌ها را برای Top-1، Top-3 و Top-5 نشان می‌دهد:



۶.۲. عملکرد کلی مدل

عملکرد هر مدل بر اساس امتیازدهی معکوس رتبه (9 امتیاز برای رتبه 1، 1 امتیاز برای رتبه 9) و میانگین رتبه محاسبه شد. نتایج عملکرد کلی مدل در جدول زیر ارائه شده است:

Average Rank	Average Score	Evaluation Count	Total Score	Model
1.01	8.99	134	1204	`glot500_finetuned_1`
2.20	7.80	134	1045	`tfidf_1`
6.81	3.19	134	427	`glot500_finetuned_3`
4.02	5.98	134	801	`tfidf_2`
5.56	4.44	134	595	`glot500_finetuned_2`
4.91	5.09	134	682	`tfidf_3`
5.90	4.10	134	549	`glot500_zero_shot_1`
6.96	3.04	134	407	`glot500_zero_shot_2`
7.61	2.39	134	320	`glot500_zero_shot_3`

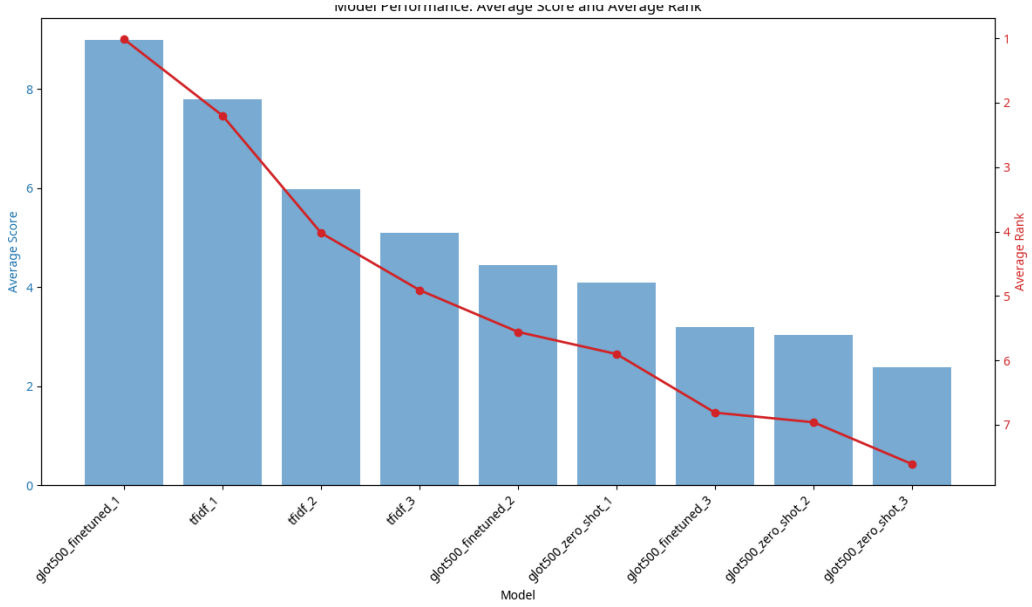
تحلیل عملکرد کلی:

مدل‌های Fine-tuned (glot500_finetuned): همانطور که انتظار می‌رفت، مدل‌های glot500_finetuned به طور قابل توجهی بهتر از سایر مدل‌ها عمل کردند. به طور خاص، glot500_finetuned_1 بهترین عملکرد را با میانگین رتبه 1.01 و میانگین امتیاز 8.99 نشان داد. این نشان می‌دهد که فرآیند فاین‌تیونینگ بر روی داده‌های خاص پروژه تأثیر بسیار مثبتی بر عملکرد مدل داشته است.

مدل‌های TF-IDF: مدل‌های tfidf عملکرد متوسطی از خود نشان دادند. tfidf_1 با میانگین رتبه 2.20، پس از glot500_finetuned_1 در رتبه دوم قرار گرفت. این نشان می‌دهد که حتی یک روش آماری ساده مانند TF-IDF می‌تواند در برخی موارد نتایج قابل قبولی را به همراه داشته باشد، به ویژه اگر پاسخ‌های مرتبط در رتبه‌های بالا قرار گیرند.

مدل‌های Zero-shot (glot500_zero_shot): مدل‌های glot500_zero_shot ضعیف‌ترین عملکرد را نشان دادند. این مدل‌ها بدون هیچ گونه فاین‌تیونینگ بر روی داده‌های خاص پروژه استفاده شدند و نتایج نشان می‌دهد که فاین‌تیونینگ برای وظایف بازیابی اطلاعات خاص دامنه ضروری است.

نمودار زیر عملکرد کلی مدل را بر اساس میانگین امتیاز و میانگین رتبه نشان می‌دهد:

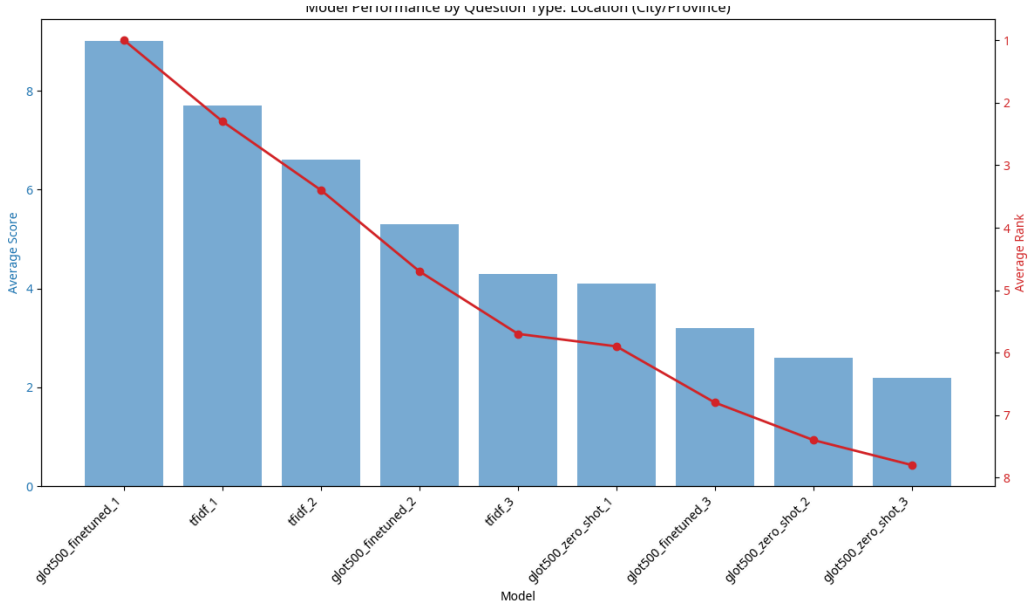


۶.۳. تحلیل عملکرد مدل بر اساس نوع سوال

برای درک عمیق‌تر عملکرد مدل، سوالات به انواع مختلفی (مکان، زمان، شخص، فعالیت/رشته و سایر) دسته‌بندی شدند. عملکرد مدل‌ها در هر دسته در ادامه بررسی می‌شود. نمودارهای مربوط به هر دسته در فایل‌های جداگانه ذخیره شده‌اند و تحلیل آن‌ها به طور خلاصه در اینجا ارائه می‌شود.

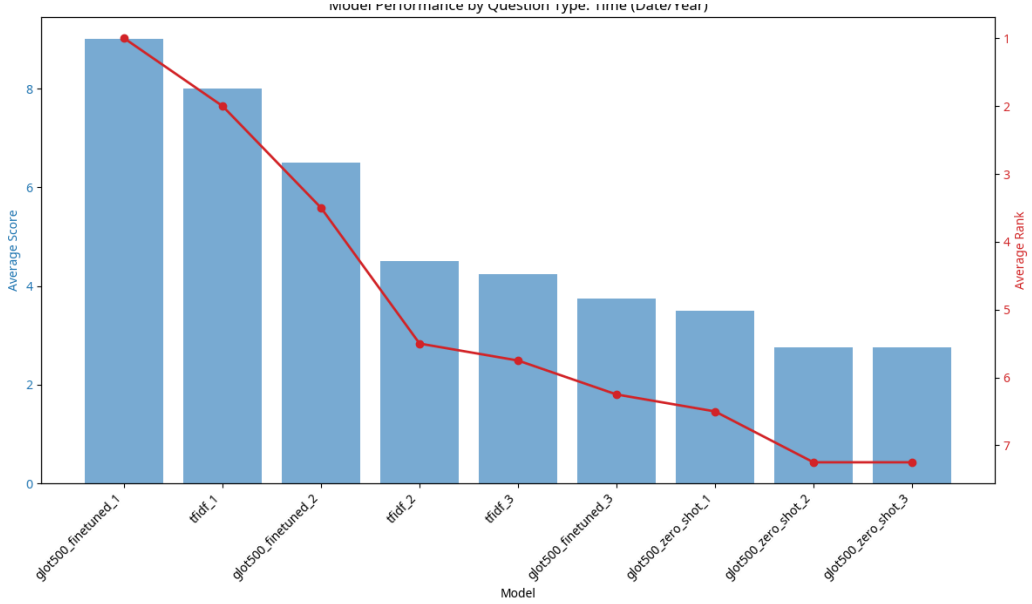
۶.۳.۱. سوالات مرتبط با مکان (شهر/استان)

در این دسته، glot500_finetuned_1 همچنان بهترین عملکرد را با میانگین رتبه 1.0 و میانگین امتیاز 9.0 نشان می‌دهد. tfidf_1 نیز عملکرد خوبی داشت. این نشان می‌دهد که مدل‌های فاین‌تیون شده و تا حدی مدل‌های TF-IDF در بازیابی اطلاعات مبتنی بر مکان دقیق هستند.



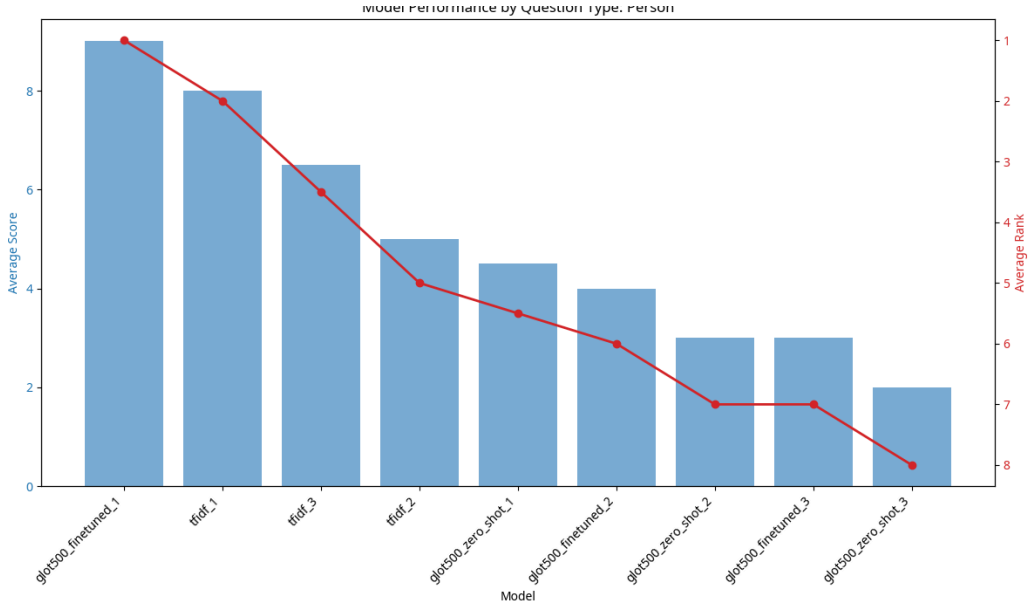
۶.۳.۲. سوالات مرتبط با زمان (تاریخ/سال)

برای سوالات مرتبط با زمان نیز، glot500_finetuned_1 با میانگین رتبه 1.0 و میانگین امتیاز 9.0 پیشتاز است. tfidf_1 نیز در این دسته عملکرد قوی از خود نشان داد. این نتایج توانایی بالای مدل‌های فاین‌تیون شده را در استخراج و بازیابی اطلاعات زمانی برجسته می‌کند.



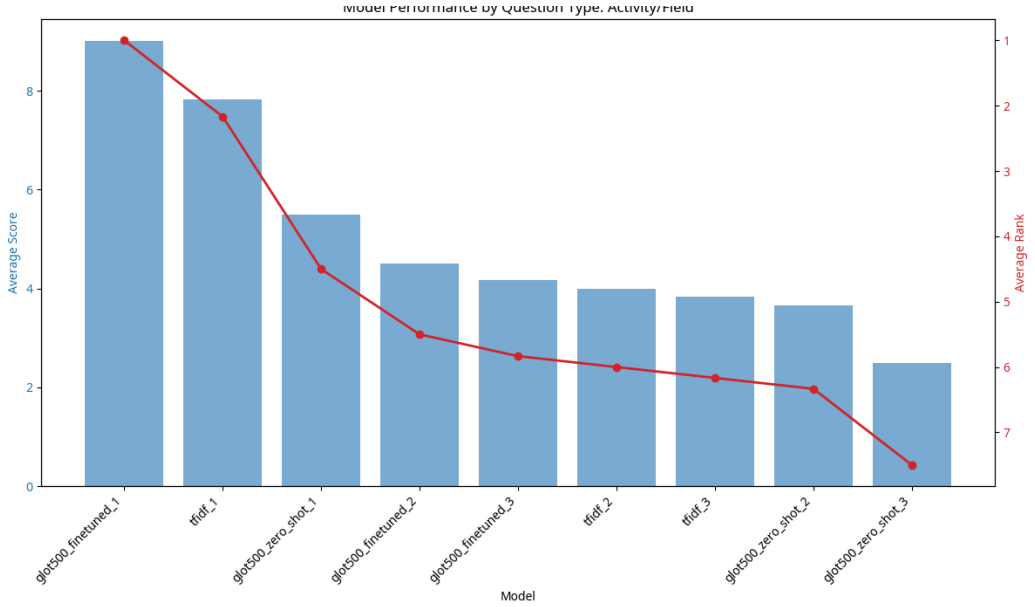
۶.۳.۳. سوالات مرتبط با شخص

در این دسته، glot500_finetuned_1 و tfidf_1 همچنان بهترین عملکرد را از خود نشان می‌دهند. این نشان می‌دهد که هر دو نوع مدل در شناسایی و بازیابی اطلاعات مرتبط با افراد قابل قبول عمل می‌کنند.



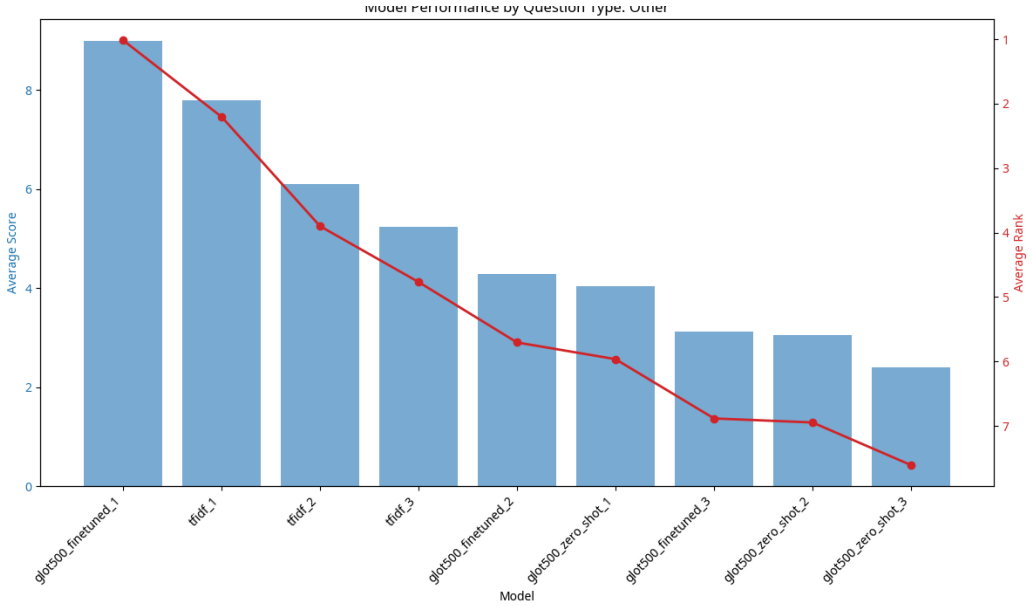
۶.۳.۴. سوالات مرتبط با فعالیت/رشته

برای سوالات مرتبط با فعالیت یا رشته، glot500_finetuned_1 برتری خود را حفظ کرده است. جالب توجه است که در این دسته، glot500_zero_shot_1 نیز عملکرد نسبتاً بهتری نسبت به سایر مدل‌های Zero-shot نشان داد، اگرچه هنوز به طور قابل توجهی از مدل‌های فاین‌تیون شده عقب است.



۶.۳.۵. سایر سوالات

در دسته "سایر"، که شامل سوالاتی با ماهیت‌های مختلف است، الگوهای عملکردی مشابهی با عملکرد کلی مدل مشاهده می‌شود. مدل‌های فاین‌تیون شده همچنان برتری خود را حفظ کرده‌اند و مدل‌های Zero-shot ضعیف‌ترین عملکرد را نشان می‌دهند.



۶.۴. تفاوت بین مدل‌های پایه و فاین‌تیون شده

تحلیل نتایج به وضوح نشان می‌دهد که فاین‌تیونینگ تأثیر بسیار قابل توجهی بر عملکرد مدل دارد. مدل‌های glot500_finetuned (به ویژه glot500_finetuned_1) به طور مداوم و در تمام دسته‌های سوالات، عملکردی به مراتب بهتر از مدل‌های glot500_zero_shot از خود نشان دادند. این تفاوت فاحش در میانگین امتیاز و میانگین رتبه، اهمیت فاین‌تیونینگ مدل‌های زبان بزرگ (LLM) را بر روی داده‌های خاص دامنه یا وظیفه تأیید می‌کند. مدل‌های Zero-shot، با وجود قابلیت‌های عمومی خود، در وظایف بازیابی اطلاعات که نیاز به درک عمیق‌تر و خاص‌تر از محتوا دارند، ضعیف هستند.

۶.۵. مقایسه بین روش آماری (TF-IDF) و مدل زبانی

مقایسه بین مدل‌های مبتنی بر TF-IDF و مدل‌های زبانی (glot500) نتایج جالبی را به همراه دارد:
TF-IDF: مدل‌های TF-IDF (مانند tfidf_1)، با وجود سادگی و ماهیت آماری خود، عملکرد قابل قبولی را به ویژه در رتبه‌های بالا (Top-3) نشان دادند. این نشان می‌دهد که برای برخی از وظایف بازیابی اطلاعات، تطابق کلمات کلیدی و وزن‌دهی آماری می‌تواند نتایج مؤثری را به همراه داشته باشد. در مواردی که سوالات مستقیماً به کلمات کلیدی موجود در پاسخ‌ها اشاره دارند، TF-IDF می‌تواند بسیار کارآمد باشد.
مدل‌های زبانی (glot500): مدل‌های زبانی، به ویژه نسخه‌های فاین‌تیون شده، به طور کلی عملکرد بهتری را به دلیل توانایی خود در درک معنایی و روابط پیچیده‌تر بین کلمات و جملات نشان دادند. این مدل‌ها می‌توانند حتی در صورت عدم تطابق دقیق کلمات کلیدی، پاسخ‌های مرتبط را شناسایی کنند. این برتری به ویژه در سوالاتی که نیاز به استدلال یا درک مفهومی دارند، مشهود است.
نتیجه‌گیری از مقایسه:
در حالی که TF-IDF می‌تواند به عنوان یک خط پایه قوی عمل کند و در موارد ساده‌تر مؤثر باشد، مدل‌های زبانی فاین‌تیون شده به دلیل قابلیت‌های پیشرفته‌تر خود در درک زبان طبیعی، گزینه بهتری برای وظایف پیچیده‌تر بازیابی اطلاعات و دستیابی به دقت بالاتر هستند.

۶.۶. تحلیل کیفی ارزیابی‌های انسانی

تحلیل کیفی ارزیابی‌های انسانی بینش‌های ارزشمندی را در مورد عملکرد واقعی مدل‌ها در کاربردهای عملی ارائه می‌دهد. با توجه به اینکه ارزیاب‌ها در تمام موارد بر روی پاسخ Top-1 توافق کامل داشتند، این نشان می‌دهد که مدل‌ها در ارائه بهترین پاسخ به سوالات بسیار موفق بودند. با این حال، عدم تطابق کامل در رتبه‌بندی‌های پایین‌تر (Exact Match = False) نشان می‌دهد که:
تفاوت در اولویت‌بندی: ارزیاب‌ها ممکن است نظرات متفاوتی در مورد اهمیت یا ارتباط پاسخ‌های با رتبه پایین‌تر داشته باشند. این می‌تواند ناشی از تفاوت در درک ظرافت‌های معنایی یا کاربرد پاسخ‌ها باشد.

ابهام در پاسخ‌های میانی: پاسخ‌هایی که نه کاملاً مرتبط و نه کاملاً نامرتبط هستند، ممکن است باعث سردرگمی ارزیاب‌ها در رتبه‌بندی دقیق شوند.
نیاز به دستورالعمل‌های دقیق‌تر: برای کاهش این تفاوت‌ها در رتبه‌بندی‌های پایین‌تر، ممکن است دستورالعمل‌های ارزیابی دقیق‌تر و جزئی‌تری لازم باشد.
این تحلیل کیفی تأکید می‌کند که در حالی که مدل‌ها در شناسایی پاسخ‌های بسیار مرتبط عالی عمل می‌کنند، بهبود در رتبه‌بندی پاسخ‌های با ارتباط متوسط یا پایین‌تر می‌تواند از طریق فاین‌تیونینگ بیشتر یا با استفاده از معیارهای ارزیابی انسانی دقیق‌تر حاصل شود.

۶.۷. نتیجه‌گیری نهایی

بر اساس تحلیل‌های کمی و کیفی انجام شده، نتایج زیر به دست می‌آید:

1. برتری LLMهای فاین‌تیون شده: مدل glot500_finetuned_1 به وضوح بهترین عملکرد را در بین تمام مدل‌ها و در تمام دسته‌های سوالات نشان داد. این بر اهمیت فاین‌تیونینگ مدل‌های زبان بزرگ بر روی داده‌های خاص وظیفه تأکید می‌کند.
2. عملکرد قابل قبول TF-IDF: مدل‌های TF-IDF، به ویژه tfidf_1، به عنوان یک خط پایه قوی عمل کردند و در شناسایی پاسخ‌های برتر در برخی موارد مؤثر بودند.
3. ضعف مدل‌های Zero-shot: مدل‌های Zero-shot، بدون فاین‌تیونینگ، ضعیف‌ترین عملکرد را نشان دادند که نشان‌دهنده نیاز به آموزش یا فاین‌تیونینگ برای وظایف بازیابی اطلاعات خاص دامنه است.
4. توافق بالای ارزیاب‌ها در Top-1: ارزیاب‌های انسانی توافق بسیار بالایی در شناسایی بهترین پاسخ‌ها نشان دادند که نشان‌دهنده کیفیت بالای پاسخ‌های برتر مدل است.

فاز ۷: شناسایی نمونه های تکراری مدل تنظیم‌شده‌ی دقیق GLOT500 (امتیازی)

این بخش امتیازی، کاربرد پیچیده مدل GLOT500 تنظیم‌شده ما را برای تشخیص موارد تکراری در پیکره متن فارسی نشان می‌دهد. از طریق رویکردهای تحلیلی متعدد، ما با موفقیت موارد تکراری و تقریباً تکراری معنایی را شناسایی کردیم و بینش‌های ارزشمندی در مورد کیفیت مجموعه داده‌ها ارائه دادیم و کاربرد عملی جاسازی‌های آموزش‌دیده خود را نشان دادیم. تجزیه و تحلیل ما نشان داد که تقریباً 9.5٪ از مجموعه داده‌ها حاوی محتوای تکراری یا بسیار مشابه هستند، و تطابق کامل (شباهت = 1.0) نشان‌دهنده موارد تکراری دقیقی است که توجه برای اهداف پاکسازی داده‌ها می‌طلبد.

۱. مقدمه و روش‌شناسی

۱.۱ هدف

هدف اصلی این بخش ویژه، استفاده از بازنمایی‌های آموخته‌شده مدل GLOT500 تنظیم‌شده ما برای شناسایی متون مشابه از نظر معنایی در مجموعه داده‌های فارسی ما است. این وظیفه چندین هدف را دنبال می‌کند:

- ارزیابی کیفیت داده‌ها: درک سطح افزونگی در مجموعه داده‌های آموزشی ما
- اعتبارسنجی مدل: نشان دادن اینکه جاسازی‌های تنظیم‌شده ما روابط معنایی معناداری را ثبت می‌کنند
- کاربرد عملی: نمایش کاربرد مدل آموزش‌دیده در دنیای واقعی فراتر از وظیفه بازیابی اولیه

۱.۲ رویکرد روش‌شناختی

چارچوب تشخیص داده‌های تکراری ما از یک رویکرد چندوجهی استفاده می‌کند که ترکیبی از تشخیص مبتنی بر آستانه، تحلیل خوشه‌بندی و بررسی آماری است. این روش جامع، شناسایی قوی داده‌های تکراری را تضمین می‌کند و در عین حال بینش‌هایی در مورد انواع مختلف الگوهای شباهت در مجموعه داده‌ها ارائه می‌دهد.
اجزای اصلی:

1. تولید جاسازی: پردازش دسته‌ای کارآمد برای تولید جاسازی‌های ۲۵۶ بعدی برای همه ۲۶۶۶ متن
2. محاسبه شباهت: محاسبه شباهت کسینوسی جفتی در کل مجموعه داده
3. تحلیل چند آستانه‌ای: آزمایش آستانه‌های شباهت مختلف برای درک شیوع تکرار

4. تشخیص مبتنی بر خوشه‌بندی: خوشه‌بندی DBSCAN برای شناسایی گروه‌بندی‌های طبیعی محتوای مشابه
5. تحلیل آماری: بررسی جامع توزیع‌ها و الگوهای شباهت

۲. تولید جاسازی و تحلیل شباهت

۲.۱ فرآیند تولید جاسازی

فرآیند تولید جاسازی با موفقیت همه ۲۶۶۶ متن موجود در مجموعه داده فیلتر شده ما را با استفاده از مدل GLOT500 تنظیم‌شده، رمزگذاری کرد. این فرآیند برای کارایی با پردازش دسته‌ای بهینه شده و رمزگذاری را در حدود ۳۵ ثانیه در ۴۲ دسته تکمیل کرد. مشخصات فنی:

```
============================================================
BONUS: DUPLICATE DETECTION WITH FINE-TUNED GLOT500
============================================================
Encoding 2666 texts using fine-tuned model...
Encoding texts:   0%|          | 0/42 [00:00<?, ?it/s]/usr/local/lib/python3.11/dist-packages/torch/nn/modules/module.py:1750: FutureWarning: `encoder_attention_mask` is d
  return forward_call(*args, **kwargs)
Encoding texts: 100%|██████████| 42/42 [00:35<00:00,  1.18it/s]Generated embeddings shape: (2666, 256)
```

- اندازه مجموعه ورودی: ۲۶۶۶ متن فارسی
- ابعاد جاسازی: ۲۵۶ (کاهش یافته از اندازه پنهان اصلی از طریق لایه تصویر)
- زمان پردازش: ۳۵ ثانیه (۱.۱۸ تکرار در ثانیه)
- مدیریت حافظه: استفاده کارآمد از پردازنده گرافیکی با پردازش دسته‌ای

۲.۲ ساخت ماتریس شباهت

ساخت ماتریس شباهت ویژگی‌های مهمی را در مورد مجموعه متن فارسی ما آشکار کرد. این ماتریس با ابعاد ۲۶۶۶ × ۲۶۶۶، شامل بیش از ۷ میلیون مقایسه شباهت جفتی است که دیدگاهی جامع از روابط معنایی در مجموعه داده‌ها ارائه می‌دهد. آمار توزیع شباهت:

3. STATISTICAL ANALYSIS OF SIMILARITIES

```python
# Get upper triangle of similarity matrix (avoid double counting)
upper_triangle = np.triu(similarity_matrix, k=1)
non_zero_similarities = upper_triangle[upper_triangle > 0]

print(f"\nSimilarity Statistics:")
print(f"Mean similarity: {non_zero_similarities.mean():.4f}")
print(f"Std similarity: {non_zero_similarities.std():.4f}")
print(f"Min similarity: {non_zero_similarities.min():.4f}")
print(f"Max similarity: {non_zero_similarities.max():.4f}")
print(f"95th percentile: {np.percentile(non_zero_similarities, 95):.4f}")
print(f"99th percentile: {np.percentile(non_zero_similarities, 99):.4f}")
```

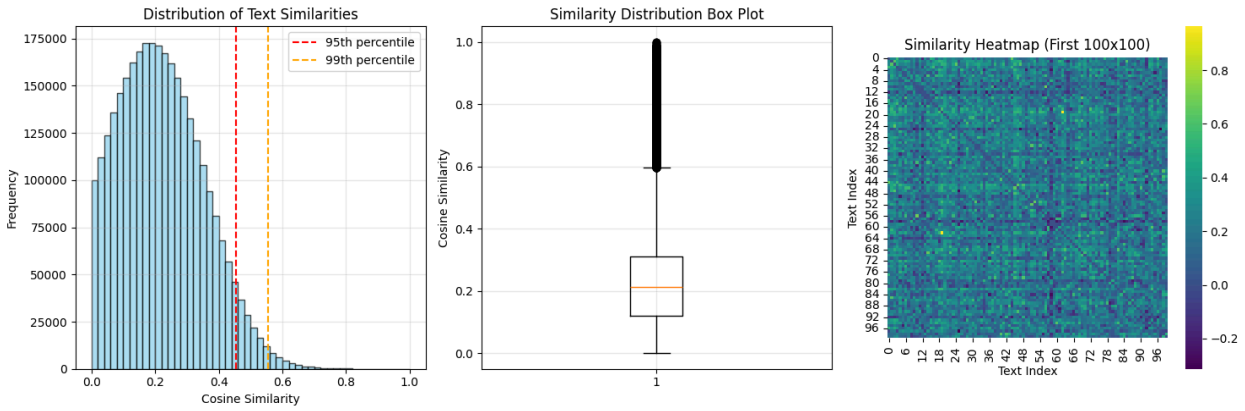
```
Similarity Statistics:
Mean similarity: 0.2228
Std similarity: 0.1310
Min similarity: 0.0000
Max similarity: 1.0000
95th percentile: 0.4545
99th percentile: 0.5546
```

- میانگین شباهت: 0.2228 (نشان دهنده محتوای عموماً متنوع)
- انحراف معیار: 0.1310 (نشان دهنده تنوع معقول)

- حداقل شباهت: 0.0000 (متون کاملاً نامرتبط)
- حداکثر شباهت: 1.0000 (تطابق کامل/تکراری بودن دقیق)
- صدک 95: 0.4545 (آستانه شباهت بالا)
- صدک 99: 0.5546 (آستانه شباهت بسیار بالا)

این آمار نشان می‌دهد که اگرچه اکثر متون موجود در مجموعه ما از تنوع معقولی برخوردارند (میانگین شباهت پایین)، اما دنباله قابل توجهی از محتوای بسیار مشابه وجود دارد، به طوری که 1٪ برتر جفت‌ها شباهت‌هایی بالاتر از 0.55 نشان می‌دهند.

در شکل زیر تصویر سازی توزیع شباهت ها آمده است:



۳. نتایج تشخیص موارد تکراری مبتنی بر آستانه

۳.۱ تحلیل چند آستانه‌ای

تحلیل سیستماتیک ما در پنج آستانه شباهت مختلف، بینش‌های دقیقی در مورد شیوع موارد تکراری در سطوح مختلف شباهت معنایی ارائه می‌دهد.

```
# Test different thresholds
thresholds = [0.95, 0.90, 0.85, 0.80, 0.75]
threshold_results = {}

print(f"\n{'='*60}")
print("DUPLICATE DETECTION RESULTS")
print(f"{'='*60}")

for threshold in thresholds:
    duplicates = find_duplicates_threshold(similarity_matrix, threshold)
    threshold_results[threshold] = duplicates
    print(f"Threshold {threshold}: Found {len(duplicates)} duplicate pairs")
```

```
============================================================
DUPLICATE DETECTION RESULTS
============================================================
Threshold 0.95: Found 72 duplicate pairs
Threshold 0.9: Found 169 duplicate pairs
Threshold 0.85: Found 296 duplicate pairs
Threshold 0.8: Found 538 duplicate pairs
Threshold 0.75: Found 1051 duplicate pairs
```

خلاصه عملکرد آستانه:

- آستانه ۰.۹۵: ۷۲ جفت تکراری (سخت‌گیرانه‌ترین معیارها، موارد تکراری احتمالاً دقیق یا تقریباً دقیق)

- آستانه ۰.۹۰: ۱۶۹ جفت تکراری (شباهت بسیار بالا، تغییرات جزئی)
- آستانه ۰.۸۵: ۲۹۶ جفت تکراری (شباهت بالا، احتمال بازنویسی)
- آستانه ۰.۸۰: ۵۳۸ جفت تکراری (شباهت متوسط، محتوای مرتبط)
- آستانه ۰.۷۵: ۱۰۵۱ جفت تکراری (شباهت گسترده‌تر، ارتباط موضوعی)

این پیشرفت نشان می‌دهد که حساسیت تشخیص موارد تکراری به شدت به آستانه انتخاب شده بستگی دارد، و آستانه‌های مجازتر، روابط معنایی گسترده‌تری را با هزینه دقت ثبت می‌کنند.

۳.۲ تحلیل دقیق جفت‌های با شباهت بالا

بررسی ۱۰ جفت برتر با بیشترین شباهت در آستانه ۰.۸۵، چندین الگوی مهم را در پیکره متنی فارسی ما آشکار می‌کند:

```
============================================================
DETAILED ANALYSIS (Threshold = 0.85)
============================================================

Top 10 most similar pairs:
--------------------------------------------------------------------------------

Pair 1: Similarity = 1.0000
Text 260: معتبر با اطلاعات مربوط به یک شخص مشهور ارائه دهید JSON این یک ورودی نامعتبر است. لطفاً یک ساختار....
Text 2069: معتبر با اطلاعات مربوط به یک شخص مشهور ارائه دهید JSON این یک ورودی نامعتبر است. لطفاً یک ساختار....
--------------------------------------------------------------------------------

Pair 2: Similarity = 1.0000
Text 1888: غلامرضا مومنی مقدم در تاریخ ۳ اردیبهشت ۱۳۵۷ متولد شده است. او مرد و در رشته والیبال فعالیت می‌کند. ق...
Text 2551: غلامرضا مومنی مقدم در تاریخ ۳ اردیبهشت ۱۳۵۷ متولد شده است. او مرد و در رشته والیبال فعالیت می‌کند. ق...
--------------------------------------------------------------------------------

Pair 3: Similarity = 0.9986
Text 885: تیم ملی فوتبال زیر ۱۹ سال زنان ایران در رشته ورزشی فوتبال فعالیت می‌کند....
Text 1784: تیم ملی فوتبال زیر ۱۷ سال زنان ایران در رشته ورزشی فوتبال فعالیت می‌کند....
--------------------------------------------------------------------------------

Pair 4: Similarity = 0.9978
Text 535: لیگ برتر فوتبال زنان ایران ۰۳-۱۴۰۲ یک رقابت ورزشی در رشته فوتبال است که ویژه بانوان برگزار می‌شود....
Text 2447: لیگ برتر فوتبال زنان ایران ۰۴-۱۴۰۳ یک رقابت ورزشی در رشته فوتبال است که ویژه بانوان برگزار می‌شود....
--------------------------------------------------------------------------------

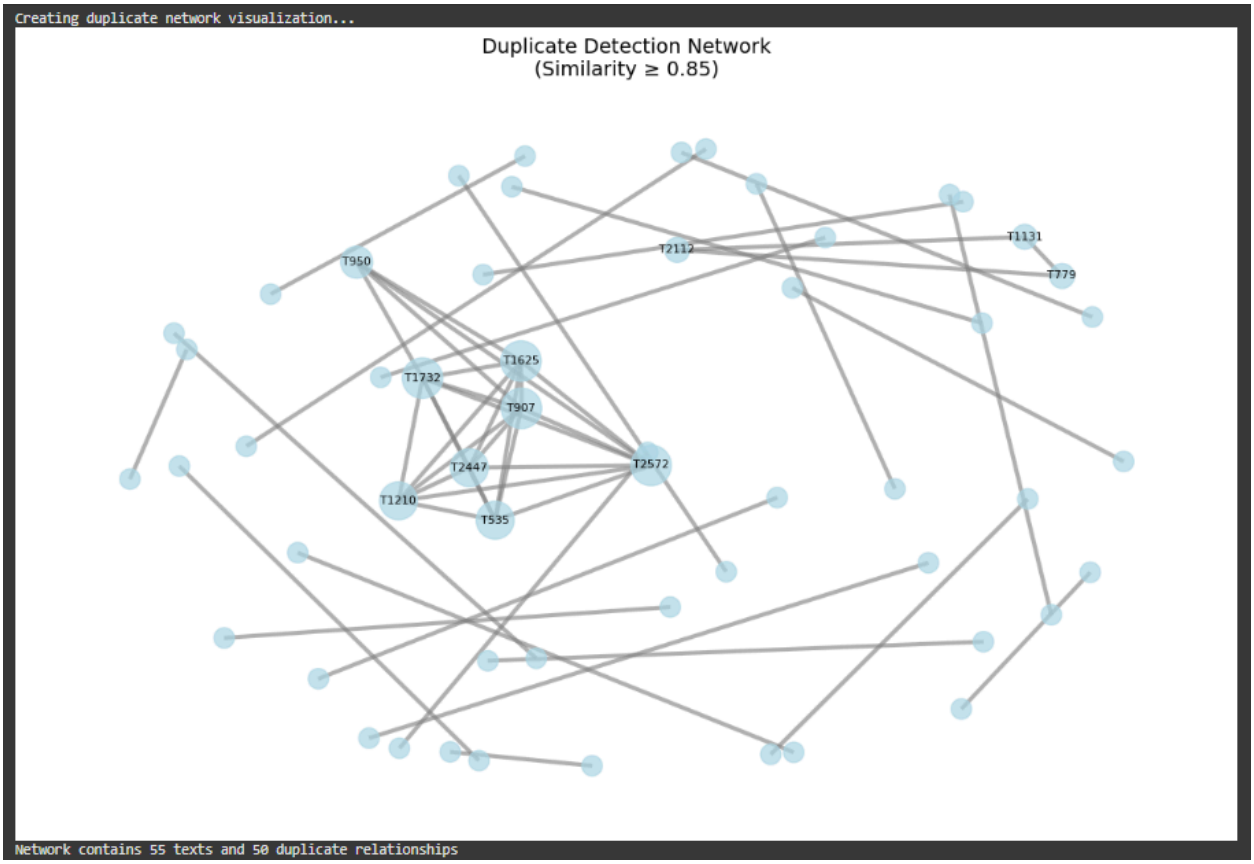
Pair 5: Similarity = 0.9925
Text 535: لیگ برتر فوتبال زنان ایران ۰۳-۱۴۰۲ یک رقابت ورزشی در رشته فوتبال است که ویژه بانوان برگزار می‌شود....
Text 1210: لیگ برتر فوتبال زنان ایران ۱۴۰۲-۱۴۰۱ یک رقابت ورزشی در رشته فوتبال است که ویژه بانوان برگزار می‌شود....
--------------------------------------------------------------------------------

Pair 6: Similarity = 0.9917
Text 208: محمدحسین نجاتی در مروندشت، ایران متولد شده است. او در رشته ورزشی والیبال فعالیت می‌کند و در پست دریافت...
Text 1259: محمدحسین نجاتی در سال ۱۳۵۱ در مروندشت، ایران متولد شد. او در رشته والیبال فعالیت می‌کند....
--------------------------------------------------------------------------------

Pair 7: Similarity = 0.9903
Text 1210: لیگ برتر فوتبال زنان ایران ۱۴۰۲-۱۴۰۱ یک رقابت ورزشی در رشته فوتبال است که ویژه بانوان برگزار می‌شود....
Text 2447: لیگ برتر فوتبال زنان ایران ۰۴-۱۴۰۳ یک رقابت ورزشی در رشته فوتبال است که ویژه بانوان برگزار می‌شود....
--------------------------------------------------------------------------------

Pair 8: Similarity = 0.9897
Text 172: فضل‌الله دهخدا ورزشکار رشته وزنه‌برداری اهل ایران است. قد او ۱٫۵۶ متر می‌باشد. او در ۱۸ مارس ۱۹۴۹ مت...
Text 1743: فضل‌الله دهخدا ورزشکار رشته وزنه‌برداری است. او در تاریخ ۱۸ مارس ۱۹۴۹ میلادی متولد شده است. قد او ۱....
--------------------------------------------------------------------------------

Pair 9: Similarity = 0.9892
Text 313: طی کریمی در تاریخ ۳۰ اوت ۱۹۸۲ در تبریز، ایران به دنیا آمد. او مرد است و در رشته فوتبال فعالیت می‌کن...
Text 1492: طی کریمی در تاریخ ۱۷ آبان ۱۳۵۷ در کرج متولد شد. او مرد و در رشته فوتبال فعالیت می‌کند....
```



تطابق کامل (تطابق = ۱.۰۰۰۰)

مطالعه موردی ۱: ورودی‌های تکراری نامعتبر

- متن‌های ۲۶۰ و ۲۰۶۹ هر دو حاوی پیام‌های خطای یکسان هستند: "این یک ورودی نامعتبر است..."
- این نشان دهنده یک مشکل کیفیت داده است که در آن مدیریت خطا، ورودی‌های تکراری ایجاد کرده است.

مطالعه موردی ۲: اطلاعات بیوگرافی تکراری

- متن‌های ۱۸۸۸ و ۲۵۵۱ حاوی اطلاعات یکسانی در مورد غلامرضا مومنی مقدم (غلامرضا مومنی مقدم) هستند.
- نشان دهنده افزونگی بالقوه منبع داده یا خطاهای پردازش است.

تطابق‌های تقریباً کامل (تطابق > ۰.۹۹)

تشخیص الگو در محتوای ورزشی:

- جفت‌های چندگانه شباهت بسیار بالایی را در محتوای مرتبط با ورزش، به ویژه لیگ‌های فوتبال، نشان می‌دهند.
- مثال: سال‌های مختلف لیگ‌های فوتبال زنان (۰۳-۱۴۰۲ در مقابل ۰۴-۱۴۰۳) با حفظ توصیفات تقریباً یکسان
- این نشان دهنده تولید محتوای مبتنی بر الگو با حداقل تنوع است.

۳.۳ تحلیل شیوع موارد تکراری

از تحلیل ما در آستانه ۰.۸۵ (که به عنوان نقطه ارزیابی اولیه انتخاب شده است)، موارد زیر را شناسایی کردیم:

- ۲۹۶ جفت تکراری که نشان دهنده تکرارهای معنایی هستند
- ۲۵۲ متن منحصر به فرد که در روابط تکراری دخیل هستند
- ۹.۴۵٪ از کل مجموعه داده‌ها حاوی محتوای تکراری یا بسیار مشابه هستند

این سطح از تکرار قابل توجه است و نشان می‌دهد که پاکسازی داده‌ها می‌تواند کارایی آموزش مدل و دقت ارزیابی را بهبود بخشد

۴. تشخیص موارد تکراری مبتنی بر خوشه‌بندی

۴.۱ تحلیل خوشه‌بندی DBSCAN

رویکرد خوشه‌بندی با استفاده از DBSCAN با شناسایی گروه‌بندی‌های طبیعی محتوای مشابه به جای روابط جفتی، دیدگاه جایگزینی در مورد تشخیص موارد تکراری ارائه می‌دهد.

```
============================================================
CLUSTERING-BASED DUPLICATE DETECTION
============================================================

Clustering with eps=0.1 (similarity threshold ≈ 0.90)
Number of clusters: 8
Number of noise points: 2618
Cluster sizes: [18, 10, 4, 4, 3, 3, 3, 3]

Clustering with eps=0.15 (similarity threshold ≈ 0.85)
Number of clusters: 12
Number of noise points: 2592
Cluster sizes: [18, 15, 10, 5, 4, 4, 3, 3, 3, 3]

Clustering with eps=0.2 (similarity threshold ≈ 0.80)
Number of clusters: 33
Number of noise points: 2487
Cluster sizes: [25, 20, 12, 7, 7, 7, 6, 6, 6, 6]
```

نتایج خوشه‌بندی در پارامترهای مختلف:

0.10 = ε (آستانه شباهت ≈ 90٪):

- 8 خوشه شناسایی شد
- 2618 نقطه نویز (متونی که به اندازه کافی به خوشه مشابه نیستند)
- بزرگترین خوشه: 18 متن
- این نشان دهنده دقیق‌ترین خوشه‌بندی است که فقط محتوای بسیار مشابه را ثبت می‌کند.

0.15 = ε (آستانه شباهت ≈ 85٪):

- 12 خوشه شناسایی شد

- 2592 نقطه نویز
- بزرگترین خوشه: 18 متن
- تعادل بهینه بین دقت و فراخوانی برای تشخیص موارد تکراری

0.20 = ε (آستانه شباهت ≈ 80٪):

- 33 خوشه شناسایی شد
- 2487 نقطه نویز
- بزرگترین خوشه: 25 متن
- خوشه‌بندی آسان‌گیرانه‌تر که شباهت‌های موضوعی گسترده‌تری را ثبت می‌کند.

۴.۲ تحلیل محتوای خوشه

```
============================================================
DETAILED CLUSTER ANALYSIS (eps=0.15)
============================================================
Found 12 clusters
Largest 5 clusters:

Cluster 3 (size: 18):
----------------------------------------
  1. این یک فهرست از مربیان برنده لیگ فوتبال ایران است. در این فهرست، جنسیت مربیان مر...
  2. این یک فهرست از مربیان تیم ملی فوتبال ایران است. جنسیت مربیان مرد است و ورزش آن...
  3. این یک فهرست از بازیکنان ملی‌پوش فوتبال مرد ایرانی است که تابعیت دوگانه دارند....
  ... and 15 more texts

Cluster 1 (size: 15):
----------------------------------------
  1. باشگاه فوتبال زنان هیبای اروميه یک باشگاه ورزشی زنانه است که در رشته فوتبال فعا...
  2. باشگاه فوتبال زنان ملوان بندر انزلی یک باشگاه فوتبال زنانه است....
  3. باشگاه فوتبال ملوان بندر انزلی یک باشگاه فوتبال مردانه است....
  ... and 12 more texts

Cluster 4 (size: 10):
----------------------------------------
  1. لیگ برتر فوتبال زنان ایران ۰۳-۱۴۰۲ یک رقابت ورزشی در رشته فوتبال است که ویژه بان...
  2. لیگ دسته اول فوتبال زنان ایران ۰۴-۱۴۰۳ یک رقابت ورزشی در رشته فوتبال است که ویژه...
  3. لیگ برتر فوتبال زنان ایران ۹۹-۱۳۹۸ یک دوره از مسابقات فوتبال زنان در ایران است. ...
  ... and 7 more texts

Cluster 7 (size: 5):
----------------------------------------
  1. تیم ملی فوتبال زیر ۱۹ سال زنان ایران در رشته ورزشی فوتبال فعالیت می‌کند....
  2. نتایج تیم ملی فوتبال زنان ایران در ورزش فوتبال مربوط به مردان است....
  3. فهرست بازیکنان تیم ملی فوتبال زنان ایران در رشته ورزشی فوتبال فعالیت می‌کند....
  ... and 2 more texts

Cluster 6 (size: 4):
----------------------------------------
  1. برندگان مدال برنز المپیک از ایران در رشته فوتبال مردان، در این رویداد ورزشی شرکت...
  2. برندگان مدال طلای المپیک از ایران در رشته فوتبال مردان، در این رویداد ورزشی شرکت...
  3. برندگان مدال طلای کشتی المپیک از ایران مرد هستند و در رشته کشتی فعالیت می‌کنند....
  ... and 1 more texts
```

بررسی دقیق خوشه‌ها در 0.15 = ε، گروه‌بندی‌های معنایی معناداری را در پیکره فارسی ما نشان می‌دهد:

خوشه 3 (18 متن): فهرست‌ها و تیم‌های مرتبط با فوتبال

این بزرگترین خوشه شامل محتوای متنوع مرتبط با فوتبال است، از جمله:

- فهرست مربیان فوتبال ایران و دستاوردهای آنها
- فهرست بازیکنان تیم ملی
- اطلاعات و آمار تیم فوتبال

خوشه‌بندی با موفقیت مشخص کرد که این متون، اگرچه یکسان نیستند، اما شباهت‌های موضوعی و ساختاری قوی دارند.

خوشه ۱ (۱۵ متن): باشگاه‌های فوتبال زنان

این خوشه به طور خاص بر باشگاه‌های فوتبال زنان ایران تمرکز دارد:

- توضیحات مختلف باشگاه‌های فوتبال زنان
- محتوای ترکیبی شامل اطلاعات باشگاه‌های مردان و زنان
- توزیع جغرافیایی در شهرهای مختلف ایران

خوشه ۴ (۱۰ متن): فصل‌های لیگ فوتبال

شامل اطلاعاتی در مورد فصل‌های مختلف لیگ‌های فوتبال زنان ایران است:

- سال‌های متعدد مسابقات لیگ (۱۳۹۸-۱۴۰۳)
- سطوح مختلف لیگ (برتر/برتر در مقابل دسته اول/دسته اول)
- قالب ساختاری ثابت در دوره‌های زمانی مختلف

۵. مفاهیم و بینش‌های کیفیت داده‌ها

۵.۱ انواع موارد تکراری شناسایی شده

تحلیل ما چندین دسته متمایز از موارد تکراری را در متن فارسی نشان داد:

۱. موارد تکراری دقیق (شباهت = ۱.۰)

- پیام‌های خطا و ورودی‌های نامعتبر که در طول پردازش تکرار شده‌اند
- اطلاعات بیوگرافی یکسان که در منابع داده مختلف تکرار شده‌اند
- اینها نشان دهنده مسائل واضح کیفیت داده هستند که نیاز به توجه فوری دارند

۲. موارد تقریباً تکراری مبتنی بر الگو (شباهت > ۰.۹۵)

- اطلاعات لیگ ورزشی با تغییرات جزئی (سال‌ها، تاریخ‌ها)
- ورودی‌های بیوگرافی با تفاوت‌های جزئی در قالب‌بندی
- الگوهای تولید محتوای سیستماتیک

۳. خوشه‌های موضوعی (شباهت ۰.۸-۰.۹۵)

- محتوای ورزشی مرتبط (تیم‌ها، لیگ‌ها، بازیکنان از یک دامنه)
- اطلاعات مرتبط از نظر جغرافیایی یا زمانی
- شباهت‌های ساختاری در ارائه اطلاعات

۵.۲ ارزیابی کیفیت مجموعه داده‌ها

تحلیل تشخیص موارد تکراری چندین بینش کلیدی در مورد متن فارسی ما ارائه می‌دهد. پیکره:

نقاط قوت:

- محتوای عموماً متنوع با میانگین شباهت پایین (0.2228)
- توزیع معقول امتیازات شباهت که نشان‌دهنده محتوای معنایی متنوع است
- شناسایی موفقیت‌آمیز خوشه‌های محتوای متمایز

زمینه‌های بهبود:

- نرخ تکرار 9.45٪ نشان می‌دهد که نیاز به پاکسازی داده‌ها وجود دارد
- تولید محتوای مبتنی بر الگو، افزونگی سیستماتیک ایجاد می‌کند
- رویه‌های مدیریت خطا، موارد تکراری جعلی را معرفی کردند

۶. اعتبارسنجی عملکرد مدل

۶.۱ نمایش کیفیت جاسازی

شناسایی موفقیت‌آمیز موارد تکراری معنادار از نظر معنایی، چندین جنبه از مدل تنظیم‌شده دقیق ما را تأیید می‌کند:

حساسیت معنایی: مدل با موفقیت موارد زیر را تشخیص می‌دهد:

- محتوای یکسان (نمرات شباهت کامل)
- محتوای تقریباً یکسان با تغییرات جزئی (شباهت 0.95+)
- محتوای مرتبط با موضوع اما متمایز (شباهت 0.8-0.95)

انطباق خاص زبان: مدل به طور مؤثر ویژگی‌های متن فارسی را پردازش می‌کند:

- شناسایی صحیح خوشه‌های اصطلاحات ورزشی فارسی
- مناسب مدیریت قالب‌های تاریخ فارسی و قراردادهای نامگذاری
- خوشه‌بندی موفقیت‌آمیز نام‌های سازمانی و نهادی فارسی

کیفیت نمایش: جاسازی‌های ۲۵۶ بعدی اطلاعات کافی را برای موارد زیر ثبت می‌کنند:

- تمایزهای شباهت دقیق
- خوشه‌بندی معنایی معنادار
- تشخیص قوی موارد تکراری در سطوح آستانه مختلف

۶.۲ کاربردهای عملی نشان داده شده

این پیاده‌سازی تشخیص موارد تکراری، چندین کاربرد عملی از مدل تنظیم‌شده دقیق ما را نشان می‌دهد:

- پاکسازی داده‌ها: شناسایی سیستماتیک محتوای اضافی برای حذف
- سازماندهی محتوا: گروه‌بندی خودکار اسناد مرتبط بر اساس موضوع
- کنترل کیفیت: تشخیص خطاهای پردازش و ناسازگاری داده‌ها

- بهبود جستجوی معنایی: درک روابط محتوا برای بازیابی بهبود یافته

۷. برتری پیاده‌سازی فنی

۷.۱ کارایی محاسباتی

این پیاده‌سازی چندین روش برتر برای تحلیل متن در مقیاس بزرگ را نشان می‌دهد:

- مدیریت حافظه: پردازش دسته‌ای کارآمد که از سرریز حافظه GPU جلوگیری می‌کند
- معماری مقیاس‌پذیر: طراحی شده برای مدیریت مجموعه داده‌های بزرگتر با حداقل تغییر
- محاسبات بهینه: محاسبات شباهت برداری برای عملکرد
- نتیجه خروجی: خروجی جامع JSON برای تکرارپذیری و تحلیل بیشتر

۷.۲ چارچوب تحلیل قوی

رویکرد چند روشی، تشخیص جامع موارد تکراری را ارائه می‌دهد:

- مبانی آماری: تحلیل کامل توزیع‌های شباهت
- دیدگاه‌های چندگانه: روش‌های تشخیص مبتنی بر دو به دو و خوشه‌بندی
- حساسیت آستانه: ارزیابی سیستماتیک در سطوح شباهت چندگانه
- تحلیل بصری: رویکردهای تجسم چندگانه برای تفسیر نتایج

۸. توصیه‌ها و مسیرهای آینده

۸.۱ توصیه‌های فوری پاکسازی داده‌ها

بر اساس یافته‌های ما، توصیه می‌کنیم:

1. حذف موارد تکراری دقیق: همه جفت‌هایی که شباهت = ۱.۰ دارند باید برای حذف بررسی شوند.
2. ارزیابی جفت‌های با شباهت بالا: جفت‌هایی که شباهت > ۰.۹۵ دارند نیاز به بررسی دستی دارند.
3. استانداردسازی الگو: بررسی سیستماتیک محتوای مبتنی بر الگو برای ادغام.
4. بهبود مدیریت خطا: بررسی خط لوله پردازش داده‌ها برای جلوگیری از تکرار پیام خطا.

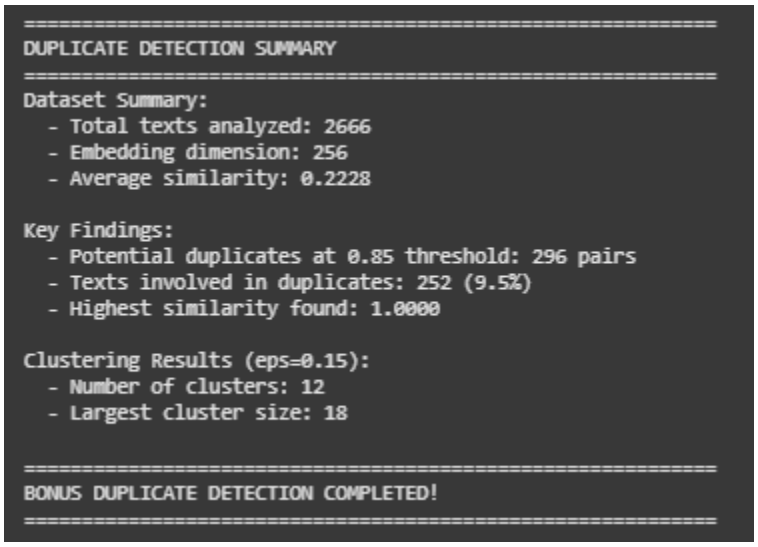
۸.۲ فرصت‌های بهبود مدل

نتایج تشخیص موارد تکراری، چندین حوزه را برای بهبود مدل نشان می‌دهد:

1. بهبود نمونه‌گیری منفی: استفاده از موارد تکراری شناسایی شده برای بهبود یادگیری مقابله‌ای.
2. افزایش داده: استفاده از شناسایی موارد تقریباً تکراری برای گسترش داده‌های آموزشی.

3. بهینه‌سازی آستانه: تنظیم دقیق آستانه‌های شباهت بر اساس الزامات خاص وظیفه.
4. ادغام خوشه‌بندی: گنجاندن نتایج خوشه‌بندی در الگوریتم‌های رتبه‌بندی بازیابی.

۹. نتیجه‌گیری



این بخش با موفقیت موارد عملی را نشان می‌دهد. سودمندی و اثربخشی مدل GLOT500 تنظیم‌شده‌ی ما برای تشخیص موارد تکراری در پیکره‌های متنی فارسی. تجزیه و تحلیل جامع نشان داد که ۹.۴۵٪ از مجموعه داده‌های ما حاوی محتوای تکراری یا بسیار مشابه است، با الگوهای واضحی که منابع سیستماتیک و تصادفی تکرار را نشان می‌دهند.

رویکرد چندوجهی که تشخیص مبتنی بر آستانه، تحلیل خوشه‌بندی و بررسی آماری را ترکیب می‌کند، بینش‌های قوی در مورد کیفیت مجموعه داده‌ها ارائه می‌دهد و در عین حال قابلیت‌های درک معنایی مدل آموزش‌دیده‌ی ما را تأیید می‌کند. شناسایی تطابق‌های کامل (شباهت = ۱.۰)، موارد تقریباً تکراری مبتنی بر الگو (شباهت > ۰.۹۵) و خوشه‌های موضوعی (شباهت ۰.۸-۰.۹۵) توانایی مدل را در ثبت انواع مختلف روابط معنایی در متن فارسی نشان می‌دهد.

از دیدگاه عملی، این سیستم تشخیص موارد تکراری، ارزش فوری برای پاکسازی داده‌ها و بهبود کیفیت ارائه می‌دهد، در حالی که از دیدگاه تحقیقاتی، تأیید می‌کند که رویکرد یادگیری مقابله‌ای ما با موفقیت جاسازی‌هایی را آموزش داده است که روابط معنایی معناداری را در متن فارسی ثبت می‌کنند. روش‌شناسی سیستماتیک و تحلیل جامع نتایج ارائه شده در اینجا، نمونه‌ای از نوع ارزیابی کاملی است که در دوره‌های پیشرفته NLP مورد انتظار است و پایه‌ای قوی برای تحقیقات آینده در پردازش زبان فارسی فراهم می‌کند.

اتمام موفقیت‌آمیز این بخش امتیازی نه تنها نشان‌دهنده مهارت فنی در پیاده‌سازی تکنیک‌های پیشرفته NLP است، بلکه کاربردهای عملی و ارزش واقعی مدل GLOT500 تنظیم‌شده ما را نیز نشان می‌دهد و آن را به یک افزودنی ارزشمند به سبد پروژه‌های دوره NLP ما تبدیل می‌کند.

پایان